CS336 · Spring 2026 · Lecture 09

缩放定律基础：从统计直觉到大模型资源分配

如何阅读这份自学增强讲义

原始英文幻灯片完整保留；每组原页之后紧接对应中文讲解。书签可跳转到原页与讲解。页码中的“原页”始终指原始 PDF 页码。

中文部分为自学补充；课堂转述、原论文结论与编者推导应按文中标记区分。第三方保存的字幕仅用于检索定位，不等同于教师审校逐字稿。

学习目标：读完后，你应能把双对数直线还原成幂律，区分总损失与超额损失；独立推导均值估计、分箱估计和临界批大小；设计固定 FLOPs 的模型与数据实验；解释 Kaplan 与 Chinchilla 为什么给出不同建议，并把训练最优与部署总成本最优分开。

先修：期望、方差、独立采样、导数与对数；交叉熵、训练/验证集；Transformer 的宽度、层数、嵌入和一次梯度更新。不熟悉方差时先精读原页16–19对应讲解，不熟悉参数计数时先读原页33–36。本文用 N 表示模型参数数、D 表示训练累计 token 数、C 表示训练 FLOPs、L 表示平均每 token 交叉熵；n 是统计例子的独立样本数，不能一概与重复训练后的 D 等同。

阅读主线：原页1–11建立问题与历史；12–27解释数据缩放、维度、混合与重复；28–42讨论架构、参数口径、批大小和学习率；43–55推导模型—数据联合分配并审视拟合方法；56–57回到完整实验流程。中文中的手算、推导和实践建议均为编者补充；标为“课堂补充”的内容是核对字幕后的转述，不是逐字引语。

来源索引：course/slides 为 Spring 2026 官方课程与原稿；captions 为第三方保存的本讲公开录像字幕。kaplan、chinchilla、batch 是核心原论文；data-repeat、data-filter、data-decide 支撑数据工程段；resolve、reconcile、replicate 支撑历史结论复核。所有原57页完整保留；原页19的速率推广、25的“下界”和49的拟合名称，在相邻中文中明确辨析。

Lecture 9

SCALING LAWS - BASICS

CS336

第 9 讲 · 原页 1–1 · 中文讲解

本讲究竟要解决什么问题

学习导航

缩放定律研究的是：当数据、模型或计算资源改变时，经过明确训练流程得到的性能怎样变化。它首先是一种预测与实验设计工具。“law”并不自动意味着物理定律或对所有网络成立的定理。本讲会先用可以证明的统计例子解释幂律为什么自然，再回到需要实测验证的语言模型。

贯穿全讲的问题是“下一单位资源应该花在哪里”。请把每张曲线都读成四件事：横轴资源及单位、纵轴指标及方向、保持不变的条件、实际测量覆盖的范围。只记住20 tokens/parameter之类数字，而不记住它优化的目标，容易在真正训练时用错。

本节参考（完整书目见讲义末尾）：[course] · [slides]

Taking scaling seriously

Imagine the following scenario..

Your friend has given you ten thousand B200s for a month,
and asked you to build a good open source LM.

What do you do?

- Put together your infra team and distributed training framework (A2)
- Put together a great pretraining dataset (A4)
- Run a big model (but which one??) <- we are here.

Scaling isn’t easy

Wide or deep? How many heads? Which nonlinearity?

Name	Has pa...	Link	Year	Tokenizer type	Vocab count	Norm	Parallel Layer	Pre-norm	Position embedding	Activations	MoE	MLP factor	num_layers	model_dim
Original transformer	Yes	arxiv.org/abs....03762	2017	BPE	37000	LayerNorm	Serial	☐	Sine	ReLU	☐	4	6	
GPT	Yes	cdn.openai.com/res...er.pdf	2018	BPE	40257	LayerNorm	Serial	☐	Absolute	GeLU	☐	4	12	
GPT2	Yes	cdn.openai.com/bet...rs.pdf	2019	BPE	50257	LayerNorm	Serial	☑	Sine	GeLU	☐	4	48	
T5 (11B)	Yes	arxiv.org/abs....10683	2019	SentencePiece	32128	RMSNorm	Serial	☑	Relative	ReLU	☐	64	24	
GPT3 (175B)	Yes	arxiv.org/abs....14165	2020	BPE	50257	LayerNorm	Serial	☑	Sine	GeLU	☐	4	96	
mT5	Yes	arxiv.org/abs....11934	2020	SentencePiece	250000	RMSNorm	Serial	☑	Relative	GeGLU	☐	2.5	24	
T5 (XXL 11B) v1.1	Kind of	github.com/goo...d#t511	2020	SentencePiece	32128	RMSNorm	Serial	☑	Relative	GeGLU	☐	2.5	24	
Gopher (280B)	Yes	arxiv.org/abs....11446	2021	SentencePiece	32000	RMSNorm	Serial	☑	Relative	ReLU	☐	4	80	
Anthropic LM (not claude)	Yes	arxiv.org/abs....00861	2021	BPE	65536			☑			☐	4	64	
LaMDA	Yes	arxiv.org/abs....08239	2021	BPE	32000			☑	Relative	GeGLU	☐	8	64	
GPTJ	Kind of	huggingface.co/Ele...t-j-6b	2021	BPE	50257	LayerNorm	Parallel	☑	RoPE	GeLU	☐		28	
Chinchilla	Yes	arxiv.org/abs....15556	2022	SentencePiece	32000	RMSNorm	Serial	☑	Relative	ReLU	☐	4	80	
PaLM (540B)	Yes	arxiv.org/abs....02311	2022	SentencePiece	256000	RMSNorm	Parallel	☑	RoPE	SwiGLU	☐	4	118	
OPT (175B)	Yes	arxiv.org/abs....01068	2022	BPE	50272	LayerNorm	Serial	☑	Absolute	ReLU	☐	4	96	
BLOOM (175B)	Yes	arxiv.org/abs....05100	2022	BPE	250680	LayerNorm	Serial	☑	AliBi	GeLU	☐	4	70	
GPT-NeoX	Yes	arxiv.org/pdf...45.pdf	2022	BPE	50257	LayerNorm	Parallel	☑	RoPE	GeLU	☐	4	44	
GPT4 OPEN	Ad	arxiv.org/abs....08774	2023	BPE	100000			☐			☐			
LLaMA (65B)	Yes	arxiv.org/abs....13971	2023	BPE	32000	RMSNorm	Serial	☑	RoPE	SwiGLU	☐	2.6875	80	
LLaMA2 (70B)	Yes	arxiv.org/abs....09288	2023	BPE	32000	RMSNorm	Serial	☑	RoPE	SwiGLU	☐	3.5	80	
Mistral (7B)	Yes	arxiv.org/abs....06825	2023	BPE	32000	RMSNorm	Serial	☑	RoPE	SwiGLU	☐	3.5	32	

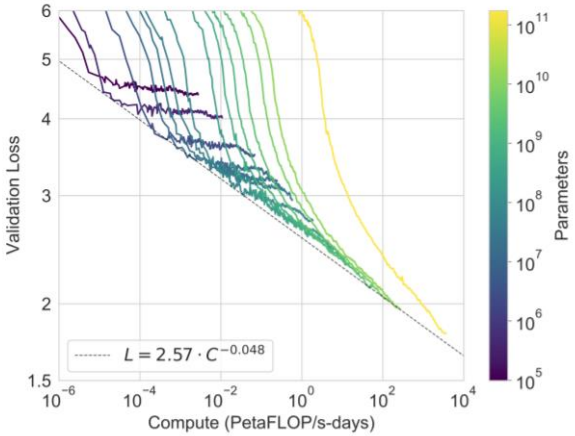
We could cargo cult things from existing LMs… but how do these get optimized in the first place?

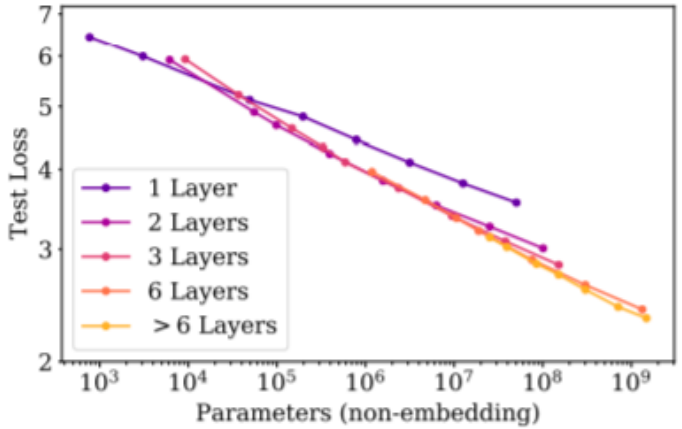
Today: simple, predictive ‘laws’ for behaviors of LMs

The approach -

scaling laws which are simple, predictive rules for model performance

Old and unpleasant: tune hyperparameters on big models
New (over?) optimism: tune on small models, extrapolate to large ones





第 9 讲 · 原页 2–4 · 中文讲解

从昂贵的大训练转向可验证的小规模预测

为什么有GPU还不够

原页2的B200场景把基础设施、数据、模型设计分开。硬件决定你能执行多少计算，但不会替你决定宽度、深度、数据量和训练时长。原页3的模型配置表展示了设计自由度：复制一个配置可以作为起点，却不能说明它适合你的数据和预算。

一个候选配置应包含架构、tokenizer、数据配方、优化器、学习率与批大小调度。若在小模型上只改变层数、大模型上却同时换数据和训练时长，结果就不能简单归因于层数。缩放预测依赖一族定义清楚、尽量可比较的实验。

如何读原页4两张图

左图每条训练曲线来自不同大小的模型：在相同累计计算量的竖线上，取最低验证损失，得到已试配置的经验最优包络。不是一条曲线一直最低，而是预算增大后更大模型才可能划算。右图在不同非嵌入参数规模上比较层数，帮助判断小规模差异会保持、缩小还是交叉。

编者补充：若方案A的超额损失为2C^(-0.10)，B为3C^(-0.20)，在归一化预算C=1时A好；两者相等要求C^0.10=1.5，即C约57.7。小规模赢家未必是大规模赢家。这只是手算模型，不是课件实验拟合值；外推交叉点之前，应新增中间规模验证。

课堂补充 · 00:03:08–00:04:02

课堂把缩放视为从小规模行为推测大规模行为的工程方法。节约的是超参数试错的成本；并不保证任何小模型上的优势都会延续。最终要为预测保留验证规模，并允许曲线告诉你假设失效了。

本节参考（完整书目见讲义末尾）：[slides] · [captions]

Part 1. Scaling laws, history and background.

- Data scaling as empirical sample complexities

- Initial forays into understanding neural scaling with data

Sample complexity and rates

Theorists have thought about ‘scaling’ for a long time..

$$\epsilon(\hat{h}) \leq \left(\min_{h \in H} \epsilon(h)\right) + 2\sqrt{\frac{1}{m} \log \frac{2k}{\delta}}$$

(learning in a finite set of k hypotheses)

Under the assumptions of Theorem 1.5, the rate of convergence of the estimator $\hat{p}_n(x_0)$ is $\psi_n = n^{-\frac{\beta}{2\beta+1}}$, which means that for a finite constant C and for all $n \geq 1$ we have

$$\sup_{p \in \mathcal{P}(\beta, L)} \mathbb{E}_p \left[\left(\hat{p}_n(x_0) - p(x_0) \right)^2 \right] \leq C \psi_n^2.$$

(generative modeling for smooth densities)

But these are upper bounds, not actual, realized loss values.

https://www.cs.cmu.edu/~epxing/Class/10701/slides/lecture16-VC.pdf
Hall, 1989

第 9 讲 · 原页 5–6 · 中文讲解

样本复杂度：保证上界与经验预测的区别

符号与理论问题

原页6上式讨论一个包含k个候选函数的有限假设集合H。ε(h)表示总体风险，ĥ是按训练数据选出的模型，m是独立训练样本数，δ是允许保证失败的概率。图中形式为 $\varepsilon(\hat{h}) \le \min_{h \in H} \varepsilon(h) + 2\sqrt{[\log(2k/\delta)/m]}$。这是在相应有界损失、独立同分布等条件下的高概率上界；不同推导的常数可不同。

第一项是集合中最好模型的风险，第二项控制有限样本造成的选择误差。候选更多，选择更容易被偶然性误导，所以出现log k；样本更多，误差项变小。若只想让第二项降到ε以内，代数上需要 $m \ge 4\log(2k/\delta)/\varepsilon^2$。这里用ε表示允许的误差宽度，与函数ε(h)的角色不同。

为什么它不是训练曲线

取k=100、δ=0.05、m=10000，附加项约0.0576。这个数是上界，不是模型一定产生的实际损失，更不表示数据翻四倍后真实误差恰好减半。真实风险可能远低于上界。下方平滑密度估计片段中，$p(x_0)$是真实密度在点x_0的值，$\hat{p}_n(x_0)$是估计值，β描述光滑程度；$\psi_n=n^{(-\beta/(2\beta+1))}$是误差幅度尺度，所展示的平方风险上界为$C\psi_n^2$，即O(n^(-2β/(2β+1)))。这里是相应一维光滑密度类与估计条件下的界，C为常数；不同函数类、光滑性和指标会有不同速率。

经验缩放则对测得的L拟合，例如L(n)=L∞+An^(-α)，试图预测具体数值。它可能很准，却没有自动继承理论界的概率保证。理论提供候选形式和直觉，实测负责决定它在哪段区间可用。

本节参考（完整书目见讲义末尾）：[slides] · [vc]

Earliest (data) scaling law paper – 1993

Learning Curves: Asymptotic Values and Rate of Convergence

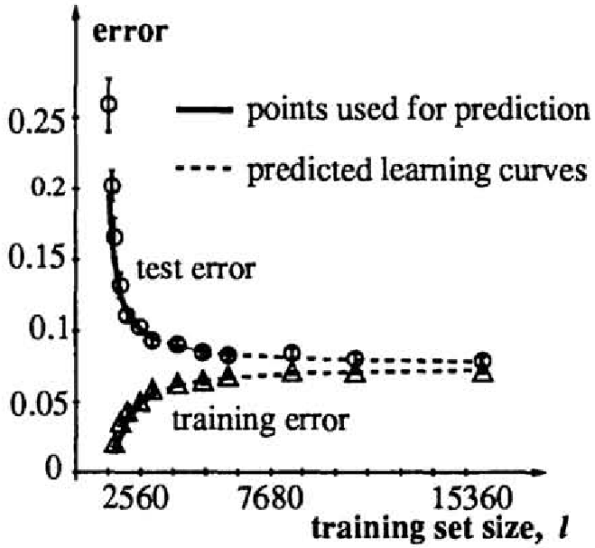
Corinna Cortes, L. D. Jackel, Sara A. Solla, Vladimir Vapnik, and John S. Denker
AT&T Bell Laboratories
Holmdel, NJ 07733

Abstract

Training classifiers on large databases is computationally demanding. It is desirable to develop efficient procedures for a reliable prediction of a classifier's suitability for implementing a given task, so that resources can be assigned to the most promising candidates or freed for exploring new classifier candidates. We propose such a practical and principled predictive method. Practical because it avoids the costly procedure of training poor classifiers on the whole training set, and principled because of its theoretical foundation. The effectiveness of the proposed procedure is demonstrated for both single- and multi-layer networks.

A typical example of learning curves is shown in Fig. 2. The test error is always larger than the training error, but asymptotically they reach a common value, a. We model the errors for large sizes of the training set as power-law decays to the

$$\mathcal{E}_{\text{test}} = a + \frac{b}{l^{\alpha}} \qquad \text{and} \qquad \mathcal{E}_{\text{train}} = a - \frac{c}{l^{\beta}}$$



Early history of scaling laws – data scaling

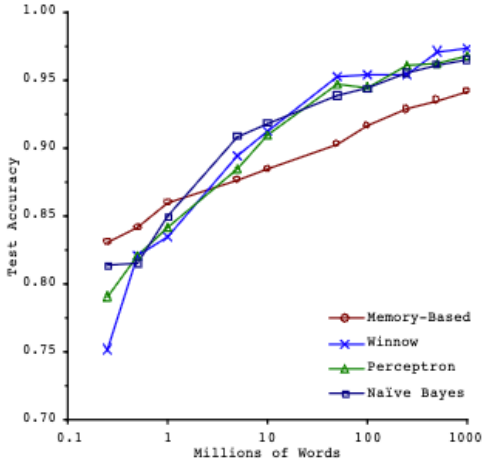
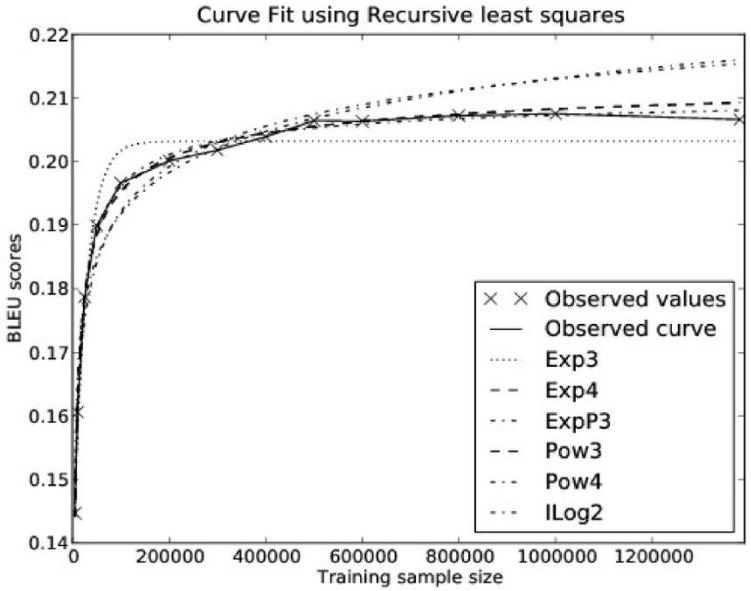


Figure 1. Learning Curves for Confusion Set Disambiguation

these results suggest that we may want to reconsider the trade-off between spending time and money on algorithm development versus spending it on corpus development. At least for the problem of confusable disambiguation, none of the learners tested is close to asymptoting in performance at the training corpus size commonly employed by the field.

Log-linear scaling with data [Banko and Brill ‘01]

Early history of scaling laws – data scaling



Model	Formula
Exp_3	$y = c - e^{-ax+b}$
Exp_4	$y = c - e^{-ax^{\alpha}+b}$
ExpP_3	$y = c - e^{(x-b)^{\alpha}}$
Pow_3	$y = c - ax^{-\alpha}$
Pow_4	$y = c - (-ax+b)^{-\alpha}$
ILog_2	$y = c - (a/\log x)$

Table 1: Curve families.

Early tests of functional forms

Kolachina et al 2012 – power law relation between data and downstream performance

第 9 讲 · 原页 7–9 · 中文讲解

历史图像：学习曲线的形状需要比较

原页7：训练误差和测试误差为什么靠近

1993年的图已展示“用小样本实验预测更大样本效果”的思想。随着训练集增大，训练误差可能上升：模型不能再轻易记住少量例子；测试误差则可能下降：估计更稳定。二者靠向非零水平，说明不能把无限数据等同于零误差。图上的预测点与拟合曲线应分开看，曲线平滑不等于外推已经被验证。“最早”在这里是课程选取的历史起点，并非对所有统计学习文献的穷尽断言。

原页8：数据收益与算法收益要在同一预算下看

Banko与Brill的图以训练词数为横轴、准确率为纵轴，对比多种消歧方法。增加语料后各算法都改善，部分算法的排序还会变化。其启发是：固定小语料上的算法优势，不足以决定大语料场景的赢家。它并不证明采集数据永远比算法研发便宜；采集、标注、计算与任务覆盖都要计成本。这里的准确率越高越好，不能直接套用后文“loss越低越好”的读图方向。

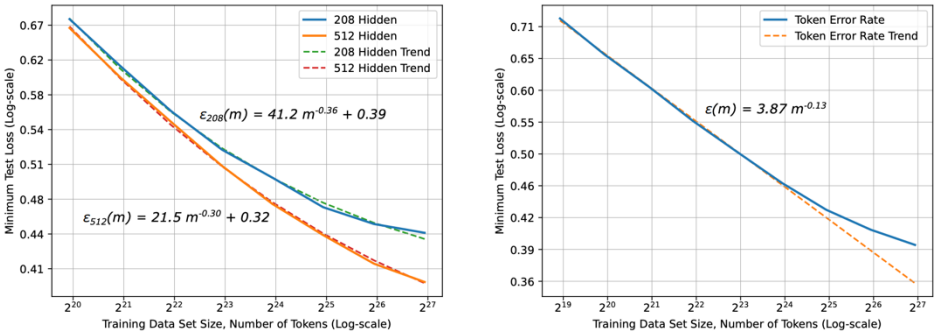
原页9：指数、幂律和上限

表中给出多个候选函数。若分数趋近上限c，幂律可写y=c−ax^(-α)，需要看的是差距c−y，而不是直接对y取对数。指数形式y=c−a exp(−bx)也会在有限区间呈现递增并饱和；它和幂律在远处的预测却可能相差很大。

编者例子：令归一化剩余误差在x=1时均为1，幂律x^(-1)在x=10为0.1，而指数exp[−(x−1)]约0.000123。少量靠近x=1的点不能可靠区分它们。Kolachina等的机器翻译研究比较学习曲线族，因此本讲的原则不是“任何数据都强行拟合直线”，而是比较候选形式并检验留出点。

本节参考（完整书目见讲义末尾）：[slides] · [banko] · [kolachina]

Hestness et al 2017



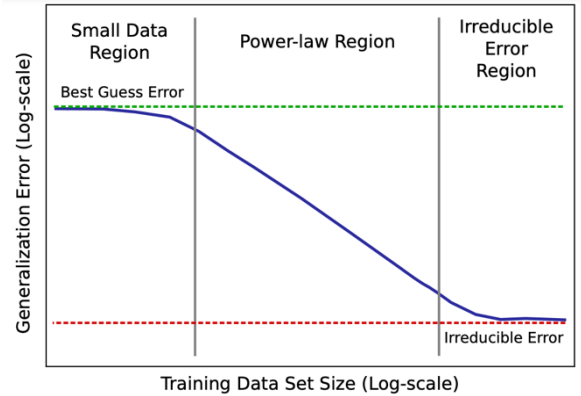


Figure 1: Neural machine translation learning curves. Left: the learning curves for separate models follow $\varepsilon(m) = \alpha m^{\beta_g} + \gamma$. Right: composite learning curve of best-fit model at each data set size.

Earliest 'large scale neural' scaling work: Hestness 2017

Predictable scaling on many tasks (MT, LM, Speech) and hypothesized scaling shape.

Hestness II

Very ahead of its time..

“Emergence”

> Although small data set testing may be possible, it can be difficult to ensure that training data is large enough to see the power-law learning curve region. We have found that models with poor optimizer parameterization or model priors/initialization show accuracy cliffs, where accuracy is only as good as best guessing, but the model trains on enough data to be in the power-law region. Researchers must take great care when defining a "large enough" training set for small data testing. We leave the methodology for defining such a training set to future work.

Scaling by compute

> **Computational Limits:** If we have identified a desirable model to scale to larger training sets, the next potential limitation is the speed of computation. In some cases, training large models on very large data sets would take months or years of critical path compute time, making these training runs impractical for any real world problem on existing systems. However, predictable learning and model size curves may offer a way to project the compute requirements to reach a particular accuracy level. The compute requirements could inform decisions about how to scale computational capacity to unlock these compute-limited applications.

Speed = accuracy

> **The Performance-Accuracy Trade-off:** Many DL software and hardware techniques impose a trade-off between model accuracy and the speed of computation. Learning curves and model size growth can indicate whether these techniques could regain lost accuracy by improving the speed of computation. For example, low-precision computation/quantization and sparse models give up some model accuracy (e.g., up to 20%) in order to improve compute throughput. If the compute throughput improvements allow DL developers to train larger models on larger data sets, these accuracy losses might be easily recoverable.

第 9 讲 · 原页 10–11 · 中文讲解

神经缩放的三个区域与系统效率

原页**10**：幂律只是中间区域

Hestness等的图把学习分为小数据区、幂律区、不可约误差区。数据太少时，优化失败或接近猜测，稳定斜率尚未出现；中间区增加数据会按近似比例降低误差；末端受噪声、模型容量或其他条件限制而变平。固定的小模型可能更早到平台，因此比较“数据带来的最好效果”时，往往需要随数据量增加模型容量。图中单个模型的曲线与各规模最佳模型拼出的曲线不是同一个实验对象。

原页**11**：速度怎样变成性能

如果系统优化让同一时间预算内的有效训练FLOPs翻倍，并且数据与优化设置支持继续利用这些计算，才可能沿缩放曲线得到更低损失。编者手算：若可下降部分为AC^(-0.1)，翻倍计算后的剩余比例为2^(-0.1)约0.933，改善约6.7%，并不是性能翻倍。若优化使数值误差增大、改变训练算法，必须重新验证这条曲线。

图中的“emergence”提醒读者，准确率这种离散指标可能出现门槛：连续分数逐渐改善，超过判定阈值后才记为答对。因此看到分数跳升，不能仅凭图形断言底层学习过程突然不连续，也不能反过来断言所有涌现都只是指标产物。

课堂补充 · **00:08:27–00:10:14**

课堂用Hestness的工作连接数据、计算和系统性能：当更大训练规模能稳定转化为性能时，提高吞吐就具有模型质量上的价值。这是本讲与前面GPU、并行训练内容的联系，前提是训练预算能真正转化为有效的优化进展。

本节参考（完整书目见讲义末尾）：[slides] · [hestness] · [captions]

Part 2. Neural (LLM) scaling behaviors

1.Data vs performance

“Are there simple rules that determine how data affects performance?”

2. Data vs model size

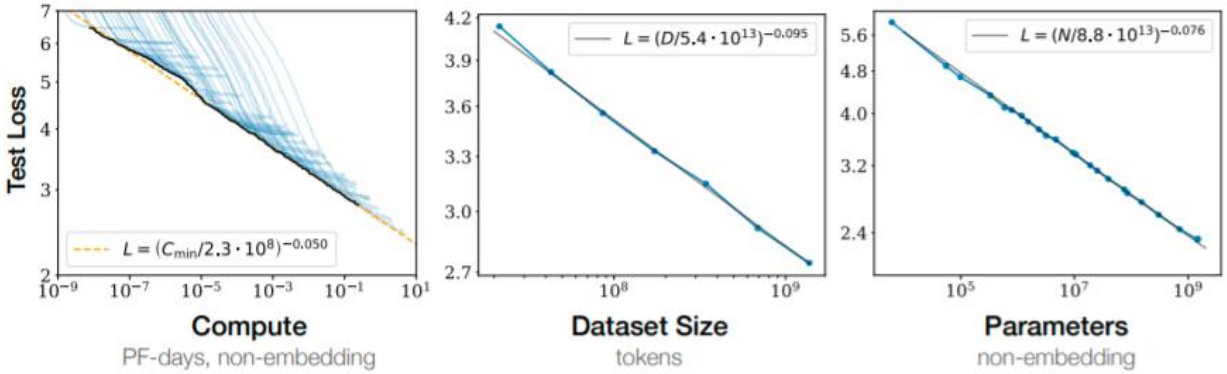
Do we train on more data or bigger models?

3. Hyper-parameters vs performance

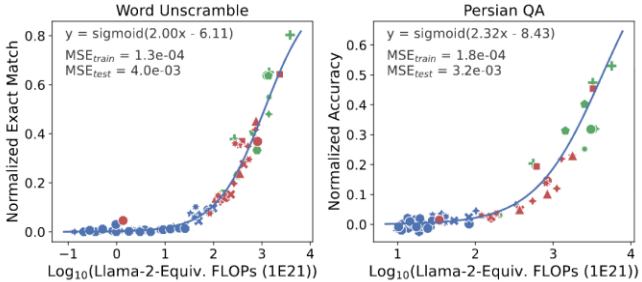
“How should we set hyperparameters on the big model??”

Scaling laws – power law relationships for many factors

These scaling laws hold on *many* different kind of phenomena!



They even hold in non standard settings





[Kaplan+ 2020]

第 9 讲 · 原页 12–13 · 中文讲解

先认清横轴：三类资源不是同一变量

数据、参数、计算分别回答什么

原页12的三个问题分别是：固定其他因素时，多数据是否更好；固定预算时，数据与模型怎样分配；扩大模型时，超参数怎样迁移。原页13上排分别以计算、数据量、参数量为横轴。看起来都是下降曲线，含义却不同。数据缩放通常希望模型容量不成为瓶颈；模型缩放则要有足够数据和训练；计算缩放常取多种配置中的最佳表现。不能从其中一张图直接读出另外两张的最优策略。

指标与外推的边界

交叉熵L是平均负对数似然。若以自然对数计算，困惑度PPL=exp(L)；因此log(PPL)=L，但log(L)不是L，也不是PPL。双对数直线的判断必须对应图真正使用的坐标。下排的下游准确率、能力分数与时间趋势仅说明可能存在其他规律；它们不由上排幂律逻辑上推出。

编者补充：训练算力C是累计运算数，FLOPs/s是速率，GPU月是时间乘设备数。利用率不同，同样GPU月会得到不同C。先明确测量口径，再用缩放规律做资源决策，才可以与系统优化结果连接。

本节参考（完整书目见讲义末尾）：[slides] · [kaplan]

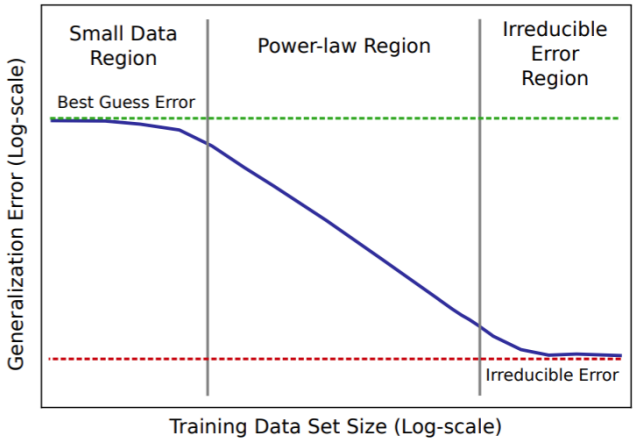
Data vs performance

What's a data scaling law?

Data scaling laws : simple formula that maps dataset size (n) to error

What do we expect out of scaling laws?

Monotonic, logistic-like curves

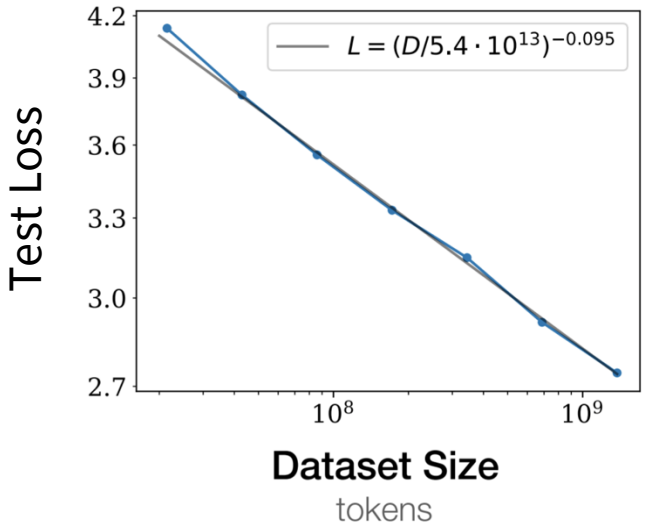


[Hestness+ 2017]

Data scaling laws for language models

First, an empirical observation

Loss and dataset size is linear on a log-log plot



"Scale-free" or
"Power law"

(For language modeling, from Kaplan+ 2020)

第 9 讲 · 原页 14–15 · 中文讲解

双对数直线的代数与数据收益

从直线还原公式

设样本规模D>0，超额损失ΔL=L−L∞>0，假定ΔL=A D^(-α)，其中A>0、α>0。取对数得log ΔL=log A−α log D。横轴每增加相同倍数，纵轴的超额损失也乘相同因子；这就是此处“scale-free”的含义。改变D的计量单位会改变A和截距，但不会改变α。

原页15图的拟合为L=(D/(5.4×10¹³))^(-0.095)，是特定实验区间的无显式平台项拟合。不要把其中的大常数解释为必须训练的token数量，也不要把这个指数当成所有语言模型的常数。原页14的两端平台说明，全区间不可能一直用同一条无平台项直线。

编者手算：小指数意味着资源昂贵

若α=0.1，数据翻倍，ΔL乘2^(-0.1)约0.933；数据乘10，ΔL乘10^(-0.1)约0.794。要让ΔL减半，需要数据乘2^(1/0.1)=1024。若原L=3、L∞=2，数据乘10后L约2.794，而不是3×0.794=2.383。

这解释了为什么去掉平台项很关键：靠近L∞时，log L曲线会变平，即使log(L−L∞)仍近似直线。平台项若由有限数据拟合不准，又会让估计斜率不稳定。实践中应同时检查原始损失、残差、拟合区间与参数不确定性。

课堂补充 · **00:20:38–00:21:29**

课堂回答“模型比数据大”时强调的是模型容量尚未使曲线进入平台的区间。应把它理解为瓶颈条件，而不是普适的“参数数必须大于token数”规则。参数与token是不同对象，单看二者数值大小不能判定容量是否足够。

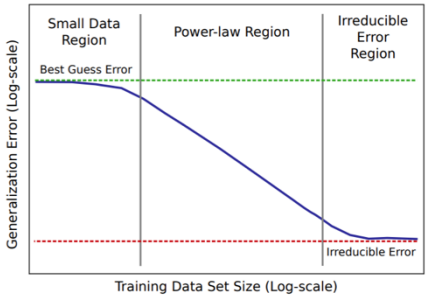
本节参考（完整书目见讲义末尾）：[slides] · [kaplan] · [captions]

Conceptual foundations of data scaling laws.

Q: Why do scaling laws show up?

We know error should be monotone

But why is it a power law / linear in log-log?



A (?): Estimation error naturally decays polynomially.

But this answer may take a moment to understand. Let's work through an example.

Example: If our task is to estimate the mean of a dataset, what's the scaling law?

Toy example: mean estimation

Input: $x_1 \ \ldots x_n \ \sim N(\mu, \sigma^2)$

Task: estimate the average as $\hat{\mu} = \frac{\sum_i x_i}{n}$

What's the error? By standard arguments..

$$\mathrm{E}[(\hat{\mu} - \mu)^2] = \frac{\sigma^2}{n}$$

This is a 'scaling law'

$$\log(Error) = -\log n + 2\log \sigma$$

More generally, any polynomial rate $1/n^{\alpha}$ is a scaling law

第 9 讲 · 原页 16–17 · 中文讲解

均值估计：完整推导一个真正可证明的幂律

独立性如何产生1/n

设$x_1,\ldots,x_n$独立同分布，均值μ、有限方差σ^2，估计量$\hat{\mu}=(x_1+\ldots+x_n)/n$。由期望线性性$E[\hat{\mu}]=\mu$，所以偏差为0。均方误差可以拆成$\mathrm{Var}(\hat{\mu})+(E[\hat{\mu}]-\mu)^2$，因此这里等于$\mathrm{Var}(\hat{\mu})$。

继续展开$\mathrm{Var}(\hat{\mu})=n^{(-2)}[\Sigma_i \mathrm{Var}(x_i)+2\Sigma_{i<j}\mathrm{Cov}(x_i,x_j)]$。独立性使协方差为0，剩下$n^{(-2)}\times n\sigma^2=\sigma^2/n$。原稿选择高斯分布便于描述$\hat{\mu}$的完整分布；上面这个均方误差结论其实只需独立同分布和有限方差，并不需要高斯。

误差指标会改变指数

于是$\log \mathrm{MSE}=2\log\sigma-\log n$，斜率为−1。若画均方根误差$\mathrm{RMSE}=\sigma/\sqrt{n}$，斜率变成−1/2。编者手算：σ=2时，n=25的MSE为0.16、RMSE为0.4；n=100时分别为0.04、0.2。样本翻四倍，MSE变为四分之一，但RMSE只减半。

“更多数据应更好”是在期望或经合理训练的趋势层面说的；某次随机样本的实际误差可能上升。若样本相关，协方差项不消失；将同一批数据复制十遍也不会等价于采集十倍独立数据。这条统计事实为后面的重复训练收益递减提供直觉，但不直接给出神经网络重复训练的精确公式。

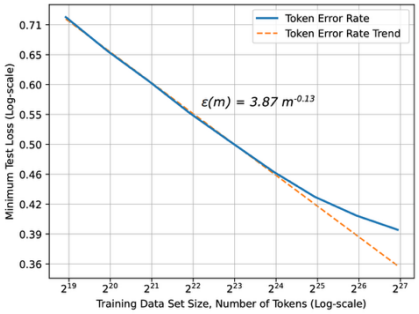
本节参考（完整书目见讲义末尾）：[slides]

Scaling law exponents: an intriguing mystery

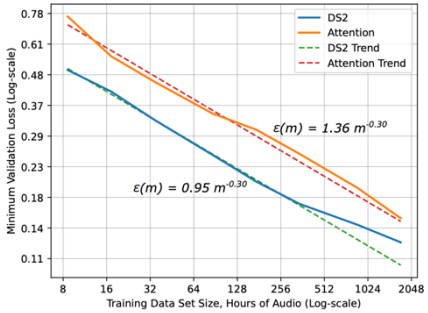
Fact: Similar arguments show most 'classical' models (regression, etc) have $\frac{1}{n}$ scaling

This means we should see $y = -x + C$

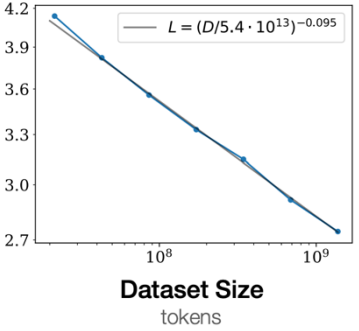
What do we find in neural scaling laws?



Machine translation



Speech



Language modeling

Very different from predictions.. Why might this be?

第 9 讲 · 原页 18–18 · 中文讲解

为什么不能把神经网络指数当成均值估计指数

先统一问题，再比较斜率

原页18把经典估计的1/n与机器翻译、语音、语言建模的缓慢下降放在一起。经典的1/n一般指固定维度、正则条件下的均方或超额风险；不是所有经典模型、所有损失都必然如此。有限假设集的泛化上界可出现1/√n，刚才的RMSE也出现1/√n，因而第一步永远是核对指标。

神经网络可能随数据一起增大、同时学习复杂特征，数据还具有长尾结构；这与只估计一个固定均值很不一样。小指数表示同样倍率的数据增长只减少较少的当前可下降误差，不等于“网络没有学习”，也不能由α≈0.1就直接宣布真实世界只有10维。

一个读图练习

编者例子：若可下降误差在数据100倍时从1变成0.4，则α=−log(0.4)/log(100)约0.199。只有在两点属于同一幂律区间、平台项处理正确且其他训练条件一致时，这个估计才有意义。两个点总能定一条直线，因此至少还应检查中间点和留出更大规模的点。下一页借分箱估计说明：维度与函数复杂度可以自然改变速率，但它只是候选解释。

本节参考（完整书目见讲义末尾）：[slides] · [hestness]

Detour: scaling laws for (nonparametric) learning

Neural nets can approximate arbitrary functions. Lets turn that into an example.

Input: $x_1 \ldots x_n$ uniform in 2D unit box. $y_i = f(x_i) + N(0,1)$

Task: estimate f(x)

Approach: cut up the 2D space into boxes with length $n^{-\frac{1}{4}}$

What's our estimation error?

Informally, we have $\sqrt{n}$ boxes, each box gets $\sqrt{n}$ samples.

$$Error \approx \frac{1}{\sqrt{n}} + (other\ smoothness\ terms)$$

In d-dimensions, this becomes $Error = n^{-1/d}$ - **This means scaling is** $\boldsymbol{y = -\frac{1}{d}x + C}$

Takeaway: flexible 'nonparametric' learning has dimension dependent scaling laws.

第 9 讲 · 原页 19–19 · 中文讲解

非参数分箱：把维度依赖推导清楚

二维例子逐步计算

原稿令x在二维单位正方形均匀采样，y=f(x)+ε，ε独立、均值0、方差1；要估计的是未知函数f。将正方形划为边长h的小格，每格使用该格训练标签的均值预测。格子数约h^(-2)，每格平均样本数约nh^2，因此格内平均噪声的方差约$1/(nh^2)$。

仅考虑方差不够：格内的f并不完全相同。编者补充假设f是Lipschitz函数，即$|f(x)-f(x')|\le K\|x-x'\|$。二维格内距离至多$\sqrt{2}h$，所以用格均值代替点值的偏差为O(h)，平方偏差为$O(h^2)$。忽略边界、随机格占用与常数，估计f的均方风险约$c_b\ h^2+c_v/(nh^2)$，c_b、c_v在这里表示正常数。令两项同量级，$h^2\approx 1/(nh^2)$，得$h\approx n^{(-1/4)}$、风险约n^(-1/2)。

数字例子与高维推广辨析

若n=10000，取h=0.1，则有100格，每格平均100个样本；噪声平均的方差约0.01，平方偏差也按h^2约0.01的量级变化。两者都必须计入。随机分箱不保证每格恰有100个点；上述是平均量级分析。

推广到d维：格数约h^(-d)，每格样本约nh^d，风险近似$h^2+1/(nh^d)$。平衡$h^{(d+2)}\approx 1/n$，得到$h\approx n^{(-1/(d+2))}$，风险约$n^{(-2/(d+2))}$。若使用能利用s阶光滑性的合适估计方法，相应形式可为$n^{(-2s/(2s+d))}$，不能把任意高阶光滑性都直接套给简单常数分箱。

原稿公式的适用边界

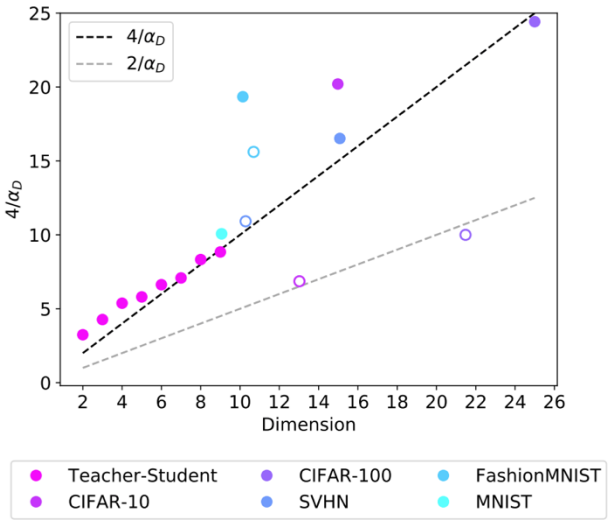
原页末尾直接写Error=n^(-1/d)，字幕00:18:23–00:19:17也作了这一简化。对本页所给“有噪声的函数估计”设定，这不是由前面的分箱推导得出的普遍速率；d=2时n^(-1/d)恰好与上面结果一致，其他d一般不同。应保留的结论是“复杂函数的估计速率会依赖维度和光滑性”。另外，若评价目标变成预测一个新的含噪y，测试均方误差还要加不可约噪声方差1；估计f的风险趋零不代表预测y的总风险趋零。

本节参考（完整书目见讲义末尾）：[slides] · [captions] · [nonparametric]

Intrinsic dimensionality theory of data scaling laws

Some have made the following argument (Bahri 2021)

1. Scaling laws arise due to polynomial rates of learning $\frac{1}{n^{\alpha}}$
2. Some argue the slope α is closely connected to the *intrinsic dimensionality* of the data.



But estimators of intrinsic dimension are sketchy, and this is not airtight..

第 9 讲 · 原页 20–20 · 中文讲解

内在维度理论：解释性假说与可测量证据

内在维度不是输入向量长度

图像可能有数百万像素，但其自然变化可以集中在更低维结构上；类似地，文本的词表大小、序列长度、嵌入宽度都不自动等于学习问题的内在维度。Bahri等研究将数据数量、模型大小与不同学习区间联系起来，为某些幂律指数提出理论机制。原图把估计维度与经验指数的关系作比较，是对假说的证据，不是直接测量“世界维度”的仪器。

如何避免倒推过度

从α反推维度，必须先指定风险指标、光滑性、噪声与学习机制。例如上一节Lipschitz有噪回归的α=2/(d+2)，若α=0.1，代数反推d=18；原稿简化式α=1/d会给d=10。两个结果不同，说明仅有一个斜率不足以唯一确定维度。实际语言模型还可能受容量、优化、分布偏移和平台项影响。

课堂00:19:46–00:20:20明确保留了对内在维度估计器与证据力度的怀疑。因此学会这个理论的价值在于产生可检验的机制：改变数据结构后斜率是否按预测变化？而不是用一个漂亮相关图替代完整解释。

本节参考（完整书目见讲义末尾）：[slides] · [bahri] · [captions]

Other data scaling laws

Data scaling thus far: how does dataset size relate to performance?
Related question: how does dataset *composition* affect performance

- Picking optimal data mixture using small scale models
- Deciding whether to repeat data or not
- Combing the two and balancing quality with repetition rate

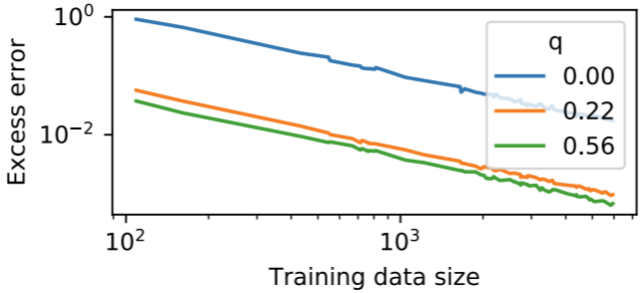
Other advanced data scaling law: distribution shift

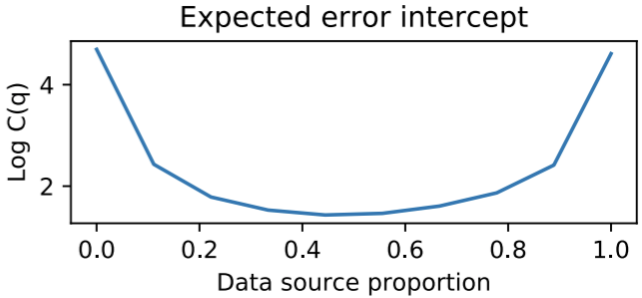
Data scaling thus far: how does dataset size relate to performance?

Related question: how does dataset *composition* affect performance

A: Data composition affects the offset, not the slope.

These 'distribution shift' scaling laws can tell us about the importance of collecting diverse data!





[Hashimoto 2021]

第 9 讲 · 原页 21–22 · 中文讲解

数据组成与分布偏移：斜率和截距分别代表什么

由一个数据量变量变为混合比例

原页21把数据工程拆成配比、重复、质量与重复的共同优化。设两个来源的采样比例为q与1−q，评估分布固定。一个便于理解的模型是ΔL(n,q)=A(q)n^(-α)。对数后为log ΔL=log A(q)−α log n；若α不变，数据配比只改变截距，不同配比曲线平行。原页22左图近似平行、右图截距对q呈碗状，表达的是适当混合能比单一来源更好。

编者例子：多样性为什么能帮助

设目标任务需要估计两个独立人群的均值，二者噪声方差均为1，评价时各占一半。训练总样本为n，比例q分给第一群，1−q分给第二群。两个均值的估计方差分别为1/(nq)、1/[n(1−q)]，因此平均风险为[1/q+1/(1−q)]/(2n)。

q=0.5时风险为2/n；q=0.9时约5.56/n。斜率都是−1，常数却差约2.78倍。若q趋近0，第一群无法可靠估计，公式也发散。这个理想例子说明覆盖不足不能总靠另一来源的数据量弥补；真实数据源有迁移关系，不能简单照搬独立人群公式。

限定原页22的断言

“组成影响截距、不影响斜率”是相关模型和实验中的结构假设，不是所有分布偏移的定理。任务难度、支持集、噪声和数据质量变了，平台项与指数都可能变化。课堂00:22:28–00:23:22使用线性回归的两来源例子解释这一点；工程上应先检验不同配比的斜率是否相容，再用平行曲线外推。

本节参考（完整书目见讲义末尾）：[slides] · [hashimoto] · [captions]

In practice: data mixture selection via scaling is hard

Data Mixing Laws: Optimizing Data Mixtures by Predicting Language Modeling Performance

Jiasheng Ye[1,*] Peiju Liu[1,*] Tianxiang Sun[1] Jun Zhan[1] Yunhua Zhou[2,†] Xipeng Qiu[1,†]

{jsye23,pjliu23}@m.fudan.edu.cn zhouyunhua@pjlab.org.cn xpqiu@fudan.edu.cn

[1]Fudan University [2]Shanghai AI Laboratory

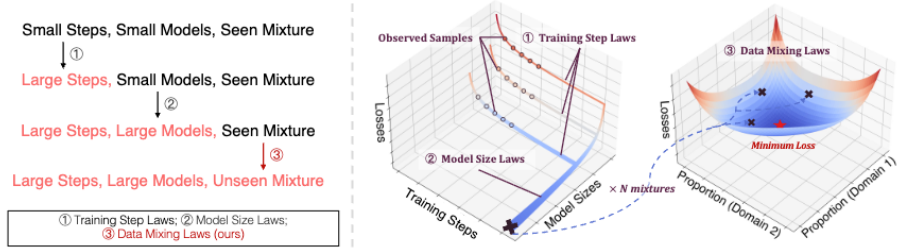


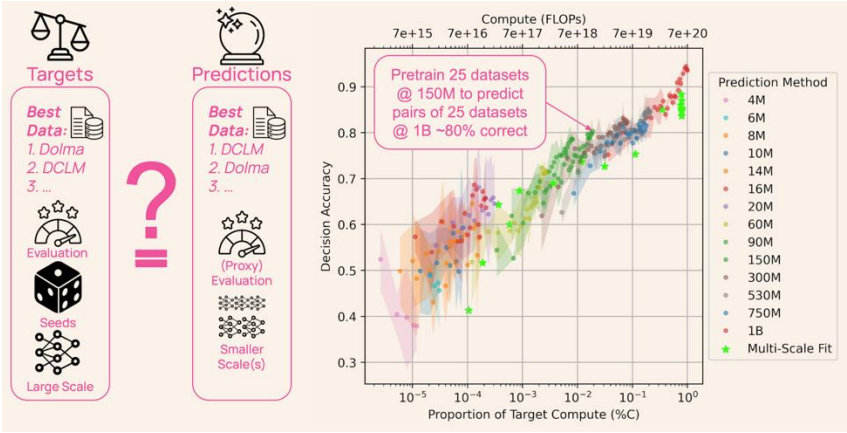
Figure 1: Illustration on our pipeline to optimize data mixture. **Left:** Our pipeline takes three steps. Starting from small-scale training results, the three steps use the scaling laws of training steps, model sizes, and data mixing laws to predict model performance on large steps, large models, and unseen mixtures, respectively. **Right:** Visualization of the three-step pipeline to predict model performance on the target model size, training step, and mixtures.

Natural idea – build data scaling laws

DataDecide

How to Predict Best Pretraining Data with Small Experiments

Ian Magnusson[*12] Nguyen Tai[*3] Ben Bogin[*1] David Heineman[1] Jena Hwang[1] Luca Soldaini[1] Akshita Bhagia[1]
Jiacheng Liu[12] Dirk Groeneveld[1] Oyvind Tafjord[1] Noah A. Smith[12] Pang Wei Koh[12] Jesse Dodge[1]



Empirical eval – just take the best small dataset

第 9 讲 · 原页 23–23 · 中文讲解

数据混合预测：复杂拟合应胜过简单基线

两项研究在回答什么

左图Data Mixing Laws尝试将训练步数、模型大小、混合比例逐层建模：小模型和少量配比实验先估函数，再预测没有跑过的配比与更大模型。右图DataDecide则关心实际决策：同样的试验计算预算，哪种方法最能选中大规模时更好的训练数据？模型拟合得复杂，并不自动提高这个选择准确率。

怎样设计一场有用的比较

编者补充：对每个候选数据配方使用同样tokenizer、训练预算与评估集，先建立“只在一个小规模上排序”的基线。然后比较多尺度拟合在额外花费计算后，能否更准确预测留出目标规模的配方排序。要把调拟合函数的预算也计入；若在目标规模结果上反复选函数，就不再是纯预测。

DataDecide在其公开实验范围内发现，单一小规模的排名是很强的基线，测试的缩放方法未超越它的计算—决策前沿。范围包括至多1B参数模型；不应外推为“所有万亿token训练都无需研究数据混合”。若曲线斜率近似相同，优胜截距本来就可能在大小规模保持排名；若斜率交叉、重复程度改变或下游指标变化，则需更谨慎。

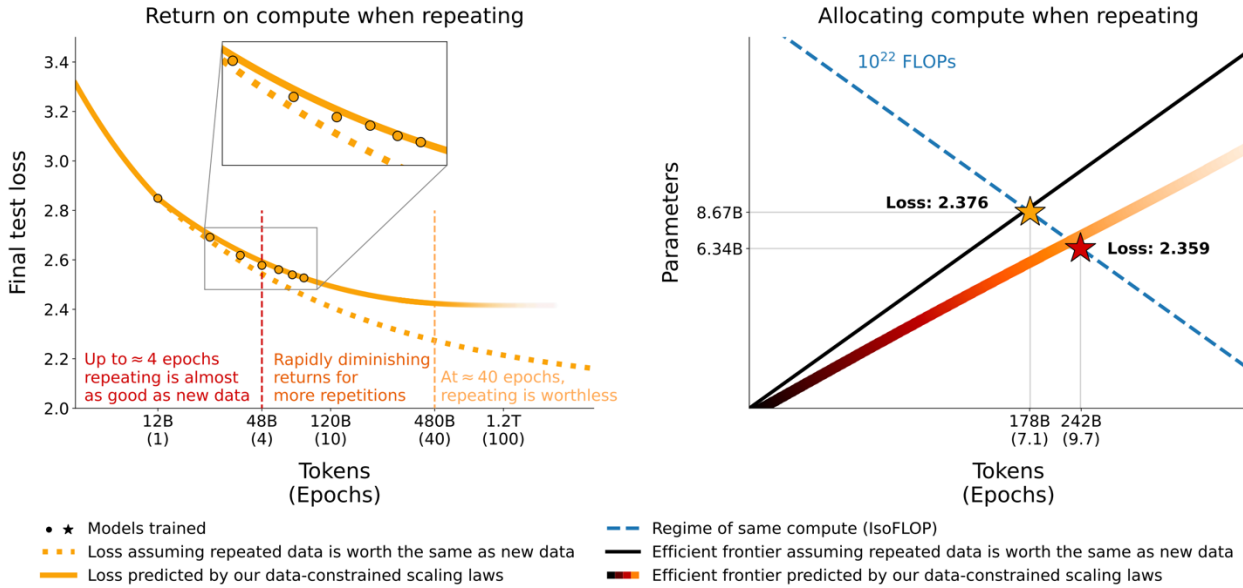
课堂补充 · **00:23:37–00:25:17**

课堂用新闻与Wikipedia的配比说明拟合方法，又指出实际数据配比预测噪声较大。应从这些结果学到“用简单基线检验额外建模是否有价值”，而不是把它读成放弃做小实验。

本节参考（完整书目见讲义末尾）：[slides] · [mixing] · [data-decide] · [captions]

Scaling laws under data repetition

In practice, we have finite data – how does repeating examples affect scaling?



Scaling Data-Constrained Language Models

Niklas Muennighoff [1] Alexander M. Rush [1] Boaz Barak [2] Teven Le Scao [1]
Aleksandra Piktus [1] Nouamane Tazi [1] Sampo Pyysalo [3] Thomas Wolf [1] Colin Raffel [1]
[1] Hugging Face [2] Harvard University [3] University of Turku
n.muennighoff@gmail.com

$$D' = U_D + U_D R_D^* (1 - e^{\frac{-R_D}{R_D^*}}) .$$

D' = Effective data
Ud = Unique tokens
Rd* = Constant
Rd = Repetition

第 9 讲 · 原页 24–24 · 中文讲解

重复数据：累计token不等于独立信息

读图与变量

左图横轴是累计训练token/遍数，观察到重复初期仍有收益，更多遍后相对持续提供新数据的理想曲线越来越差。右图是固定计算预算时模型大小与训练token的权衡；重复数据变廉价的信息增量会改变最优分配。原论文在其配方下观察到前几遍较接近新数据收益；“四遍”是经验范围，不能推广为所有语料的安全阈值。

公式D′=U_D+U_D R_D* [1−exp(−R_D/R_D*)]中，U_D是唯一token量，D′是拟合意义的有效数据量，R_D是第一遍之后的额外重复次数，R_D*>0控制边际收益衰减。总暴露量D=U_D(1+R_D)。D′不是实际训练token计数，也不是直接测出的独立样本数。

极限与手算

当R_D=0，D′=U_D。当R_D远小于R_D*，用exp(−x)≈1−x，得到D′≈U_D(1+R_D)：重复初期近似同等有用。当R_D趋于无穷，D′趋于U_D(1+R_D*)，不会无限增长。导数dD′/dR_D=U_D exp(−R_D/R_D*)说明每多一遍的有效增量下降。

编者例子，取U_D=100M、R_D*=3：训练4遍对应R_D=3，实际见过400M token，有效数据约100M+300M(1−e^(-1))=289.6M；训练10遍实际为1000M，有效数据约385.1M，极限为400M。常数3纯属教学设定，不是论文通用拟合值。该饱和函数不能表达任意过拟合后的损失上升，下一页正说明配方和区间边界。

本节参考（完整书目见讲义末尾）：[slides] · [data-repeat]

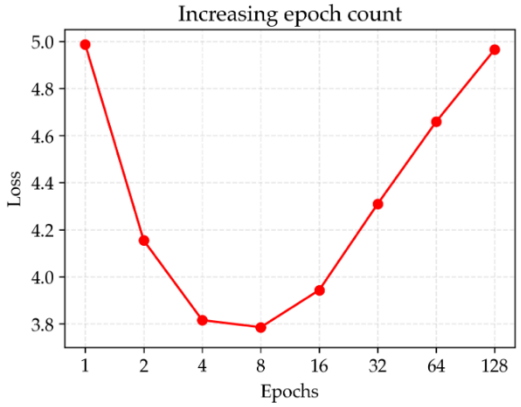
Scaling laws in *compute unbounded* settings

Pre-training under infinite compute

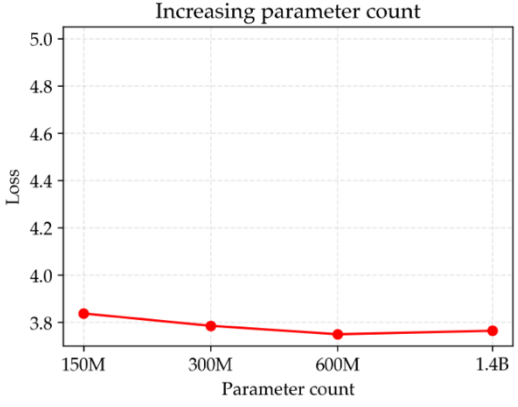
Konwoo Kim∞, Suhas Kotha∞, Percy Liang, Tatsunori Hashimoto
Stanford University

Important notes:

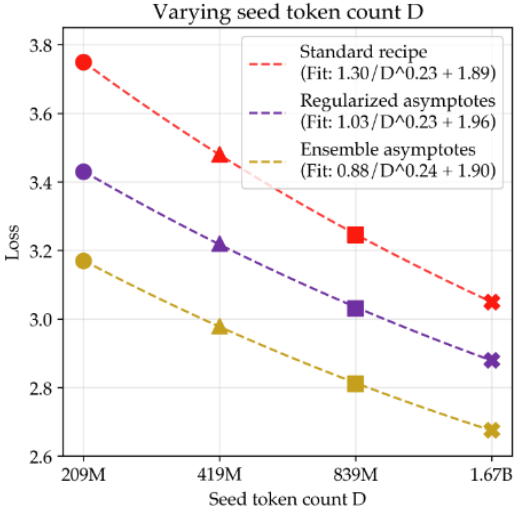
1. Scaling laws can ‘break’ if you blindly apply it
2. Scaling laws are *lower bounds* so you can always potentially do better



Tuned H	1	8	128
Learning rate	1e-3	1e-3	3e-3



Tuned H	150M	300M	600M	1.4B
Learning rate	3e-3	1e-3	1e-3	3e-4
Epoch count	8	8	4	4



第 9 讲 · 原页 25–25 · 中文讲解

计算近乎不限时：经验曲线可以被更好的配方突破

三张图要一起读

左图在固定有限数据上增加epoch，验证损失先降后升，提示反复优化训练目标可能开始损害泛化。中图增加模型参数也有收益递减；“计算更多”并未保证无条件改善。右图比较标准训练、正则化与集成后关于唯一数据规模的曲线，研究的是进一步挖掘有限数据的价值。集成通常要付额外训练与推理成本，因此是否值得还依赖使用目标。

“lower bounds”的方向辨析

原页说缩放定律是lower bounds，仍可能做得更好。若纵轴是越低越好的损失，不能将它理解为严格数学命题L≥f(C)：真正的不可突破损失下界恰恰不允许得到更低的loss。这里更合适的理解是，现有配方展示一种已能达到的性能基线，改进配方后可能得到更低损失。有限已跑实验的最低损失包络，也只是候选集合中的最好结果。

课堂01:10:29–01:10:47再次强调：缩放的是一套具体recipe，若warmup或batch设置不适合小规模，拟合出来的预测也会受影响。所以“突破旧缩放曲线”可以意味着算法与配方改善，不一定推翻资源与表现之间存在规律这件事。

课堂补充 · 00:29:02–00:30:09

问答专门提醒这页坐标容易误读：横轴数据规模按倍数增加，不能因标签看起来整齐就当线性轴；较窄纵轴区间内，对数与线性变化也可能视觉相近。拟合形式和坐标刻度比“看起来是一条直线”更可靠。有限范围内许多光滑函数都近似线性，外推必须检验。

本节参考（完整书目见讲义末尾）：[slides] · [infinite] · [captions]

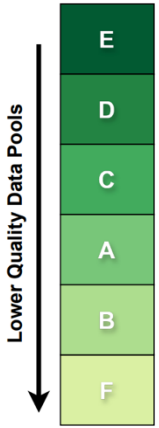
Data selection scaling and accounting for finiteness

Given that repeated data is less valuable..

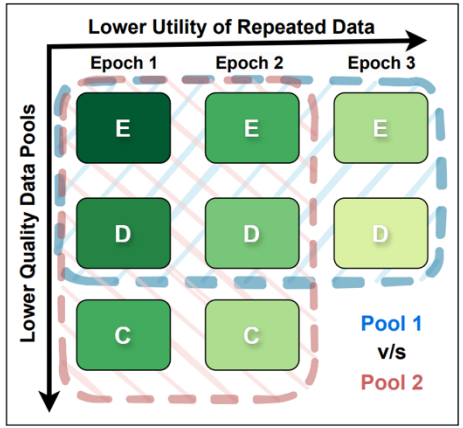
Data selection should then be adaptive to scale !

Scaling Laws for Data Filtering—
Data Curation *cannot* be Compute Agnostic

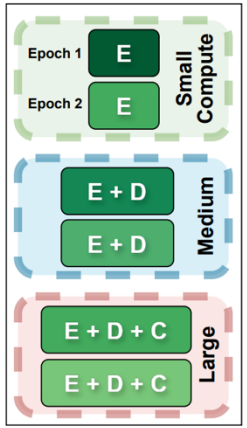
Sachin Goyal*† Pratyush Maini*†
Zachary C. Lipton† Aditi Raghunathan† J. Zico Kolter†‡
Carnegie Mellon University† Bosch Center for AI‡
{sachingoyal,pratyushmaini,zlipton,raditi,zkolter}@cmu.edu



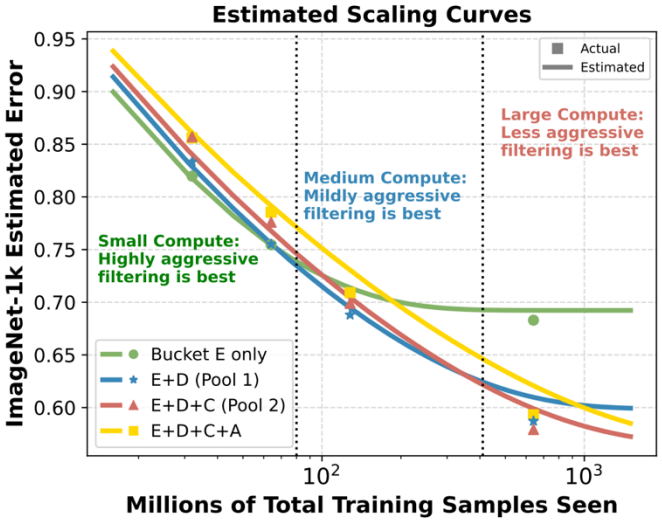
Web Data is Non-Homogenous



Quality-Quantity Tradeoff (QQT) for Data Filtering



Best Data Pool Changes with Total Compute



Recap: data scaling laws

- Remarkably linear relationship between log-data size and log-error
- Holds across domains and models
- Theory understanding: similar to generalization bounds: mean estimation example
- Applications: data collection / curation

第 9 讲 · 原页 26–27 · 中文讲解

质量、数量与重复共同决定过滤强度

原页**26**的池子图

不同数据桶的“质量”是相对于目标评估而言的训练效用。左图把高效用桶优先使用，但相同桶反复见过后，新增一次训练的边际价值下降；原来稍低质量但尚未见过的桶可能更划算。右图中不同保留比例的曲线交叉，所以最佳过滤阈值随总训练计算改变。该论文的主要实验证据来自视觉语言模型的数据过滤，课件借它展示一般的质量—数量权衡，不应直接当成所有文本语料的定量定律。

编者手算与工程含义

假设高质量数据有100M唯一token，较低质量数据有500M。训练预算只够100M token时，优先高质量桶合理；预算够600M时，只用高质量桶要重复6遍，而混合可以减少重复。究竟哪种好，应比较高质量桶第6遍与另一桶首遍的边际收益，而不只是比较首遍质量分数。这不是“预算大就无条件加入噪声”：有害、偏离目标或污染评估的数据可能始终不值得加入。

把原页27小结写成一个可执行问题：先确认唯一数据量，再记录总暴露量和来源比例，保持测试分布固定，用小规模实验测量不同桶与重复的效用。单变量L(D)是起点，实际数据工程常需L(N,U_D,重复,配比)。这些额外变量解释了为什么只报一个token总数不足以复现实验。

本节参考（完整书目见讲义末尾）：[slides] · [data-filter]

Scaling laws for model engineering

Now for what I promised at the start: **model scaling!**

Our motivation: how can we efficiently design huge LMs?

- LSTMs vs Transformers
- Adam vs SGD

How should we allocate our limited resources?

- Train models longer vs train bigger models?
- Collect more data vs get more GPUs?

Scaling laws provide a simple procedure to answer these.

Hyperparameter questions

We'll consider some of these choices in the context of the classic Kaplan scaling paper

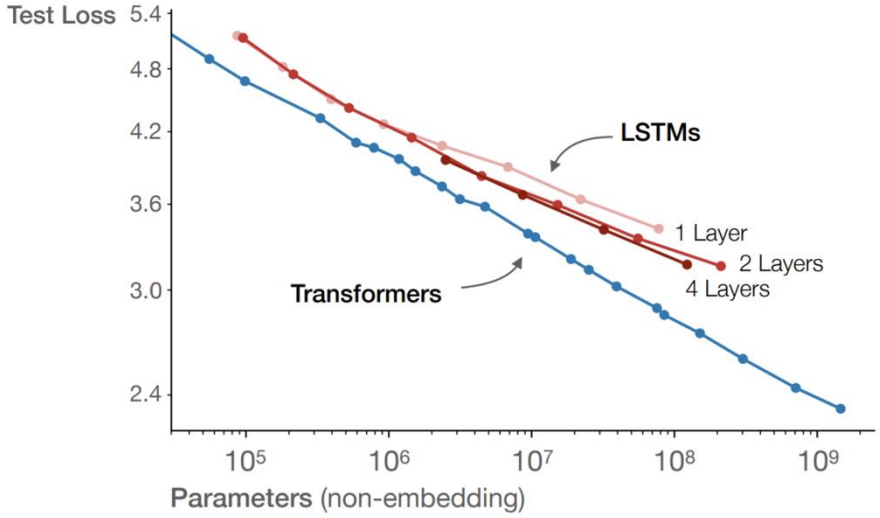
- Architecture
- Optimizer
- Aspect ratio / depth
- Batch size

1. Architecture: transformers vs LSTMs

Q: Are transformers better than LSTMs?

Brute force way: spend tens of millions to train a LSTM GPT-3

Scaling law way:



[Kaplan+ 2021]

第 9 讲 · 原页 28–30 · 中文讲解

用缩放曲线比较架构：先规定公平的横轴

从数据问题转向模型工程

原页28–29列出架构、优化器、深宽比、批大小等选择。方法是为每个候选族训练一串规模，观察其损失如何随资源变化，再预测目标预算的优劣。原页30的横轴实际是非嵌入参数数，不是训练FLOPs：图中Transformer在相同参数量下损失较低，并且大规模趋势更好，但这不直接证明相同训练时间、相同显存下也有同等优势。

读出差距，不只看赢家

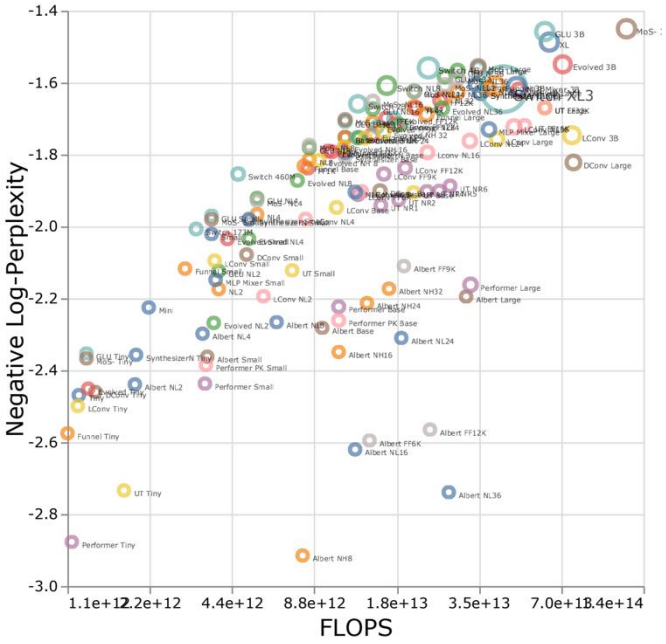
若两族有相同平台项、同指数α，且ΔL_A=A_A N^(-α)、ΔL_B=A_B N^(-α)，A_A<A_B表示A在同参数量下更好。要使B追平A在N上的损失，B所需参数比为(A_B/A_A)^(1/α)。小指数会放大常数差距：假设A_B/A_A=1.1、α=0.1，参数比约2.59。该手算说明一个小的纵向优势可能有大的资源价值，但它依赖拟合及同平台假设。

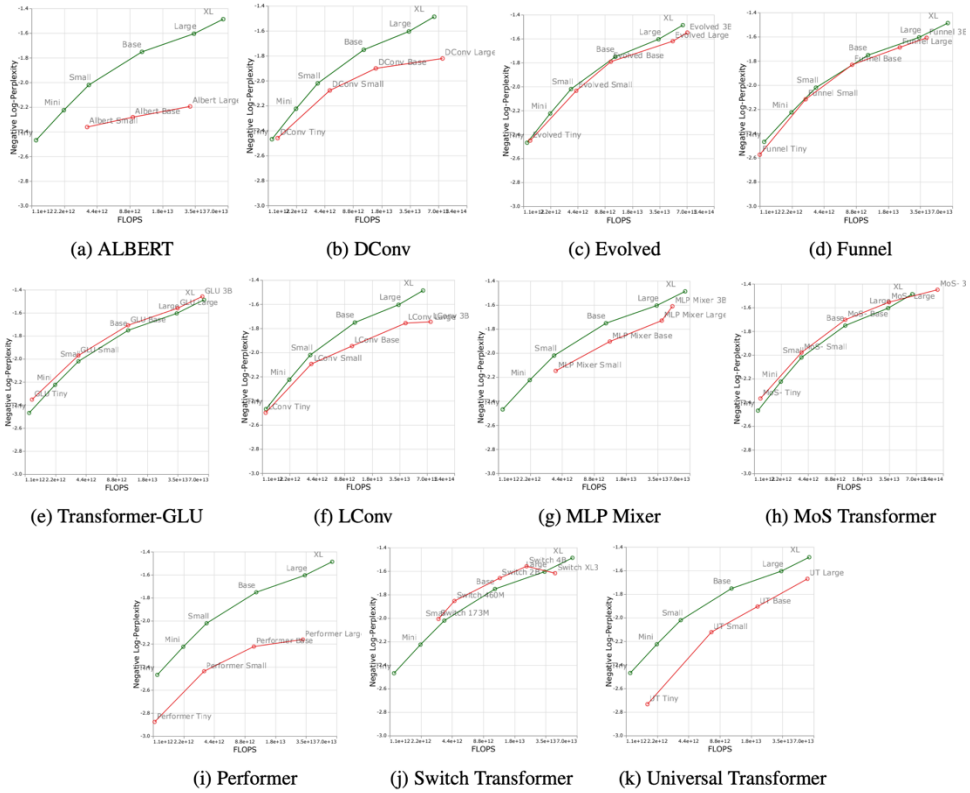
如何做一组真正可比较的实验

应固定语料、tokenizer、上下文与评估方式，让各架构有合理调参机会，并报告参数量、FLOPs、训练时长。LSTM和Transformer并行性质不同，固定N只比较容量代理，固定C更接近训练资源问题，固定时长又牵涉硬件效率。图支持所测范围内的趋势，不是对所有现代循环或状态空间模型的判决。原页的Kaplan年份标为2021，而本讲所用核心论文最初发布于2020；这里统一以论文标题和URL识别来源。

本节参考（完整书目见讲义末尾）：[slides] · [kaplan]

1. Many architectures





Cross-architecture scaling in Tay et al 2022.

第 9 讲 · 原页 31–31 · 中文讲解

跨架构缩放：效率技巧也要接受规模检验

多个小图怎样读

原页31左图横轴是FLOPs，纵轴是负的log困惑度，因此向上通常表示更好，与“loss越低越好”方向相反。右侧各图把一个候选架构与基线跨规模比较：注意是持续领先、逐渐靠拢还是发生交叉。GLU、稀疏专家、注意力近似等改动，既可能改变单位计算效率，也可能改变给定计算下的统计效率。

编者补充：复杂度更低不保证损失更低

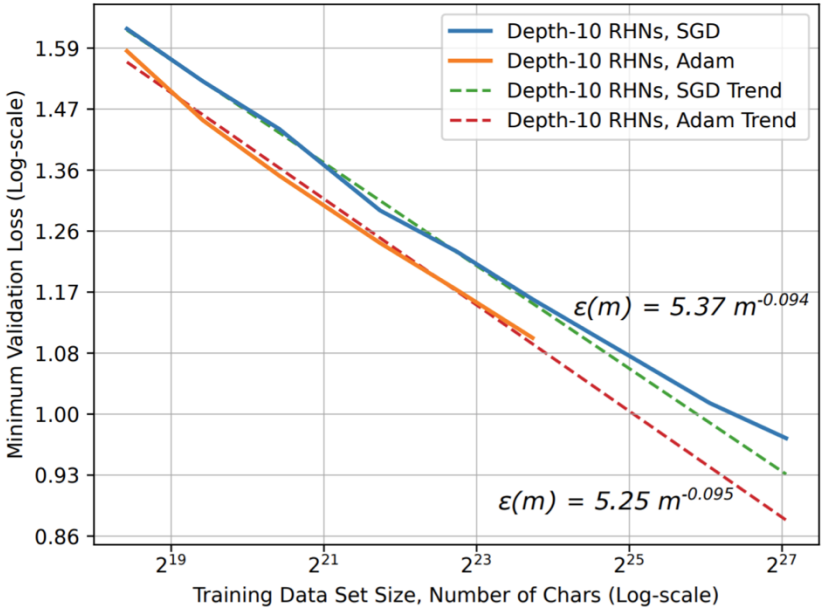
把一个运算从较高复杂度换成较低复杂度，可以让同样计算运行更长序列或更大模型，却也可能牺牲表达能力。因此需要把真实训练结果放回统一的FLOPs—性能坐标中。Tay等的Transformer架构缩放研究表明，不同改动并非都沿同一种趋势变化。

不要只摘最小模型上最好看的点，也不要把单个最大规模异常点忽略：它可能是优化失败、预算不足，也可能是真实机制变化，应检查运行状态和误差后再作结论。下游迁移、硬件吞吐和推理延迟是额外评价维度，后面原页41会看到预训练指标与下游排名可以不一致。

本节参考（完整书目见讲义末尾）：[slides] · [architecture]

2. Optimizer choice

What about ADAM vs SGD?



[Hestness+ 2017]

(Note, this is in 2017, so pre-transformers. RHN is recurrent highway nets)

第 9 讲 · 原页 32–32 · 中文讲解

优化器缩放：平行曲线也有实际价值

原图能支持什么

图中比较2017年循环高速网络RHN上的Adam与SGD，横轴是训练字符数，纵轴是最低验证损失。两条趋势的指数约−0.094与−0.095，十分接近；Adam在这个实验中有较低的损失。它说明优化器变化可以主要表现为常数差异，却不能证明现代Transformer中Adam永远优于SGD，也不能证明所有优化器都保持相同指数。

从常数差异转为资源量

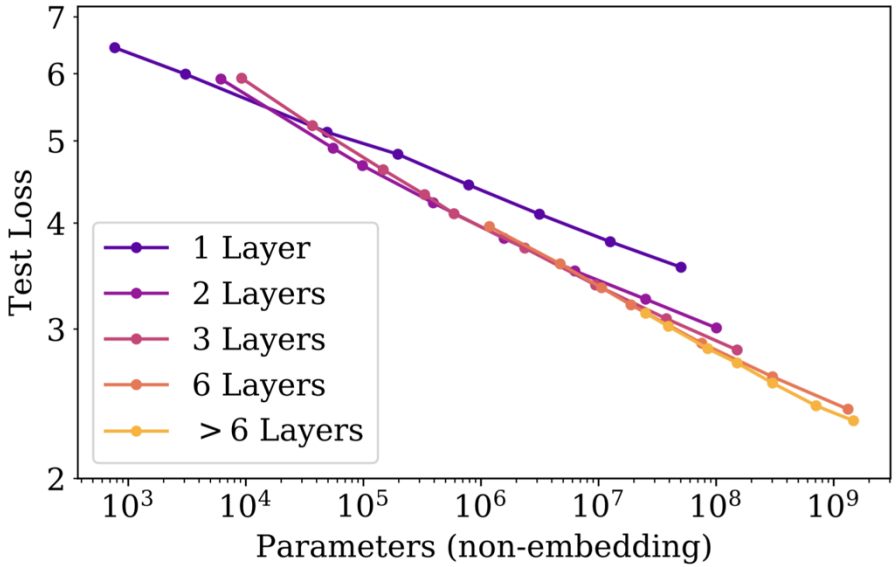
编者补充：若某优化器将相同数据量下的可下降误差乘0.95，而α=0.1，那么旧优化器要达到相同误差需要约(1/0.95)^10=1.67倍数据。这是对拟合曲线的代数解释，不包含额外内存和运算开销。Adam维护矩估计，SGD的状态更少；如果瓶颈是显存或通信，墙钟成本排序可能改变。

公平比较要对各优化器调节学习率、warmup、批大小与衰减，而不是拿某一优化器的好超参数直接给另一个。观察到的差距可能来自算法，也可能来自调参不充分。缩放规律用于发现稳定趋势，同时也用于检查异常运行。

本节参考（完整书目见讲义末尾）：[slides] · [hestness]

3. Depth/Width: Number of layers

Does depth or width make a huge difference?



- 1 vs 2 layers makes a huge difference.
- More layers have diminishing returns below 10^7 params

3. Depth/Width: and other Transformer hypers

Do hyperparameters like the aspect ratio depend on scale?

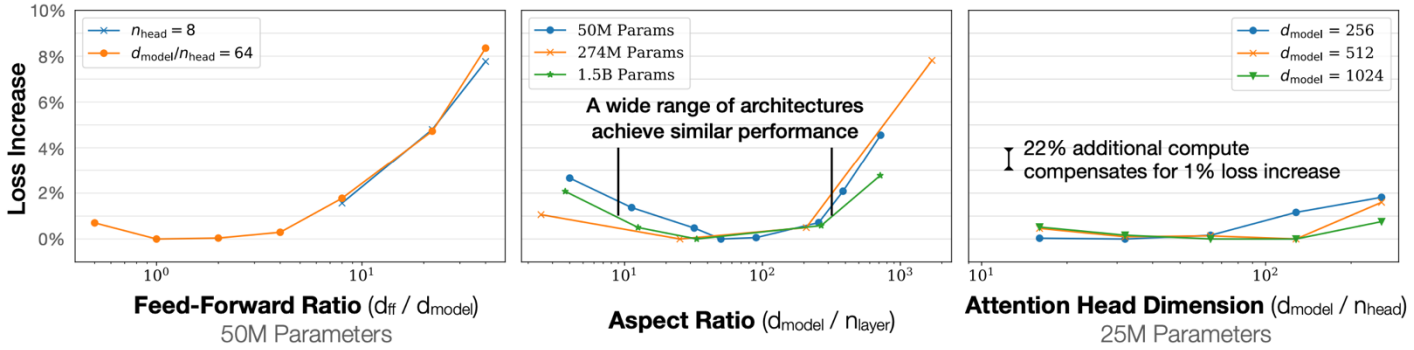


Figure 5 Performance depends very mildly on model shape when the total number of non-embedding parameters N is held fixed. The loss varies only a few percent over a wide range of shapes. Small differences in parameter counts are compensated for by using the fit to $L(N)$ as a baseline. Aspect ratio in particular can vary by a factor of 40 while only slightly impacting performance; an $(n_{\text{layer}}, d_{\text{model}}) = (6, 4288)$ reaches a loss within 3% of the $(48, 1600)$ model used in [RWC+19].

第 9 讲 · 原页 33–34 · 中文讲解

深度、宽度和头维度：固定参数预算下的形状

为什么深一点通常意味着窄一点

令层数为ℓ、隐藏宽度为d，标准Transformer中每层注意力投影约$4d^2$参数，前馈层若中间宽度4d则约$8d^2$，因此粗略$N_{nonemb} \approx 12\ell d^2$，忽略偏置、归一化与架构变体。这不是精确清单，但可以解释权衡：固定N时，层数翻倍，宽度约除以$\sqrt{2}$。比如$\ell=12$、$d=768$时约84.9M非嵌入参数；改为24层时保持同预算的宽度约543，实际需按头数与硬件对齐选可用整数。

两页图的具体结论

原页33的一层模型与多层模型差距大；超过少数层以后，在图中较小参数区间新增深度收益递减。原页34比较前馈宽度比d_{ff}/d、宽深比d/ℓ和每头维度d/n_{head}，展示在合理区间内损失常呈较宽的谷底。宽谷底意味着可以在接近性能的配置中选择更适合硬件的一项，而不是存在唯一神奇比例。

“形状影响较小”只针对所测参数范围与可正常训练的配置。一层与几十层的差别、极端窄层、过小头维度，可能跳出这个温和区间。更深网络还增加串行依赖，较宽矩阵可能更高效；同参数量的两个模型不会自动有相同延迟与吞吐。

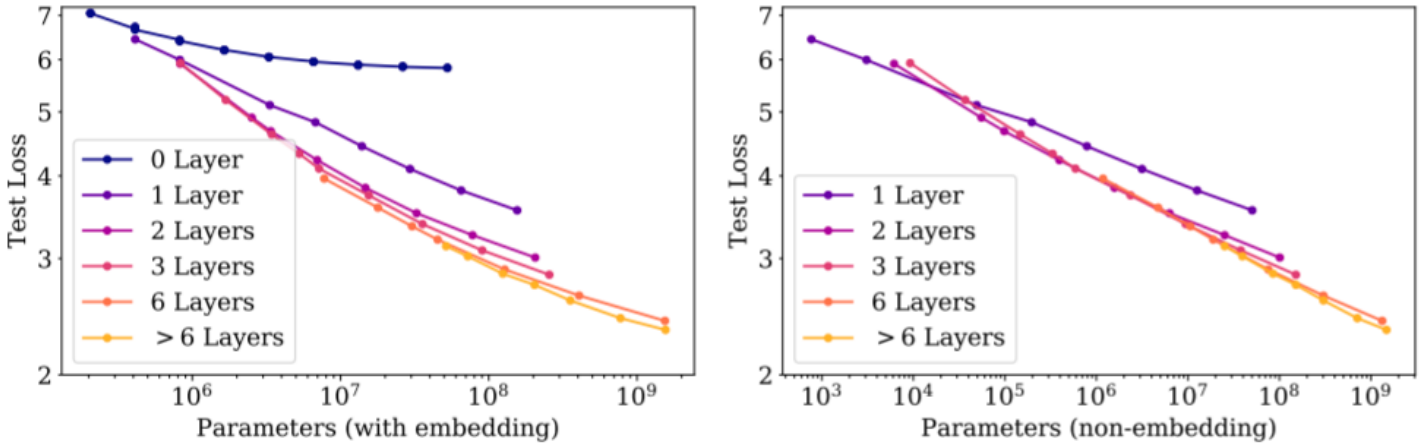
学习顺序提示

先用$N \approx 12\ell d^2$检查候选大致预算，再看原页34横轴上你改变的是哪个比值。不要把attention head数增加误当成总注意力投影参数一定增加：若d固定且只重新划分头，投影矩阵总尺寸可基本不变，变化的是每头维度和计算布局。

本节参考（完整书目见讲义末尾）：[slides] · [kaplan]

3. Depth/Width: But not all parameters are made equal

We've been thinking about 'parameters' but not all parameters are equal

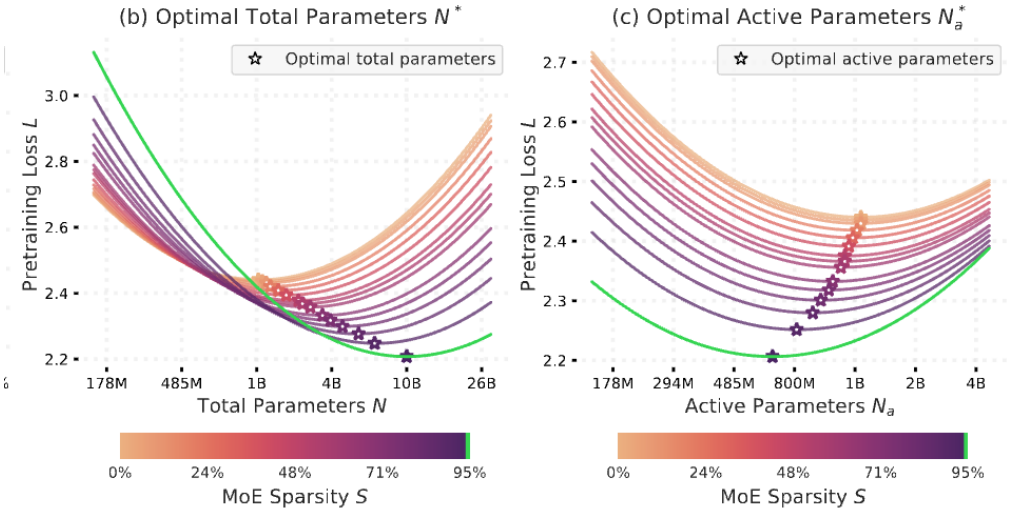


Embedding layer parameters don't behave the same!

Related: recent papers on scaling laws for mixtures of experts.

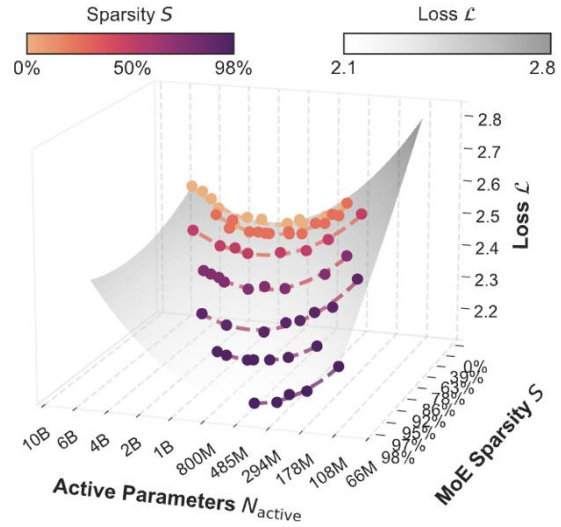
Side note – ‘Value of parameters’

With MoEs, we expect parameter scaling to change



Parameters vs FLOPs: Scaling Laws for Optimal Sparsity for Mixture-of-Experts Language Models

Samira Abnar* Apple
Harshay Shah* MIT
Dan Busbridge Apple
Alaaeldin Mohamed Elnouby Ali Apple
Josh Susskind Apple
Vimal Thilak* Apple



(b) IsoFLOP surface over sparsity and active parameters

第 9 讲 · 原页 35–36 · 中文讲解

参数的价值：嵌入、输出头与稀疏专家

原页35为什么换横轴后更直

输入嵌入表约有Vd个参数，V为词表大小；主体约为12ℓd^2。小模型里Vd占比可能很大，而且随宽度与层数变化的方式不同。把所有参数当成同质资源，会让不同层数曲线看起来扭曲；只看主体参数能改善这张容量关系图的整齐程度，却不表示被排除的参数没有成本或没有作用。

输入token查表只取少数行，输出词表投影却通常要用隐藏状态与整个d×V矩阵乘法。即使输入与输出共享同一权重、存储只算一次，输出计算仍需执行。容量计数、存储计数和FLOPs计数应分别定义。后文Kaplan与Chinchilla分歧中，遗漏输出头计算就是重要问题。

原页36：总参数与激活参数分开

MoE每个token只路由到部分专家。总参数N_total决定模型储存和专家容量，激活参数N_active更接近每token计算的代理；共享注意力和路由等开销仍须计入。图中同一计算预算下，最优总参数与最优激活参数可随稀疏度朝不同方向移动，所以一条稠密模型的L(N)不能不加修改地用于MoE。

编者手算：8个专家各10M参数、共享模块20M，每token使用2个专家，则总参数约100M，激活参数约40M。不能用100M直接估每token专家乘法，也不能只按40M估计存储。未被当前token激活的专家可为其他token服务；这里的容量收益不是“永久闲置的参数也能凭空学习”。

适用边界

Abnar等用固定FLOPs研究稀疏度与规模的联合最优。图所显示的更稀疏趋势仍受其架构与训练范围约束，不能无限推为专家越多越好。真实系统还承担专家通信、负载不均衡与容量溢出等成本，理论FLOPs相同不等于运行时间相同。

本节参考（完整书目见讲义末尾）：[slides] · [kaplan] · [moe] · [resolve]

4. Batch size: Critical batch size

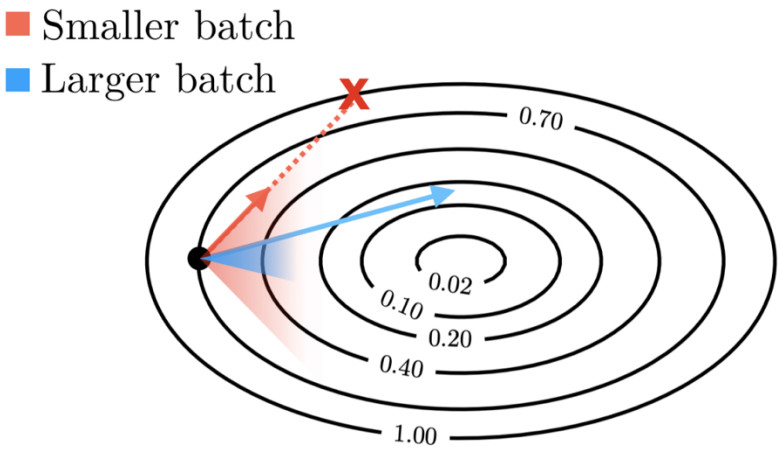
An Empirical Model of Large-Batch Training

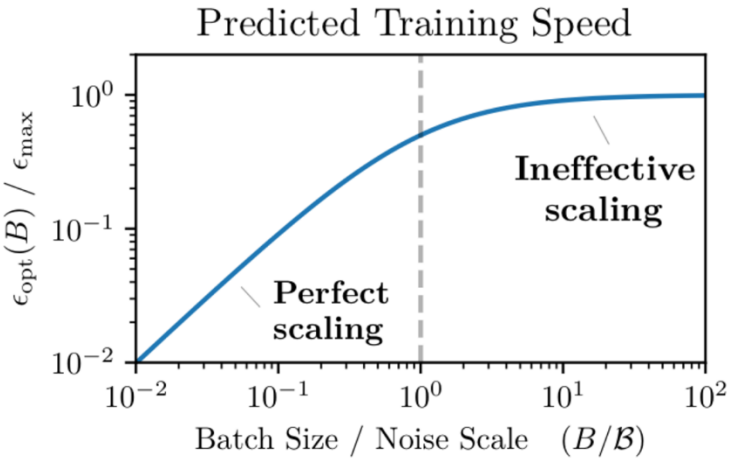
Sam McCandlish* OpenAI sam@openai.com

Jared Kaplan Johns Hopkins University, OpenAI jaredk@jhu.edu

Dario Amodei OpenAI damodei@openai.com

and the **OpenAI Dota Team**†





Batch size – known to have strong diminishing returns past a certain point.

Critical batch = min number of examples before diminishing returns (what does that mean?)

4. Critical batch size definitions..

What is critical batch size, more precisely?

- Pick a target loss and train 1). Steps needed (S), 2). Examples needed.
- Sweep over batches

The curve should follow roughly..

$$\frac{S}{S_{\min}} - 1 = \left(\frac{E}{E_{\min}} - 1\right)^{-1}$$

Fit for S_{min}, E_{min} on this curve and pick

$$\mathcal{B}_{\text{crit}} = \frac{E_{\min}}{S_{\min}}.$$

This balances both sides of the equation, giving roughly 2x the steps / passes optimal

(this is claimed to be close to the ratio of the trace of the gradient covariance and squared norm of the gradient)

第 9 讲 · 原页 37–38 · 中文讲解

临界批大小：步数与样本开销的平衡点

为什么大batch不能无限加速

设每个样本梯度为g_i，平均梯度$G=E[g_i]$，协方差$\Sigma=Cov(g_i)$。独立采样B个样本后，平均梯度的协方差为Σ/B。小batch时噪声大，增加B会明显改善方向；大batch时平均方向已较稳定，再降噪也不能消除目标曲率与多步优化的需要。原页37右图的“perfect scaling”与“ineffective scaling”描述的是收益逐渐饱和，不是某个B处突然失效。左图的几何局限不应误解为SGD梯度必然是统计上有偏的估计。

原页38公式逐步化简

先固定模型、训练流程与目标损失，再对多个批大小运行，并记录达到目标所需步数S和累计处理样本E。若B恒定，则$E=BS$。经验关系为$(S/S_{min}-1)(E/E_{min}-1)=1$，其中$S_{min}$与$E_{min}$分别是该拟合模型中的步数、样本量极限。

展开乘积：$SE/(S_{min}\,E_{min})-S/S_{min}-E/E_{min}=0$。两边乘$S_{min}\,E_{min}$后，得$SE-SE_{min}-ES_{min}=0$。代入$E=BS$并除以正数S：$BS-E_{min}-BS_{min}=0$。于是$S=S_{min}+E_{min}/B$，$E=E_{min}+B\,S_{min}$。小B使S大而E接近$E_{min}$；大B使S接近$S_{min}$而E变大。两个最低值不能在同一个有限B同时取得。

平衡点与数字例子

令$B_{crit}=E_{min}/S_{min}$，则$S=2S_{min}$、$E=2E_{min}$。这个点同时离两种各自最优值只有约2倍，是一个折中，不是所有硬件下唯一最省钱的B。编者例子：S_{min}=1000步、E_{min}=1,000,000样本，则B_{crit}=1000样本/步。B=100时S=11000、E=1.1M；B=1000时S=2000、E=2M；B=10000时S=1100、E=11M。

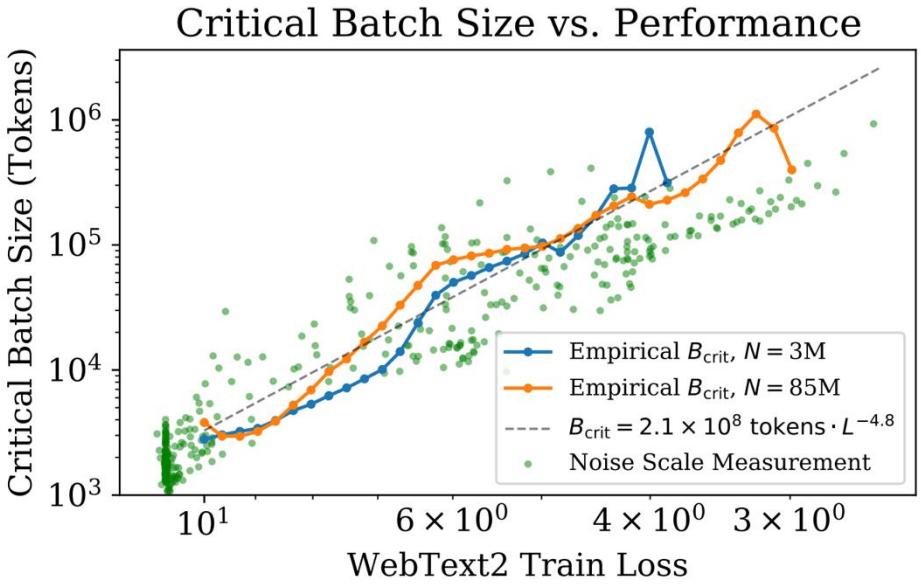
E是累计暴露次数，不是唯一数据集大小，也不是epoch数。若以token计batch，E也必须用token计。实际墙钟时间还要乘每步耗时$T_{step}(B)$，后者受并行度、显存与通信影响。

噪声尺度的近似关系

论文研究的简化噪声尺度$B_{simple}=tr(\Sigma)/\|G\|^2$比较梯度噪声能量和信号大小；它可以辅助预测有用batch规模，但不能写成B_{crit}与该比值普遍严格相等。更细的局部分析含Hessian曲率权重，而且梯度统计随训练变化。课堂00:44:32–00:46:37的主要可操作步骤是扫batch并拟合S、E曲线。

本节参考（完整书目见讲义末尾）：[slides] · [batch] · [kaplan] · [captions]

4. Batch size: critical batch size



The smaller the loss target,
The bigger the batch

$$C_{\min}(C) \equiv \frac{C}{1 + B/B_{\text{crit}}(L)} \qquad \text{(minimum compute, at } B \ll B_{\text{crit}}\text{)}$$

第 9 讲 · 原页 39–39 · 中文讲解

临界批大小也随目标损失缩放

读清横轴方向

原图横轴损失从左到右减小，纵轴临界batch增加；这意味着更低的目标损失对应更大的可用batch，而不是损失越高batch越大。直觉是接近较好的解时，平均梯度信号可能变小，噪声与信号比增大，更精确的平均梯度更有价值。这是经验趋势，具体斜率、常数与训练配方和指标单位有关。

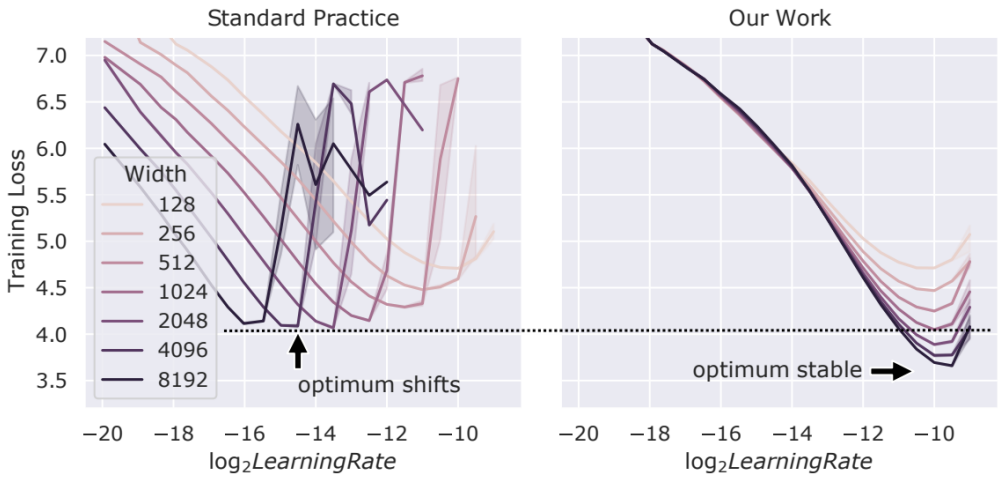
计算效率修正与条件

从上一节E=E_min(1+B/B_crit)出发，在每个样本计算成本近似相同、同目标损失下，C=C_min(1+B/B_crit)，因此C_min=C/[1+B/B_crit(L)]。原页底部公式就是将过大batch带来的计算额外开销折回理想的小batch计算量。它不表示只需代入一次就能确定整个训练过程的最优调度。

编者手算：B=0.1B_crit时，计算开销约为理想值1.1倍；B=B_crit时为2倍；B=10B_crit时为11倍。较大batch即使浪费样本，也可能因并行硬件而缩短时间。应同时记录达标计算、墙钟时间与内存，不能把最少优化步数当成最少计算。

本节参考（完整书目见讲义末尾）：[slides] · [kaplan] · [batch]

5. Learning rates: muP and scale-aware LR choices



Yang et al 2022

Table 2. μP function for a model M' that is r times the widths of M. If a parameter tensor has 2 dimensions that goes infinite when the model width goes infinite, it is "matrix-like" (*e.g.,* a fully-connected hidden layer); if the number is 1 or 0, it belongs to the "others" class. Note that embedding layers are "others". "Output" means the layer that maps an infinite dimension to a finite dimension, which is the word decoding layer (lm_head) in Transformers. A multiplier is a constant multiplied by a parameter tensor, which has a similar function to softmax temperature.

Hyperparameter (weight)	M	$M' \sim r$
AdamW learning rate (matrix-like)	l	l/r
AdamW learning rate (others)	l	l
Initialization variance (matrix-like)	σ	σ/r
Initialization variance (others)	σ	σ
Multiplier (output)	τ	τ/r
Multiplier (others)	τ	τ

Yao et al 2024

If we naively scale up – optimal learning rate depends on scale.
We need *scaling aware* initialization and learning rate scaling

第 9 讲 · 原页 40–40 · 中文讲解

学习率迁移：预测最优点移动，或改变参数化

为什么同一个学习率在宽模型上可能不同

宽度变大后，某层聚合的项数、激活尺度、梯度尺度与优化器更新会改变。如果初始化和更新规则没有保持合适的尺度，原本稳定的步长可能产生过大的函数变化，或者让某些层几乎不学习。原图左边显示标准设置下损失谷底随宽度移动；右边展示经过μP参数化后，不同宽度的基准学习率谷底更接近。这里关注的是宽度迁移，不是对深度、token量、batch所有变化的同时保证。

两种方法分别在做什么

第一种方法是实测小模型的最优学习率如何随宽度变化，再拟合迁移规则。第二种是μP：协同规定初始化、不同参数类的学习率与输出缩放，使随宽度增长的更新尺度有合适的极限，再在小模型调基准超参数。所谓“学习率可迁移”通常指这个基准值，不是说所有张量实际使用同一个常数步长。

原页右表用宽度放大因子r区分matrix-like、other与output等类别。表中的初始化方差与标准差也不能混淆：方差除以r，相应标准差除以√r。编者手算：r=4时，若某矩阵按表学习率除r，基准1e−3对应2.5e−4；若其初始化方差也除r，则标准差减半。只对所有层统一除4，并不能复现整套μP。

课堂补充 · **00:48:25–00:50:50**

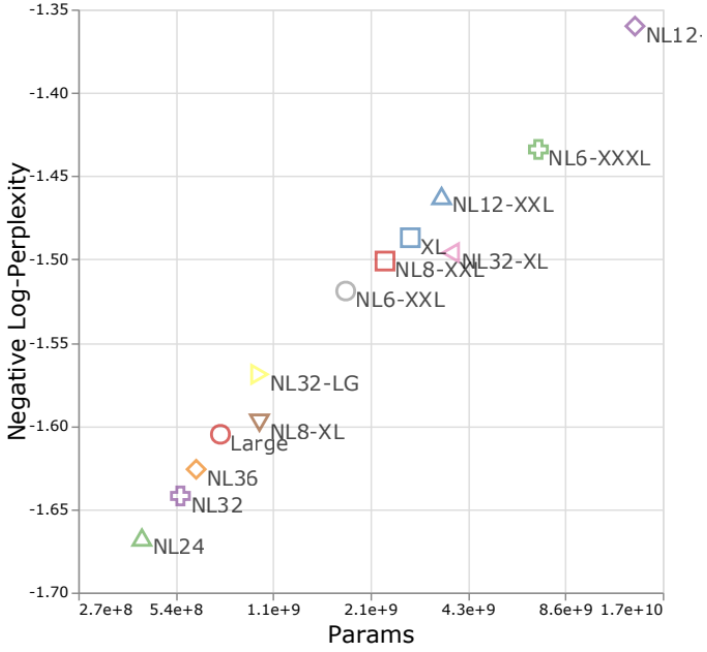
课堂将预测谷底移动与重参数化稳定谷底视为两条可行路线。实做时还需核对优化器、参数类、输出层处理与宽度定义。不能仅凭小模型最优学习率照搬成功，就声称对所有更大规模和更长训练均已验证；至少应使用中间尺度检验。

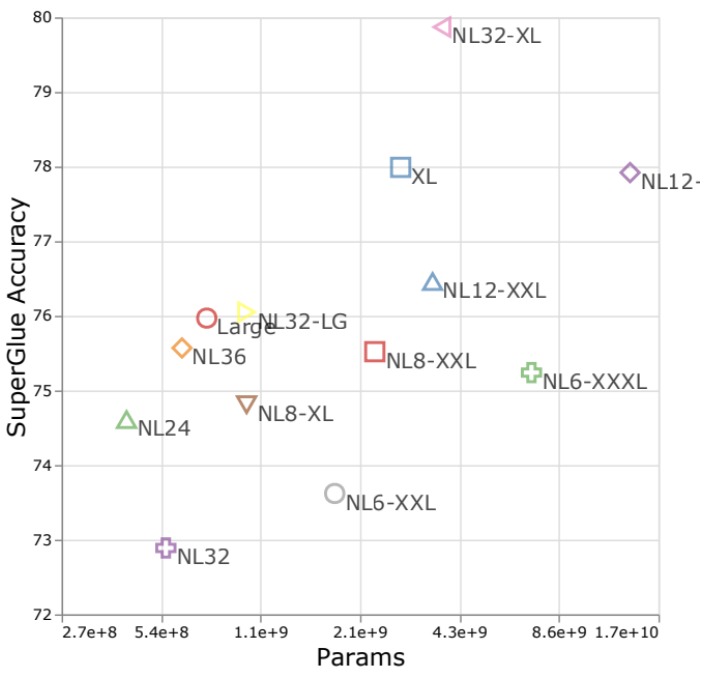
本节参考（完整书目见讲义末尾）：[slides] · [mup] · [captions]

Caution – scaling behaviors can differ downstream

Thus far: scaling is predictable and depends mainly on parameters

Catch: downstream scaling can often be much less predictable





Tay et al 2023

Some surprising takeaways

The effect of hyperparameters on big LMs can be predicted *before* training!

- Optimizer choice
- Model depth
- Architecture choice

The scaling law based design procedure.

1. Train a few smaller models
2. Establish a scaling law (e.g. ADAM vs SGD scaling law)
3. Select optimal hyperparam based on the scaling law prediction.

第 9 讲 · 原页 41–42 · 中文讲解

预训练损失与下游能力：预测目标不能偷换

原页41为什么两幅图排名不同

左图参数量与负log困惑度关系较整齐，右图相同模型在SuperGLUE上的准确率排名却明显变化。预训练平均交叉熵衡量的是某个token分布的拟合；下游任务可能要求特定知识、推理、格式或经微调后才体现的能力。平均指标的改善也可能主要来自频繁、容易的token。因此两者常相关，但没有逻辑上的一一对应。

编者概率例子

假设任务只在正确答案概率超过0.5时记为答对。将正确答案概率从0.40提高到0.49，负log概率从约0.916降到0.713，但准确率仍为0；再从0.49提高到0.51，只改善约0.040的负log概率，准确率却跳到1。真实任务不一定恰是二分类阈值，但这个例子说明连续损失与离散指标可以有不同的曲线形状。它不证明所有能力跃迁都是测量假象。

让原页42的流程可验收

按小模型训练、拟合、预测大模型三步执行时，应提前写清最终要优化的指标。若使用预训练loss做代理，还需额外验证它与目标任务的关系。对不同规模保留相同评估协议，并检查残差、误差范围和留出规模；当架构、配方的差异小于测量噪声时，应重复关键实验。

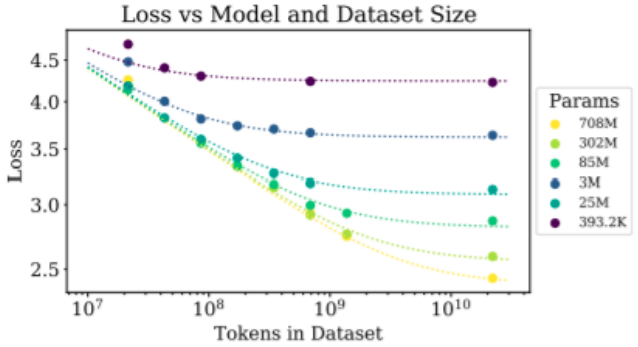
课堂00:53:43–00:56:35讨论loss测量往往较稳定，以及单遍训练时训练与验证损失可能接近。这是经验说明，不是允许取消验证集的理由；重复数据、分布偏移、数据泄漏和小样本任务都会破坏这种接近。

本节参考（完整书目见讲义末尾）：[slides] · [transfer] · [captions]

One important use of scaling laws

Q: Do we need more data or bigger models?

Clearly, lots of data is wasted on small models



Joint data-model scaling laws describe how the two relate

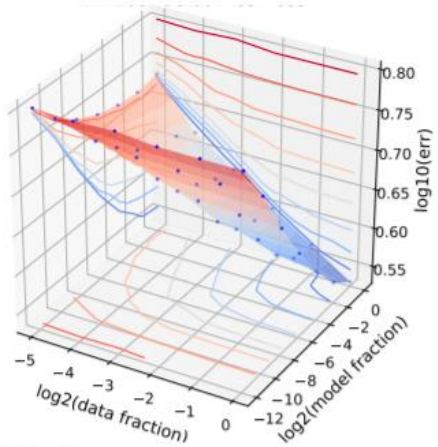
From Rosenfeld+ 2020,

$$Error = n^{-\alpha} + m^{-\beta} + C$$

From Kaplan+ 2020

$$Error = [m^{-\alpha} + n^{-1}]^{\beta}$$

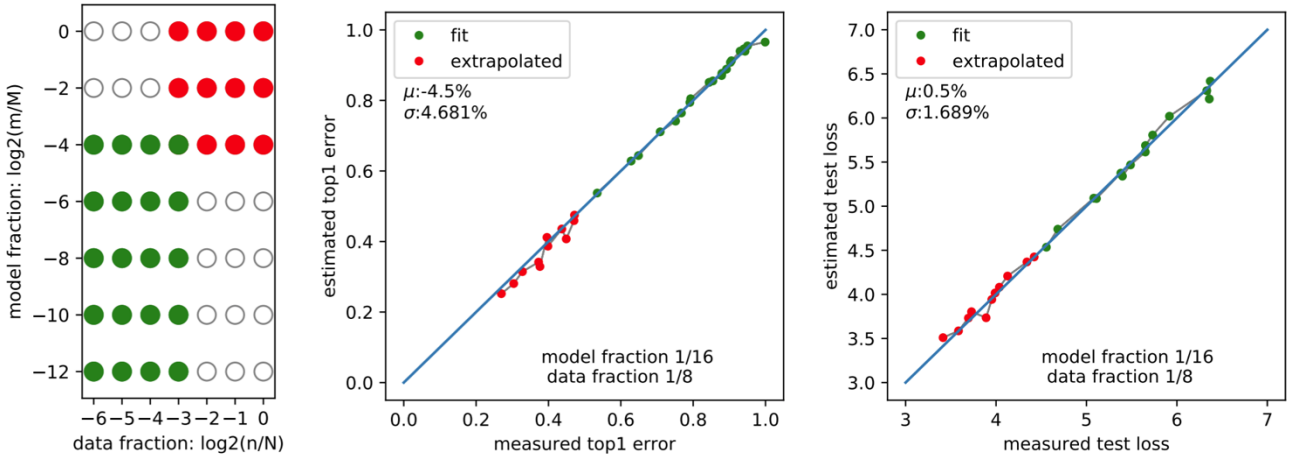
Provides surprisingly good fits to model-data joint error.



(a) Wiki103 error (cross entropy) landscape.

Model-data joint scaling is accurate

From Rosenfeld – fit scaling exponents on small data, small models. Predict rest.



(a) Illustration. (b) Extrapolation on ImageNet (c) Extrapolation on WikiText-103.

Trading off data size and model size: optimize $n^{-\alpha}+m^{-\beta}+C$ with your costs.

第 9 讲 · 原页 43–44 · 中文讲解

联合缩放：固定计算预算下推导最优模型和数据

先理解曲面的两个极限

原页43的每条数据曲线来自固定模型大小：小模型很快进入平台，更大模型可以继续从数据获益。课件用简化的联合公式说明容量与数据限制可以同时表达。为避免原稿n、m及常数C混用，这里统一使用L(N,D)=L∞+A N^(-α)+B D^(-β)，A,B,α,β>0。固定N让D趋于无穷，只剩容量项；固定D让N趋于无穷，只剩数据项。原页Kaplan形式是另一种参数化，不应把两个拟合式的同名字母直接视为同一个指数。其带尺度常数的形式可写L(N,D)=[(N_c/N)^(α_N/α_D)+D_c/D]^α_D，其中N_c、D_c为拟合尺度。D趋于无穷时，外层指数与内层相乘，得到(N_c/N)^α_N；N趋于无穷时得到(D_c/D)^α_D。括号外的指数不能忽略，也不能把这两个α与本节加法模型的指数机械互换。

编者推导：从6ND约束到最优指数

对稠密Transformer，用训练计算近似C≈6ND：前向每参数每token约2 FLOPs，反向通常约前向两倍，总计约6。它省略了长上下文注意力、部分嵌入/输出及其他细节，不适合作为所有架构的精确成本。固定C，则D=C/(6N)，代入可得L−L∞=A N^(-α)+B(6N/C)^β。

对N求导：dL/dN=−αA N^(-α−1)+βB(6/C)^β N^(β−1)。令其为0并乘N，得到αA N^(-α)=βB D^(-β)。最优点平衡的是带指数权重的边际收益，两个损失项只有α=β时才相等。

移项得N^(α+β)=[αA/(βB)](C/6)^β。因此N_opt=[αA/(βB)]^(1/(α+β))(C/6)^(β/(α+β))，D_opt与C^(α/(α+β))成比例。两个计算分配指数之和为1。不能把损失的α、β直接当成N、D对C的指数。

原页44：预测图与验证

左图绿色点表示用于拟合的较小模型/数据组合，红色代表外推目标；右图将预测值对实测值画散点，理想情况落在对角线附近。重要的是没有用目标点反复调整公式。检验时应看远离训练区域是否出现系统偏差，而不只是整体相关系数高。

编者手算：若α=β、A=B且使用一致归一化单位，则N_opt和D_opt都按√C增长。计算乘4时二者各乘2；这并不意味着真实参数数和token数相等，单位归一化与A/B决定比例。数据有限、重复较多、模型离散或成本包含推理时，上面的优化约束需要重写。

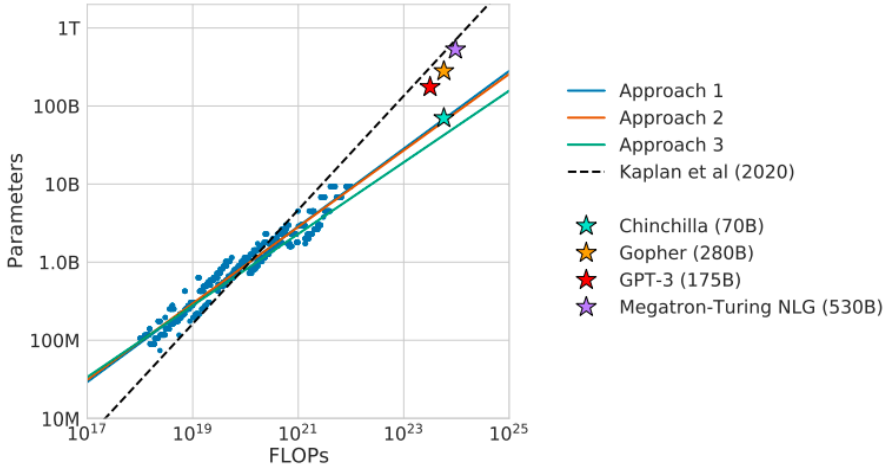
本节参考（完整书目见讲义末尾）：[slides] · [rosenfeld] · [kaplan] · [chinchilla]

‘Optimal’ compute and data tradeoffs as a case study.

Rosenfeld, Kaplan both predict relationship of data, model and perf.

Kaplan claims: $N_{opt} = C^{0.73}, D_{opt} = C^{0.27}$ (tokens per param decreases w/ C)

Chinchilla [Hoffman et al] argue these fits are quite off.



Hoffman+ 2022

Chinchilla in depth – 3 methods

Approach	Coeff. a where $N_{opt} \propto C^a$	Coeff. b where $D_{opt} \propto C^b$
1. Minimum over training curves	0.50 (0.488, 0.502)	0.50 (0.501, 0.512)
2. IsoFLOP profiles	0.49 (0.462, 0.534)	0.51 (0.483, 0.529)
3. Parametric modelling of the loss	0.46 (0.454, 0.455)	0.54 (0.542, 0.543)
Kaplan et al. (2020)	0.73	0.27

The chinchilla authors suggest 3 ways of fitting scaling laws – we'll go over each.

They mostly (minus method 3) suggest similar constants. More on this later..

第 9 讲 · 原页 45–46 · 中文讲解

Kaplan与Chinchilla：相近拟合问题为何建议不同

先把N和D认准

N是参数数，D是累计训练token，C是计算预算。Kaplan的经典建议近似N_opt∝C^0.73、D_opt∝C^0.27；Chinchilla方法1与2给出更接近均分的指数。原稿省略的比例常数并非不存在，不能把“ ∝ ”随意当成在任意单位下都成立的等号。

编者手算：预算扩大10倍，Kaplan式给N约5.37倍、D约1.86倍，因此D/N变为约0.347倍；均分式给N和D各约3.16倍，D/N近似不变。这个差别随规模累积，所以不是只改一点小超参数。

三种方法是交叉检查

原页46表中方法1约(0.50,0.50)，方法2约(0.49,0.51)，方法3约(0.46,0.54)，分别是N、D对C的指数。前两种较一致，第三种有偏差；后文会看到复核。它们不是损失曲线的指数，也不是“50%的GPU跑参数、50%的GPU跑数据”：一次训练中N和D共同相乘消耗计算。

Chinchilla论文的重要结果是，在所研究配方与预算下，用比Gopher更小、但训练更多token的模型取得更好表现；约20 token/参数是该经验区域的常用概括。一个模型的最优比例还取决于数据、训练配方、计数口径与目标，不是普适常数。先学习三种方法怎样产生建议，比背下比例更有用。

本节参考（完整书目见讲义末尾）：[slides] · [kaplan] · [chinchilla]

Method 1 – minimum over runs.

Similar to the FLOPS figure on Kaplan –
the minimum over the union of all training curves is a power law.

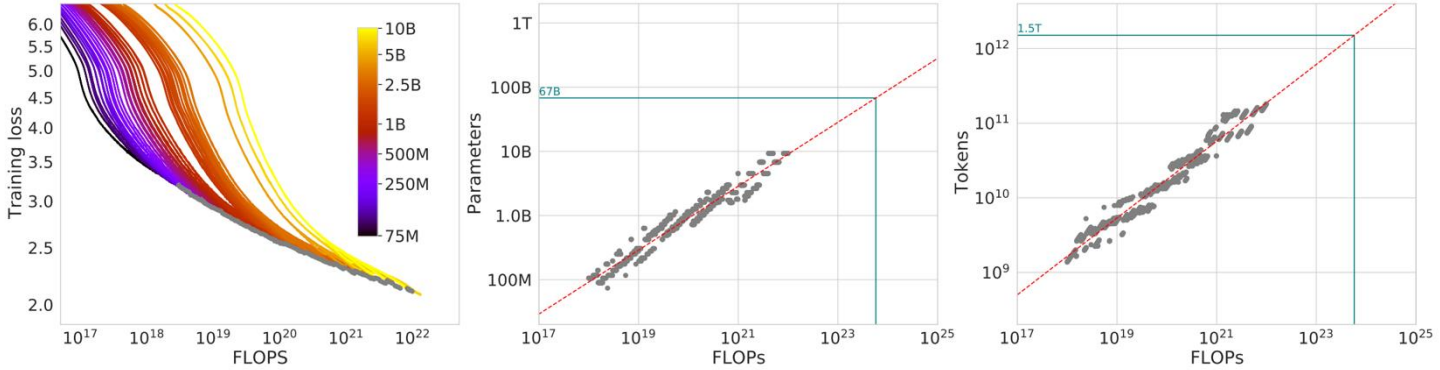


Figure 2 | **Training curve envelope.** On the **left** we show all of our different runs. We launched a range of model sizes going from 70M to 10B, each for four different cosine cycle lengths. From these curves, we extracted the envelope of minimal loss per FLOP, and we used these points to estimate the optimal model size (**center**) for a given compute budget and the optimal number of training tokens (**right**). In green, we show projections of optimal model size and training token count based on the number of FLOPs used to train *Gopher* (5.76×10^{23}).

第 9 讲 · 原页 47–47 · 中文讲解

方法一：训练曲线的下包络

每一步究竟记录什么

对一系列参数规模N和训练终点运行，记录检查点的累计计算C与损失L。对某个C，比较所有可用训练曲线在该计算处的损失，取最小值，形成经验下包络。再记录贡献这个包络点的模型大小N，以及该点已经处理的token D；对多个C拟合log N_opt和log D_opt随log C的关系。原图左边显示训练轨迹，中间与右边显示从包络提取的最优资源分配。

编者小表例子与陷阱

假设C=1时三个候选模型A/B/C的损失为3.0/3.2/3.5，C=4时为2.8/2.6/2.7，则包络先选A后选B；C模型不能因为最大就自动入选。若不同实验只在不同C记录检查点，需要有原则地插值，不能将一个预算较大的检查点当成低预算结果。

包络受候选覆盖影响：没试到真正合适的模型，只能得到已试集合的最优。学习率衰减也依赖计划终点，长训练中途的检查点不一定等于专门在此预算结束的最佳模型。原论文为多个规模和训练长度设计运行，这一点帮助减少但不会自动消除训练调度的影响。噪声下取最小值也有乐观偏差，最好复核关键包络点。

课堂补充 · **01:03:17–01:04:28**

课堂将此法称为lower envelope，强调每个包络点对应一个实际模型及已耗计算，同时提醒包络定义和提取存在技术细节。此处的“下”只是图上较低损失的位置，不是所有算法不可突破的理论下界。

本节参考（完整书目见讲义末尾）：[slides] · [chinchilla] · [captions]

Method 2 - IsoFLOPS

Pick a range of FLOP budgets, vary the total parameter count, take the min over these convex shapes. The minima form a power law.

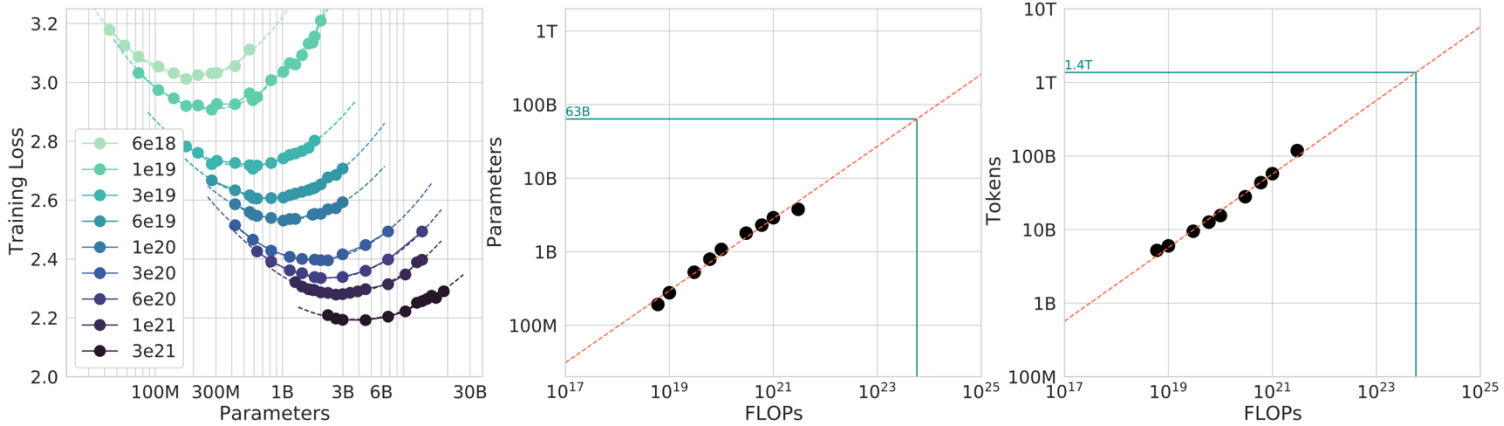


Figure 3 | **IsoFLOP curves.** For various model sizes, we choose the number of training tokens such that the final FLOPs is a constant. The cosine cycle length is set to match the target FLOP count. We find a clear valley in loss, meaning that for a given FLOP budget there is an optimal model to train (**left**). Using the location of these valleys, we project optimal model size and number of tokens for larger models (**center** and **right**). In green, we show the estimated number of parameters and tokens for an *optimal* model trained with the compute budget of *Gopher*.

第 9 讲 · 原页 48–48 · 中文讲解

方法二：IsoFLOPs如何做成一张U形曲线

固定预算后只剩一个主要自由度

选计算预算C_0，枚举模型大小N；按近似$D=C_0/(6N)$确定训练token，各模型都在自己的终点测损失。小N训练得久但容量不足，大N容量充足却看数据太少或优化不足，中间通常较优。原图左边每条同色曲线属于同一预算；谷底给该预算的最佳N。对多档预算重复，再将谷底位置对C作双对数拟合。

编者手算：预算约束是乘积

设$C_0=6\times10^{18}$ FLOPs，N=100M、200M、400M时，对应D=10B、5B、2.5B token。三种配置都满足$6ND=C_0$。它们的loss必须实测，不能只靠参数多或token多决定输赢。每个运行的warmup和衰减要匹配自身的总步数/token预算，同时记录真实FLOPs与近似式的差距。

谷底附近可用横坐标x=log N拟合二次函数$L\approx a(x-x^*)^2+b$，从x^*得到N^*；这只是局部近似。原稿说“convex shapes”描述经验U形，不能据此断言整条真实损失曲线在N坐标上全局凸。如果扫描范围里最低点落在端点，就需要扩大搜索范围，不能把端点直接宣布为内部最优。

课堂补充 · 01:04:28–01:05:44

课堂倾向把IsoFLOPs作为直观而稳健的默认研究工具，因为它显式固定最关心的预算。稳健依然依赖公平调参、足够覆盖谷底以及稳定评估；拟合抛物线并不会自动消除这些要求。

本节参考（完整书目见讲义末尾）：[slides] · [chinchilla] · [captions]

Method 3 – Joint fits

Run a bunch of models on the size-data grid. Use least squares to fit a joint scaling law

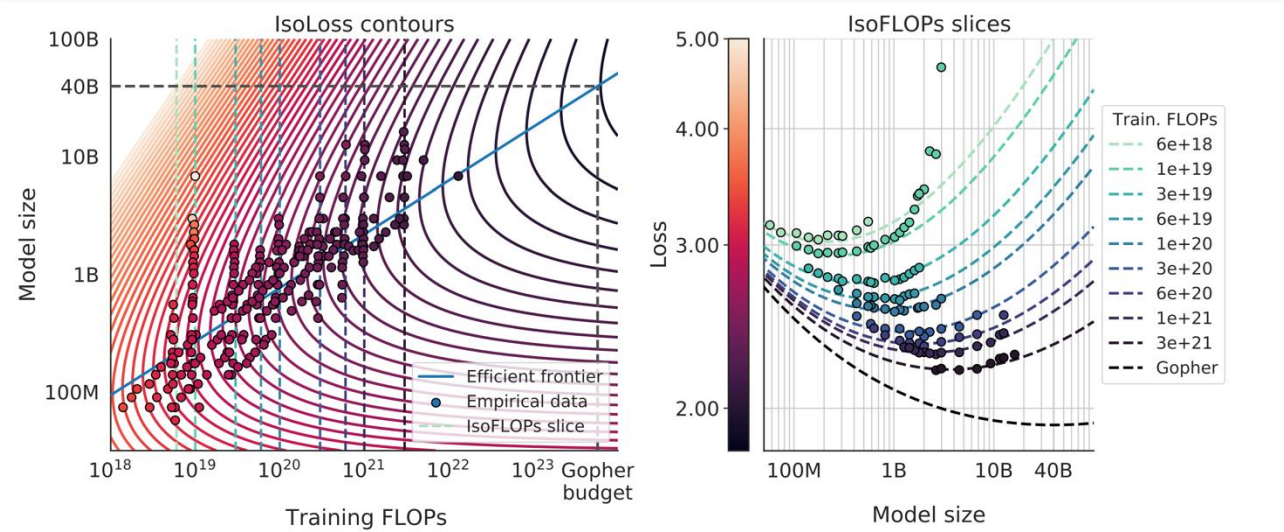


Figure 4 | **Parametric fit.** We fit a parametric modelling of the loss $\hat{L}(N, D)$ and display contour (**left**) and isoFLOP slices (**right**). For each isoFLOP slice, we include a corresponding dashed line in the left plot. In the left plot, we show the efficient frontier in blue, which is a line in log-log space. Specifically, the curve goes through each iso-loss contour at the point with the fewest FLOPs. We project the optimal model size given the *Gopher* FLOP budget to be 40B parameters.

第 9 讲 · 原页 49–49 · 中文讲解

方法三：拟合完整损失曲面

曲面拟合比画一条线多了什么

收集多个(N,D,L)终点，以L̂(N,D)=L∞+A/N^α+B/D^β同时拟合平台、两个幅度与两个指数。原图左边是等损失线与计算约束，最优前沿对应以最少计算触及某一损失的位置；右边是把曲面沿固定FLOPs切开后，与实际IsoFLOPs点比较。一个公式可以同时回答多个预算问题，但它对模型形式正确性的依赖也更强。

原稿“least squares”的精确说明

原页把方法概括成最小二乘。Chinchilla论文第3.3节实际对log L̂与log L的残差使用Huber损失，用L-BFGS并从多个初值优化。小残差时Huber近似平方，大残差时近似线性，以减轻离群点影响；这不等同于原始loss上直接做普通最小二乘。公式可写$r_i=\log \hat{L}_i-\log L_i$，目标$\Sigma_i$ Huberδ(r_i)，其中δ是残差转折阈值。

对数残差约衡量相对误差：L̂=L(1+ε)且ε很小时，r=log(1+ε)≈ε。直接拟合L的绝对残差则会有不同权重。报告“拟合了幂律”时必须说明目标函数、初值、约束、训练点筛选及优化是否收敛。

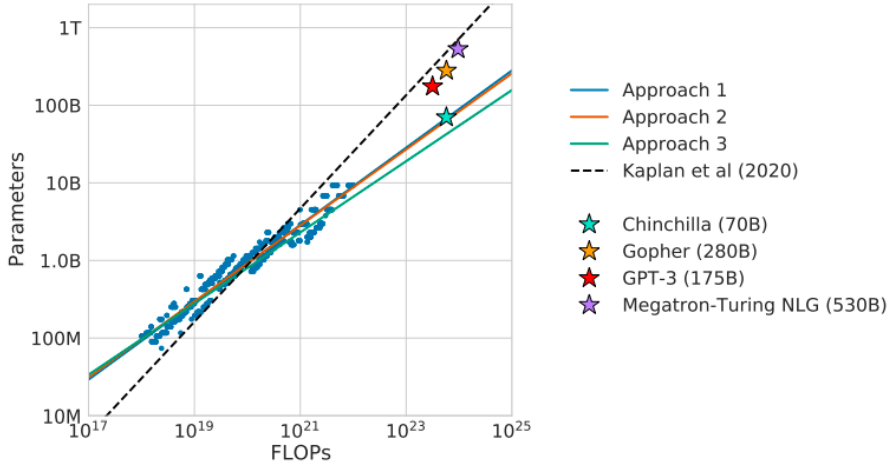
编者补充：为什么一组漂亮参数仍需怀疑

若观测范围很窄，较大的平台L∞可以被更大幅度A、B及不同指数部分补偿，多个参数组合可能拟合同样好，却对大规模给出不同预测。可用留出规模、重采样或多个合理形式检查最优N的稳定性，并画残差是否随N、D有系统偏差。原页53的复核说明，拟合过程本身也需要验收，而不只是训练运行。

本节参考（完整书目见讲义末尾）：[slides] · [chinchilla] · [replicate]

Why do we have this big difference?

Kaplan claims: $N_{opt} = C^{0.73}, D_{opt} = C^{0.27}$ (tokens per param decreases w/ C)

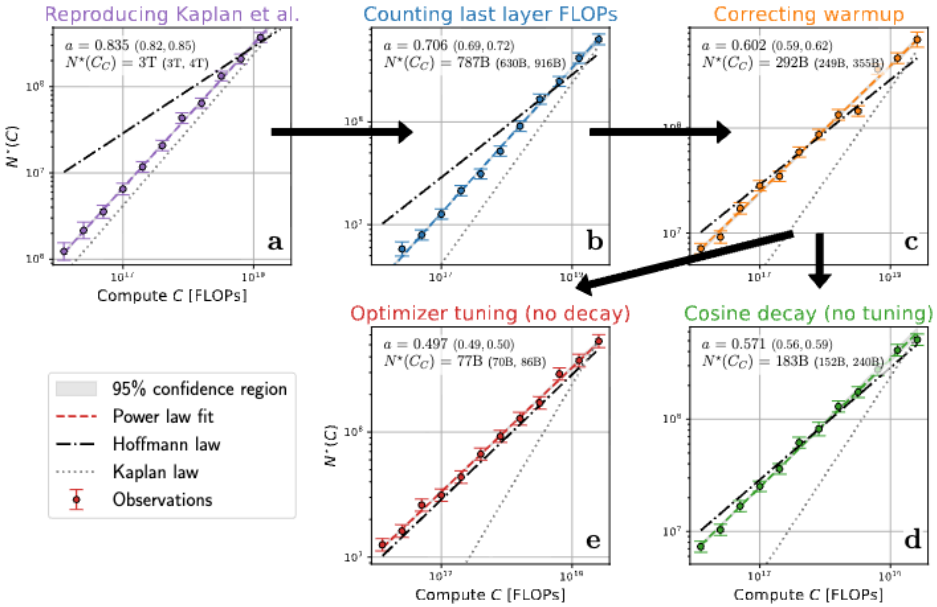


Why such a big difference (when both fit joint scaling laws?)

Explanation 1

Resolving Discrepancies in Compute-Optimal Scaling of Language Models

ll Wortsman† Jenia Jitsev‡ Ludwig Schmidt† Yair Carmon*



- Kaplan removed last layer param from the count
- Warmup at very small compute budgets was too high
- (Decay itself is maybe not critical if batch / LR is properly tuned)

第 9 讲 · 原页 50–51 · 中文讲解

分歧解释一：输出计算与小模型训练配方

原页51箭头表示控制实验

Porian等先复现接近Kaplan的结果，再依次改变输出层计算计数、warmup和优化器设置，观察推导出的计算最优指数如何移动。图的重点是这些看似局部的选择足以影响大尺度外推，而不是“某一个人的公式不够复杂”。各因素相互作用，不能声称只改一个计数就解释了全部差异。

最后一层为何不可忽略

原页用“移除最后一层参数”作简写，更精确的问题包括忽略输出词表投影的计算。词表V=50000、宽度d=512时，输出矩阵有25.6M个权重，前向每token约需2Vd=51.2M FLOPs；训练还要反向。输入embedding查表与输出head虽形状对偶，却不是同样的计算。即使二者共享存储，输出乘法仍必须执行。

小模型主体参数不大时，该成本比例高；大模型主体占比上升时，该比例下降。因此遗漏这部分不只是所有C乘一个常数，而会改变小大模型之间的相对预算，进而影响拟合斜率。复核论文具体区分了输入embedding与输出线性层，不能把它简化成“以后所有场景统一使用总参数便正确”。

warmup和batch怎样污染缩放

若某小预算运行总共1000步，却沿用大实验2000步warmup，整个运行都没到计划峰值学习率；它表现差未必说明小模型容量不足。若小模型总是用远大于自身临界值的batch，同样计算会被更差的样本效率消耗。原研究通过更合适的warmup和优化器/batch设置让结果接近Chinchilla。课堂01:08:42–01:10:21强调了这些细节。

正确经验是让不同规模都处在合理训练区间。它不是说warmup或学习率衰减普遍无用，也不是说所有规模都必须用完全相同的超参数值。

本节参考（完整书目见讲义末尾）：[slides] · [resolve] · [captions]

Explanation 2

Reconciling Kaplan and Chinchilla Scaling Laws

Tim Pearce *Microsoft Research*

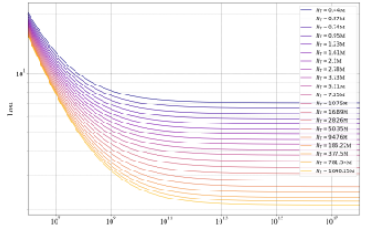
Jinyeop Song *MIT*

Reviewed on OpenReview: *https://openreview.net/forum?id=NLoaLyuUUF*

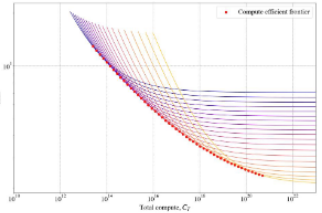
Start from fitted model of **Chinchilla's** training curves

$$\text{Loss}(N_T, D) = \frac{482}{N_T^{0.35}} + \frac{2085}{D^{0.37}} + 1.82$$

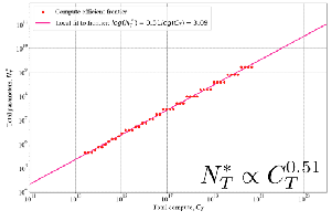
Generate training curves for model sizes used in **Kaplan's** study (1k to 1.5B params)



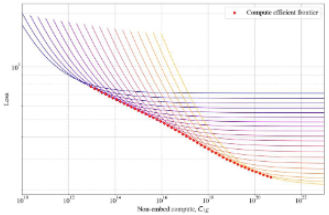
Find compute optimal frontier in terms of **total** parameters N_T and compute as in **Chinchilla**



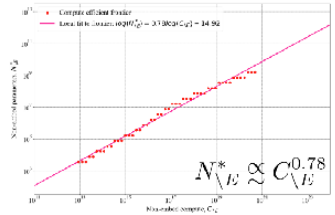
Find power law scaling coefficient of 0.51, close to Chinchilla's 0.50

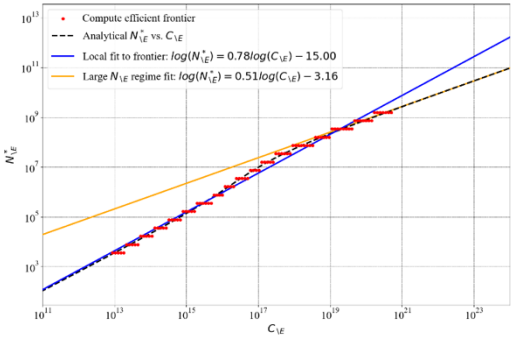


Find compute optimal frontier in **non-embedding** parameters $N_{\setminus E}$ and compute as in **Kaplan**



Find **local** power law scaling coefficient of 0.78, close to Kaplan's 0.73





Non-embedding vs total param choice + small nonlinearities

第 9 讲 · 原页 52–52 · 中文讲解

分歧解释二：参数口径造成局部曲率

无需重新训练的解释路线

Pearce与Song从Chinchilla拟合出的损失曲面生成模拟曲线，再以不同参数与计算口径提取最优关系。他们展示在较小规模上，非嵌入参数与总参数的差异可以带来曲率，使局部幂律拟合斜率不同。这与上一页重新做受控训练的证据路线不同：模拟揭示一个可能机制，不能冒充对原实验所有因素的直接测量。

编者推导：为什么不是固定换单位

若固定宽深比，则ℓ与d成比例，主体N_nonemb约与d^3成比例，所以d约与N_nonemb^(1/3)成比例。固定词表下，嵌入项Vd随N_nonemb^(1/3)增长，因此总参数可写N_total≈N_nonemb+ωN_nonemb^(1/3)，ω由词表和架构常数决定。

若只是N_total=2N_nonemb，双对数图仅改变截距；但这里两个不同幂次相加，在小规模第二项占比较大，斜率会变化。设x=N_nonemb，其局部对数导数为dlog N_total/dlog x=[x+(ω/3)x^(1/3)]/[x+ωx^(1/3)]，可在约1/3到1之间变化。它说明参数口径不同确实可能改变局部斜率，而不仅是标签。

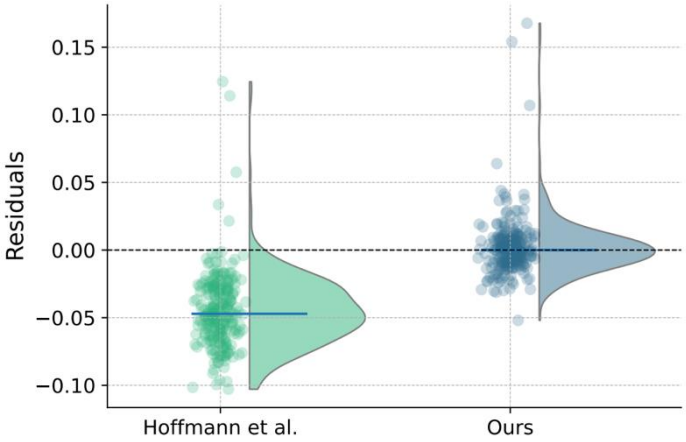
实践检验

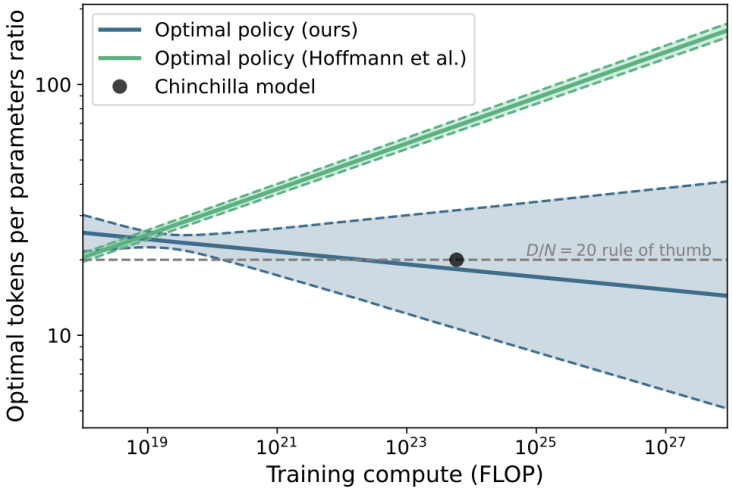
拟合前写清参数计算方法、是否共享embedding/head、计算成本是否含输出层与注意力，然后在完整规模跨度上画残差。若分段斜率不同，应首先考虑曲率和训练区间变化，不能看到两条局部直线就立即宣布存在两条互不相容的自然定律。

本节参考（完整书目见讲义末尾）：[slides] · [reconcile]

Fun addendum – errors in chinchilla method 3

Note that this method three was likely flawed in the original paper. Some authors did data forensics, recovered the raw data, and re-did the fit and got results more consistent with methods 1 and 2





[Besiroglu et al 2024]

第 9 讲 · 原页 53–53 · 中文讲解

Chinchilla复核：曲面优化也会出错

原图的比较对象

左边是原拟合与重新拟合的残差分布；更接近0且偏差更小意味着拟合更贴合重建的观测。右图比较计算增加时最优token/参数比的趋势。方法三原来的指数约0.46、0.54，使D/N随C^0.08增加；若计算乘1000，比例会乘1000^0.08约1.74。指数看似只差几个百分点，远距离外推仍有明显影响。

复核证据的准确边界

Besiroglu等没有拿到全部原始运行数据与代码，而是从论文图形中重建部分实验观测，再进行拟合和检验；重建含点位置、颜色量化等误差。作者发现原拟合参数与重建数据之间存在可改进的拟合偏差，也讨论优化提前停止、数值精度及离群点处理的问题。重新拟合的资源分配更接近前两种方法。

因此可以说“原方法三的拟合结果需要谨慎解释”，不能推为整个Chinchilla研究失效，也不应说复核拿到了全部原始实验。它保留了训练预算应同时分配给模型与数据的主要认识。

课堂补充 · **01:12:20–01:14:25**

课堂借这个案例强调：多个独立估计方法之间的不一致值得调查，即使原论文影响很大。编者建议保留运行记录、拟合输入、代码、初值与收敛诊断，让后人无需从图片反推数据。看起来光滑的等高线也可能来自尚未充分优化的拟合器。

本节参考（完整书目见讲义末尾）：[slides] · [replicate] · [captions]

Important note – train-optimal is likely not what you want

Chinchilla aims to tell you what gives the best model for fixed training compute..

But most of the compute in a real deployment is inference.. So we should ‘over’ train

- **GPT3** – 2 tokens / param
- **Chinchilla** – 20 tokens / param
- **LLaMA65B** – 22 tokens / param
- **Llama 2 70B** – 29 tokens / param
- **Mistral 7B** – 110 tokens / param
- **Llama 3 70B** – 215 tokens / param

… etc etc

The more usage we expect, the more it becomes worth it to pay the upfront cost

第 9 讲 · 原页 54–54 · 中文讲解

训练最优与部署总成本最优是不同目标

“过度训练”不等于过拟合

Chinchilla回答的是固定训练计算下怎样获得较好模型。若模型会被大量调用，小模型每次推理便宜，可能值得用更多训练token让小模型追上较大模型。这里的“overtrain”指相对训练计算最优比例训练更久，不等于验证loss已经开始变坏的统计过拟合。是否值得取决于未来调用量、延迟、显存和质量要求。原页不同模型的token/参数比例是历史配方示意，不是对不同数据质量与训练目标的控制实验。

编者成本模型与回本点

对稠密模型粗略写$C_{total}\approx 6ND+2NT$，其中T是部署生命周期处理的token总量。推理的2NT只考虑主要参数乘法，忽略长上下文attention、KV cache、批处理效率、硬件和prefill/decode差异；它用于说明目标函数为何改变，不是服务账单预测器。

假设两模型经实测达到同等目标质量：方案A为10B参数、训练200B token，训练成本约1.2×10^{22} FLOPs；方案B为5B参数、训练800B token，约2.4×10^{22} FLOPs。B多花1.2×10^{22}训练计算，但每个推理token少用约$2\times5B=10^{10}$ FLOPs，因此约$T=1.2\times10^{12}$个推理token后，理想化总计算成本打平。模型是否能在这些训练量达到同质量是本例假设，不能由6ND推出。

课堂补充 · **01:14:25–01:16:02**

课堂强调实际生产服务会改变训练最优的选择。并非每个项目都由推理成本主导：只做一次科研实验、少量部署或数据已耗尽时，决策不同。应估算需求、明确服务约束，再优化全生命周期成本；20 tokens/parameter只是特定训练目标下的参考。原页中的具体历史比例未全部逐一重审，本文不将其作为通用建议。

本节参考（完整书目见讲义末尾）：[slides] · [chinchilla] · [captions]

Isoflops everywhere

Methods like IsoFLOPS are pretty easy to execute and usually pretty clean

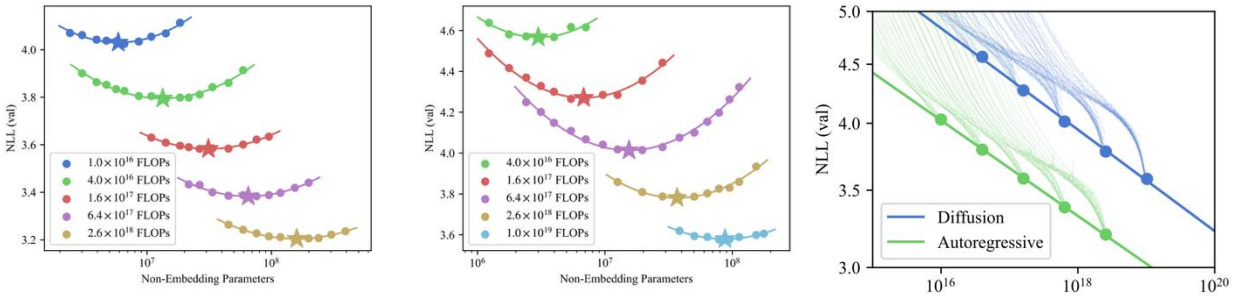
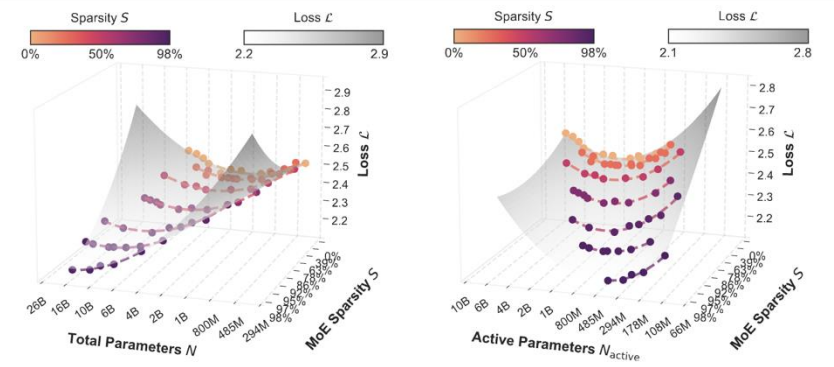


Figure 5: IsoFLOP profiles for autoregressive models (left) and diffusion models (right).

Diffusion - Gulrajani+ 2023.



(a) IsoFLOP surface over sparsity and total parameters (b) IsoFLOP surface over sparsity and active parameters

MoEs – Abnar+ 2025.

第 9 讲 · 原页 55–55 · 中文讲解

IsoFLOPs可以迁移，拟合常数不能照搬

从自回归到扩散与MoE

上排将自回归模型与扩散语言模型分别画成固定预算曲线，再比较其计算—损失前沿。横轴具体计数和纵轴似然评估必须一致才有可比性；不同模型的生成步数、训练目标与推理代价仍可能不同。下排MoE图把稀疏度增加为额外轴：每个预算下需要寻找一个二维面的谷底，而不再只是N方向的一维最低点。

编者补充：迁移的是实验逻辑

IsoFLOPs的通用原则是固定一种明确成本，系统扫描其他自由度。对于扩散可扫描宽度、深度或训练量，对于MoE可同时扫描激活参数与专家数量。但稠密Transformer的6ND近似和原有α、β不会自动对这些模型有效。稀疏通信、专家负载和多步采样会影响真实成本。

如果真正受限的是训练时间而不是理论FLOPs，可以另外画固定GPU小时的前沿；这时需要说明硬件、并行设置与利用率。课堂01:16:02–01:16:47把IsoFLOPs作为研究的好起点，重点在于受控比较，而不是保证所有曲面都会漂亮或全局凸。

本节参考（完整书目见讲义末尾）：[slides] · [diffusion] · [moe] · [captions]

Scaling laws for models and compute

Log-linearity extends to model parameters and compute!

Lets us set the following based on small models

- Pick optimizer
- Pick architecture and model sizes

Also lets us make smart resource tradeoffs

- Big models vs more data?

Recap: scaling laws – surprising and useful!

- **Data scaling**: understand how data affects models, clean theory
- **Model scaling**: dramatically reduce costs for training
- **Scaling as prediction:** understand what problems can be ‘brute forced’

第 9 讲 · 原页 56–57 · 中文讲解

把整讲收束成可执行的缩放研究流程

从问题到一次值得信任的预测

先定义目标：预训练验证loss、下游质量还是服务总成本。再定义资源与口径：唯一数据、累计token、参数、激活参数、训练FLOPs与实际时间。选择一族合理调参且覆盖多个尺度的模型，确保小规模没有被warmup、batch或容量平台支配。

接着提出候选函数：有无不可约项，幂律区间在哪里，需要哪些联合变量。明确拟合目标、初值与离群点处理，检查残差和不确定性，用未参与拟合的中间或更大规模测试预测。最后将函数和真实成本约束一起优化，检查最优点是否在实验覆盖区内，以及部署是否改变了目标。

你应能独立解释的四个联系

统计估计解释为何幂律自然，但不证明所有神经指数；系统优化让相同时间获得更多有效计算，但收益由曲线斜率决定；数据混合与重复改变有效信息量，因此数据管线和训练规模应共同设计；参数口径与优化配方改变拟合，所以可预测性需要精心构建实验。

本讲最终的产物应是一项带假设、证据和验证的资源决策。例如“在当前数据和损失定义下，已用留出规模检查，预算C附近选择N与D更有利；未来服务成本另计”。它比只写“缩放定律说明越大越好”更接近真正的大模型工程。下列自测用于检查你能否亲手复现这些推理，而不仅是认得曲线。

本节参考（完整书目见讲义末尾）：[slides]

自测与参考答案

1. L(D)=2+4D^(-0.5)。D从100变为400时，总损失与可下降部分各变多少？

D=100时L=2.4、可下降部分0.4；D=400时L=2.2、可下降部分0.2。可下降部分减半，总损失只减少0.2。对log L做直线拟合会混入平台2的影响。这里D采用教学归一化单位。

2. 同一均值估计问题，为什么有人报告−1斜率，有人报告−1/2？

若报告MSE=σ^2/n，双对数斜率为−1；若报告RMSE=$\sigma/\sqrt{n}$，斜率为−1/2。先核对风险定义，再讨论两项实验是否矛盾。若样本相关，还应保留协方差项。

3. 在d=4的有噪Lipschitz回归中，分箱平衡给什么速率？

风险量级为$h^2+1/(nh^4)$。令$h^2\approx 1/(nh^4)$，得$h\approx n^{(-1/6)}$，均方风险约$n^{(-1/3)}$。不是将原页19的简化式直接套为n^(-1/4)。预测新含噪标签还要加噪声方差。

4. 为何可以有“同样斜率、不同最佳配比”？

若$\Delta L=A(q)n^{(-\alpha)}$，斜率$-\alpha$共同，但A(q)不同；选择较小A(q)的配比就更好。两群均值例子给A(q)=[1/q+1/(1−q)]/2，在q=0.5时最小。若斜率或平台随配比变，排名可能交叉。

5. 100M唯一token训练4遍，在R*=3的教学模型中，有效数据是多少？

额外重复次数R=3；D′=100M+300M(1−exp(−1))约289.6M。累计处理量是400M；唯一数据仍100M。三种量回答不同问题，不能混报。

6. Bcrit=1000，Smin=1000时，将batch从1000提高到10000会发生什么？

Emin=Bcrit×Smin=1M。原B下S=2000、E=2M；新B下S=1100、E=11M。步数仅减少45%，累计样本增至5.5倍；实际是否更快取决于每步耗时，不能仅凭步数作结论。

7. 固定宽度d时增加attention head数，参数是否必定增加？

不必。若总投影仍为d×d，只是把维度分给更多头，则总投影参数基本不变，每头维度d/n_head减小。硬件布局、注意力行为与部分实现开销仍可变化。因此比较头数时应同时固定总宽度、核对每头维度，并报告所用实现；仅报告头数不能确定参数预算。

8. 8个10M专家、共享部分20M、每token激活2个专家，总参数和激活参数各是多少？

总参数约100M，激活参数约40M。这个简例忽略路由器等细节。存储预算应看全部参数；每token计算可由激活参数近似，但还要计路由与通信。

9. 损失指数α=0.3、β=0.2时，6ND固定的最优分配指数是多少？

N_opt随C^(β/(α+β))=C^0.4，D_opt随C^0.6增长；不是N随C^0.3、D随C^0.2。最优条件为0.3A/N^0.3=0.2B/D^0.2，而非两个损失项简单相等。

10. 为什么IsoFLOPs最低点落在搜索边界时不能直接宣布最优？

因为谷底可能在尚未扫描的范围外。应扩大参数搜索并按相同预算调整token，同时检查配方是否适合这些规模。U形拟合是经验局部近似，不保证真实全局凸。

11. 方法三与普通最小二乘有什么区别，为什么要多初值？

Chinchilla对log预测loss与log观测loss的残差使用Huber损失，且用L-BFGS多初值优化。Huber处理大残差与平方损失不同；平台、幅度和指数耦合，目标非线性，多初值用于减轻不良局部解或收敛问题。仍需保留留出点验证。

12. 共享输入embedding和输出head的权重，能否把输出计算从FLOPs删掉？

不能。共享减少独立存储参数，并不消除隐藏状态对全词表的输出乘法。输入查表和输出投影的操作成本不同，计数时要分别处理。

13. 为什么“旧缩放曲线被新方法突破”不必意味着整个研究范式错误？

旧曲线描述具体数据、配方和实验区间的表现。改进优化、正则或数据可以降低常数或改变其他项。已试配置的下包络不是所有可能算法的不可突破损失下界。应检验新方法是否形成稳定、可复现的新趋势。

14. 小模型额外花费1.2e22训练FLOPs，每个推理token节省1e10 FLOPs，何时回本？

理想化回本$T=1.2\times10^{22}/10^{10}=1.2\times10^{12}$个推理token。这个算式还假设模型质量满足相同目标，并忽略硬件、缓存、上下文与延迟差异；它是说明服务量如何改变最优解的教学模型。若按金额计费，还需区分训练与服务硬件的单位价格、利用率和固定开销，不能直接把FLOPs比当成账单比。例如需求不确定时，可分别估算低、中、高调用量下的总成本；只有同时满足质量、显存与延迟要求的方案才进入比较。这样得到的是带使用情景的决策，而不是一个脱离部署条件的固定比例。

15. 你只有三个小规模点且拟合几乎完美，下一步该做什么？

保留训练/评估协议，增加一个未用于拟合的中间或更大规模检验预测；同时比较带平台项等合理候选形式，记录参数和数据口径，检查残差与优化充分性。少量点上的高拟合优度不等于远距离外推可信。

参考资料

[course] Stanford CS336 Spring 2026 官方课程

https://cs336.stanford.edu/

[slides] Lecture 09 原始英文幻灯片 · 官方仓库

https://github.com/stanford-cs336/lectures/blob/main/lecture_09.pdf

[captions] 第9讲公开录像字幕 · 第三方保存、未经教师审校

https://jingzechen.github.io/assets/courses/stanford-cs336-s26/lectures/009/captions.source.srt

[vc] Eric Xing 统计学习课程 · 有限假设集泛化界，原课件引用

https://www.cs.cmu.edu/~epxing/Class/10701/slides/lecture16-VC.pdf

[banko] Banko & Brill 2001 · Scaling to Very Very Large Corpora for Natural Language Disambiguation · 原论文

https://aclanthology.org/P01-1005/

[kolachina] Kolachina et al. 2012 · Prediction of Learning Curves in Machine Translation · 原论文

https://aclanthology.org/P12-1003/

[hestness] Hestness et al. 2017 · Deep Learning Scaling is Predictable, Empirically · 原论文

https://arxiv.org/abs/1712.00409

[kaplan] Kaplan et al. 2020 · Scaling Laws for Neural Language Models · 原论文

https://arxiv.org/abs/2001.08361

[nonparametric] Ryan Tibshirani（with Larry Wasserman）· Nonparametric Regression · 2015理论补充课程讲义

https://stat.cmu.edu/~larry/=sml/nonpar.pdf

[bahri] Bahri et al. · Explaining Neural Scaling Laws · 原论文，**2021**预印本/**2024**修订

https://arxiv.org/abs/2102.06701

[hashimoto] Hashimoto 2021 · Model Performance Scaling with Multiple Data Sources · 原论文

https://proceedings.mlr.press/v139/hashimoto21a.html

[mixing] Ye et al. · Data Mixing Laws: Optimizing Data Mixtures by Predicting Language Modeling Performance · 原论文

https://arxiv.org/abs/2403.16952

[data-decide] Magnusson et al. 2025 · DataDecide: How to Predict Best Pretraining Data with Small Experiments · 原论文

https://arxiv.org/abs/2504.11393

[data-repeat] Muennighoff et al. 2023 · Scaling Data-Constrained Language Models · 原论文

https://arxiv.org/abs/2305.16264

[infinite] Kim et al. · Pre-training under infinite compute · 原论文，2025预印本

https://arxiv.org/abs/2509.14786

[data-filter] Goyal et al. 2024 · Scaling Laws for Data Filtering — Data Curation cannot be Compute Agnostic · 原论文，视觉语言实验

https://arxiv.org/abs/2404.07177

[architecture] Tay et al. 2022 · Scaling Laws vs Model Architectures: How does Inductive Bias Influence Scaling? · 原论文

https://arxiv.org/abs/2207.10551

[moe] Abnar et al. 2025 · Parameters vs FLOPs: Scaling Laws for Optimal Sparsity for Mixture-of-Experts Language Models · 原论文

https://arxiv.org/abs/2501.12370

[batch] McCandlish et al. 2018 · An Empirical Model of Large-Batch Training · 原论文

https://arxiv.org/abs/1812.06162

[mup] Yang et al. · Tensor Programs V: Tuning Large Neural Networks via Zero-Shot Hyperparameter Transfer · 原论文

https://arxiv.org/abs/2203.03466

[transfer] Tay et al. · Scale Efficiently: Insights from Pre-training and Fine-tuning Transformers · 原论文

https://arxiv.org/abs/2109.10686

[rosenfeld] Rosenfeld et al. · A Constructive Prediction of the Generalization Error Across Scales · 原论文

https://arxiv.org/abs/1909.12673

[chinchilla] Hoffmann et al. 2022 · Training Compute-Optimal Large Language Models · 原论文，**§3**三种方法

https://arxiv.org/abs/2203.15556

[resolve] Porian et al. 2024 · Resolving Discrepancies in Compute-Optimal Scaling of Language Models · 原论文

https://arxiv.org/html/2406.19146v1

[reconcile] Pearce & Song 2024 · Reconciling Kaplan and Chinchilla Scaling Laws · 原论文

https://arxiv.org/html/2406.12907v2

[replicate] Besiroglu et al. 2024 · Chinchilla Scaling: A replication attempt · 图形重建与重新拟合原研究

https://arxiv.org/html/2404.10102v2

[diffusion] Gulrajani & Hashimoto 2023 · Likelihood-Based Diffusion Language Models · 原论文

https://arxiv.org/abs/2305.18619