CS336 · Spring 2026 · Lecture 11

缩放定律的实验配方：调度复用、超参数迁移与 μP 的条件

如何阅读这份自学增强讲义

原始英文幻灯片完整保留；每组原页之后紧接对应中文讲解。书签可跳转到原页与讲解。页码中的“原页”始终指原始 PDF 页码。

中文部分为自学补充；课堂转述、原论文结论与编者推导应按文中标记区分。第三方保存的字幕仅用于检索定位，不等同于教师审校逐字稿。

学习目标：把第9讲的下包络、IsoFLOP和联合曲面拟合转化为可执行的实验设计；能计算WSD共享前缀节约了什么，解释学习率与批大小为何会随规模漂移；能读懂μP的初始化、更新量级及Transformer参数分组，并判断何时需要重新验证迁移。

先修与符号：需理解交叉熵、SGD/Adam、warmup与cosine调度、Transformer宽度和深度，以及第9讲的C≈6ND。本文通常以N表示非嵌入参数数、D表示累计训练token数、C表示训练FLOPs、B表示一次优化器更新的全局token数、η表示学习率、L表示平均损失。若更换tokenizer，token损失不一定可直接比较。DeepSeek原图的M另指每token的非嵌入计算量，后文明确区分。

阅读主线：原页1–18看MiniCPM如何固定参数化、调批大小、共享训练前缀并拟合；19–30比较DeepSeek与其他模型的实际选择；31–43讨论调参曲面与优化器公平比较；44–58推导并检验μP。第9讲回答“如何拟合”，本讲追问“拿什么训练结果去拟合，配方是否随规模保持可比”。

来源与解释边界：slides为Spring 2026原课件，所有58页原样保留；captions为第三方保存的本讲录像字幕，仅用于核对课堂转述，附时间范围。minicpm/deepseek/step/optimizers/spectral/transfer是原论文或作者项目，固定版本尽量对应原页；编者推导、算例和实验建议均明确标记。原页中的模型性能和最佳超参数是其当时实验结果，不是当前模型榜单或通用常数。

Lecture 11

SCALING – CASE STUDY AND DETAILS

CS336

Motivation today

What is the best practices for scaling and hparam tuning LMs?

- Does chinchilla's approach to scaling actually work?
- Can we save compute when training and fitting these things?
- Should we be picking particular architectures / parametrizations to scale nicely?

第 11 讲 · 原页 1–2 · 中文讲解

从第9讲的拟合公式走到训练配方

为什么还需要这一讲

第9讲把训练结果写成L(N,D)，但真实实验还有初始化、架构、数据配方、优化器、批大小和学习率调度。更完整的记号是L(N,D;θ)，θ代表这些选择。把θ省略，隐含的是每个规模都获得了足够好的、彼此可比较的训练。若大模型学习率太高而发散，小模型学习率恰好合适，拟合到的可能是调参失败，而不是模型容量的规律。

三道必须先回答的问题

原页2的三个问题依次是：Chinchilla的分配方法在实际模型上有没有预测力；收集拟合数据能否少花计算；能否通过架构和参数化减少尺度敏感性。学习时把它们连起来：先定义可比较的模型族，再高效采样，再验证外推。μP帮助控制宽度变化时的超参数漂移，WSD帮助低成本收集不同D的终点，它们解决不同环节，不能互相替代。

本节参考（完整书目见讲义末尾）：[slides]

Scaling in practice

The newest model we talked about with scaling details - 2022

DeepMind

Training Compute-Optimal Large Language Models

Jordan Hoffmann*, Sebastian Borgeaud*, Arthur Mensch*, Elena Buchatskaya, Trevor Cai, Eliza Rutherford, Diego de Las Casas, Lisa Anne Hendricks, Johannes Welbl, Aidan Clark, Tom Hennigan, Eric Noland, Katie Millican, George van den Driessche, Bogdan Damoc, Aurelia Guy, Simon Osindero, Karen Simonyan, Erich Elsen, Jack W. Rae, Oriol Vinyals and Laurent Sifre*

*Equal contributions

What about more recently?

deepseek

DeepSeek LLM
Scaling Open-Source Language Models with Longtermism

2024

MiniCPM: Unveiling the Potential of Small Language Models with Scalable Training Strategies

Shengding Hu[1], Yuge Tu[2], Xu Han[1], Chaoqun He[1], Ganqu Cui[1], Xiang Long[2], Zhi Zheng[2], Yewei Fang[2], Yuxiang Huang[1], Weilin Zhao[1], Xinrong Zhang[1], Zheng Leng Thai[1], Kaihuo Zhang[2], Chongyi Wang[2], Yuan Yao[1], Chenyang Zhao[1], Jie Zhou[2], Jie Cai[2], , Zhongwu Zhai[2], Ning Ding[1], Chao Jia[2], Guoyang Zeng[2], Dahai Li[2], Zhiyuan Liu[1]*, Maosong Sun[1]
[1]Department of Computer Science and Technology, Tsinghua University.
[2]Modelbest Inc.
shengdinghu@gmail.com

2024

Meta

The Llama 3 Herd of Models

Llama Team, AI @ Meta[1]
[1]A detailed contributor list can be found in the appendix of this paper.

2024

Hunyuan-Large: An Open-Source MoE Model with 52 Billion Activated Parameters by Tencent

Tencent Hunyuan Team

2024

MINIMAX

MiniMax-01: Scaling Foundation Models with Lightning Attention

MiniMax[1]

2025

KIMI K2: OPEN AGENTIC INTELLIGENCE

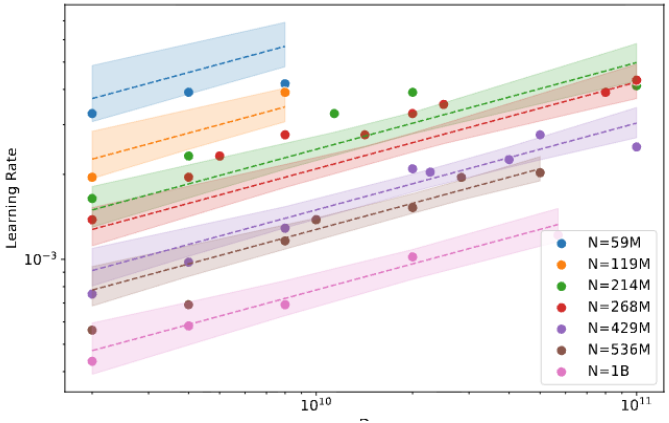
TECHNICAL REPORT OF KIMI K2

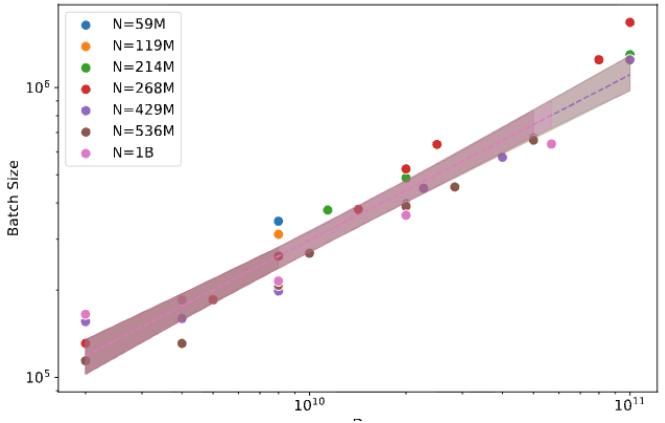
Kimi Team

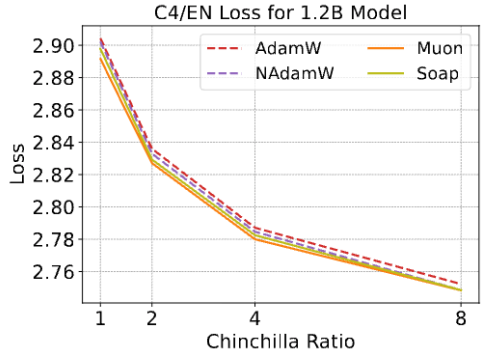
2026

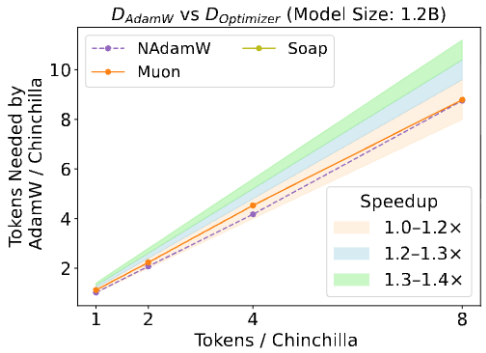
Initialization and optimizers

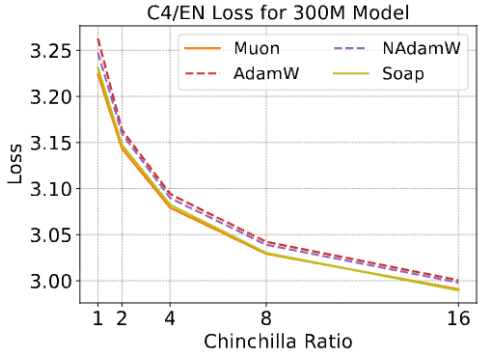
Initialization, optimizers, and various hyperparams (LR/batch) can be scale sensitive











Working through some detailed, public scaling recipes

1. MiniCPM

MiniCPM: Unveiling the Potential of Small Language Models with Scalable Training Strategies

Shengding Hu[1], Yuge Tu[2], Xu Han[1], Chaoqun He[1], Ganqu Cui[1], Xiang Long[2], Zhi Zheng[2], Yewei Fang[2], Yuxiang Huang[1], Weilin Zhao[1], Xinrong Zhang[1], Zheng Leng Thai[1], Kaihuo Zhang[2], Chongyi Wang[2], Yuan Yao[1], Chenyang Zhao[1], Jie Zhou[2], Jie Cai[2], , Zhongwu Zhai[2], Ning Ding[1], Chao Jia[2], Guoyang Zeng[2], Dahai Li[2], Zhiyuan Liu[1]*, Maosong Sun[1]
[1]Department of Computer Science and Technology, Tsinghua University.
[2]Modelbest Inc.
shengdinghu@gmail.com

2. DeepSeek

deepseek

DeepSeek LLM
Scaling Open-Source Language Models with Longtermism

第 11 讲 · 原页 3–5 · 中文讲解

公开模型报告是条件各异的实验记录

读原页3与5：为什么选这些案例

原页从2022年的Chinchilla转向MiniCPM、DeepSeek、LLaMA、Hunyuan等后续报告。两项详细案例分别代表“用μP规范缩放”和“直接拟合学习率/批大小缩放”两条路线。阅读模型名和年份是为了定位实验来源，不能把这些年份或性能描述当作今天的产品状态。原页5选择它们的主要价值在于公开了实验过程。

读原页4：规模敏感的不只是参数数量

上方学习率/批大小曲线提醒我们：同一个超参数在不同模型或数据量上可能含义不同；下方优化器图则提醒我们：小模型上的加速比可能随规模、训练token/参数比而变。编者补充：宽度从512变2048时，一个方阵参数量变为16倍，但每层输入维度只变为4倍；“学习率按参数量除16”和“按fanin除4”不是同一个规则。定义缩放方向比机械套一个指数更早。

本节参考（完整书目见讲义末尾）：[slides]

MiniCPM

MiniCPM (2024) – small, high-perf LM from Tsinghua group.



MiniCPM: Unveiling the Potential of Small Language Models with Scalable Training Strategies

Shengding Hu[1], Yuge Tu[2], Xu Han[1]*, Chaoqun He[1], Ganqu Cui[1], Xiang Long[2], Zhi Zheng[2], Yewei Fang[2], Yuxiang Huang[1], Weilin Zhao[1], Xinrong Zhang[1], Zheng Leng Thai[1], Kaihuo Zhang[2], Chongyi Wang[2], Yuan Yao[1], Chenyang Zhao[1], Jie Zhou[2], Jie Cai[2], , Zhongwu Zhai[2], Ning Ding[1], Chao Jia[2], Guoyang Zeng[2], Dahai Li[2], Zhiyuan Liu[1]*, Maosong Sun[1]

[1]Department of Computer Science and Technology, Tsinghua University.

[2]Modelbest Inc.

shengdinghu@gmail.com

Careful, extensive scaling computations + muP to stabilize and simplify scaling

Not really ‘sota’ model (even in 2024) but many interesting lessons on scaling

MiniCPM

High performance 1-2.5 B parameter models. These models beat most out 2Bs and match many modern 7B models.

Model	C-Eval	CMMLU	MMLU	HumanEval	MBPP	GSM8K	MATH
Llama2-7B	32.42	31.11	44.32	12.20	27.17	13.57	1.80
Qwen-7B	58.96	60.35	57.65	17.07	42.15	41.24	5.34
Deepseek-7B	42.82	44.45	47.82	20.12	41.45	15.85	1.53
Mistral-7B	46.12	42.96	62.69	27.44	45.20	33.13	5.00
Gemma-7B	42.57	44.20	60.83	38.41	50.12	47.31	6.18
Llama2-13B	37.32	37.06	54.71	17.07	32.55	21.15	2.25
MPT-30B	29.34	32.09	46.56	21.95	35.36	10.31	1.56
Falcon-40B	40.29	41.57	53.53	24.39	36.53	22.44	1.92
TinyLlama-1.1B	25.02	24.03	24.3	6.71	19.91	2.27	0.74
Qwen-1.8B	49.81	45.32	43.37	7.93	17.8	19.26	2.42
Qwen1.5-1.8B	**55.00**	50.85	43.81	5.49	24.82	26.16	3.25
Gemini Nano-3B	-	-	-	-	27.20	22.80	-
StableLM-Zephyr-3B	30.34	30.89	45.90	35.37	31.85	52.54	12.12
Phi-2(2B)	23.37	24.18	52.66	47.56	**55.04**	**57.16**	3.50
Gemma-2B	29.26	28.56	38.49	24.39	29.74	16.83	3.34
MiniCPM-1.2B	49.14	46.81	49.63	44.51	32.75	31.77	10.60
MiniCPM-2.4B	51.13	**51.07**	**53.46**	**50.00**	47.31	53.83	**10.24**

第 11 讲 · 原页 6–7 · 中文讲解

MiniCPM：从可审计的小模型族出发

原页6–7的证据如何读

MiniCPM案例关注约1–2.5B参数的小模型，原页7列出知识、数学、代码等多项评测。横向比较前先看任务、模型版本和训练数据条件；某列接近7B模型不等于所有能力都等于7B，也不能单靠排行榜证明μP造成了收益。真正支持本讲主线的，是后面公开的模型族、学习率扫描和训练调度对照。

编者补充：把报告拆成可验证的问题

一份配方至少要回答：模型大小怎么改变；哪些初始化和缩放因子被固定；B与η如何确定；训练到何种终点；哪部分结果用于拟合，哪部分留给外推验证。若只有最终分数而没有这些控制，最多知道配方能训练出模型，无法知道为什么可以从小模型预测大模型。MiniCPM的细节使我们能逐项检查这些连接。

本节参考（完整书目见讲义末尾）：[slides] · [minicpm]

Techique 1: muP to stabilize scaling

Scale_emb = 12, scale_depth = 1.4, init_std = 0.1, lr =0.01

Name	Specific Operation
Embedding Output Scaling	Multiply the output of the embedding by $scale_emb$
Residual Connection Scaling	Scale the increment at each residual connection in each layer by $scale_depth/\sqrt{\text{num_layers}}$
Initialization of Tensors	Set the initialization standard deviation of each two-dimensional tensor parameter to $init_std/\sqrt{d_m/d_{base}}$, and set other parameters' initialization to 0.1
Learning Rate Scaling of Tensors	Adjust the learning rate of each two-dimensional tensor parameter to $1/(d_m/d_{base})$ times the learning rate of other parts (or the overall learning rate)
LM Head Scaling	Adjust the output logits to $1/(d_m/d_{base})$ times the original value

Table 7: List of operations used when applying tensor program techniques.

第 11 讲 · 原页 8–8 · 中文讲解

μP 配方先规范参数组，再谈“学习率不变”

逐行读原表

记宽度倍率r=d_m/d_base。原表把embedding输出乘scale_emb；每个残差分支增量乘scale_depth/√层数；二维参数初始化标准差按init_std/√r变化；相应学习率按1/r变化；LM head输出logits也乘1/r。原页顶部的12、1.4、0.1、0.01是该案例的基准常数，而非所有Transformer的推荐默认值。残差深度因子是这个实际配方的组成，不能从后文仅沿宽度的简化推导自动得到。

编者手算与含义

若r从1增到4，二维权重的标准差从0.1变0.05，其方差从0.01变0.0025；基准学习率0.01对应这些矩阵的实际学习率变0.0025，logits倍率变1/4。于是“最佳学习率能迁移”说的是归一化后的基准学习率，实际参数组的η已经在变化。只复制0.01而遗漏参数组缩放，不是同一μP实验。输出倍率还会影响softmax分布和反向梯度，因此初始化、前向缩放、学习率必须成套处理。

本节参考（完整书目见讲义末尾）：[slides] · [minicpm]

Scaling recipe / strategy

Use muP for initialization, fix the aspect ratio, scale up the overall model size.

Name	N (B)	d_m	d_{ff}	d_h	n_h	L
9M	0.009	320	800	64	5	8
30M	0.036	512	1280	64	8	12
70M	0.066	640	1600	64	10	14
0.1B	0.109	768	1920	64	12	16
0.17B	0.166	896	2240	64	14	18
0.2B	0.241	1024	2560	64	16	20
0.5B	0.499	1344	3360	64	21	24

Note that the gap between the largest model here and the actual model they train is ~5x

Optimal batch, LR, token-to-size ratios are directly fitted via scaling analysis

Optimal LR

According to muP – optimal learning rate should be (roughly) stable. Is it?

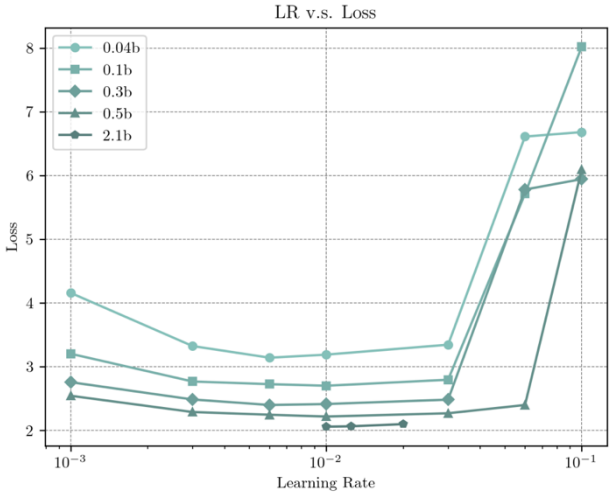


Figure 3: Loss vs Learning Rate. After applying for the Tensor Program, the learning rate shift becomes minimal.

第 11 讲 · 原页 9–10 · 中文讲解

模型族与学习率扫描：检验迁移而非假定迁移

原页**9**：缩放方向要可描述

表中从9M到约0.5B，同时增加宽度、MLP维度、头数和层数，头维度保持64，模型形状比例大体保持。所谓固定aspect ratio是按约定的形状关系建立模型族，不表示每个整数配置都完全等比。最大的代理模型与最终约2.4B模型仍相差约5倍，故最终训练是外推验证，不能算入同一小规模拟合的训练集来制造“预测正确”。

原页**10**：看谷底位置，不看曲线高度相同

横轴是学习率，纵轴是损失，多条线代表不同规模。大模型曲线整体较低很正常；迁移检验看各曲线的最低区域是否落在相近基准学习率附近。要同时看谷底宽度、扫描间隔和高学习率处是否急剧恶化。几个离散点共享同一个最优格点，只能说明在当前分辨率下近似一致，不能证明连续最优值完全相等。

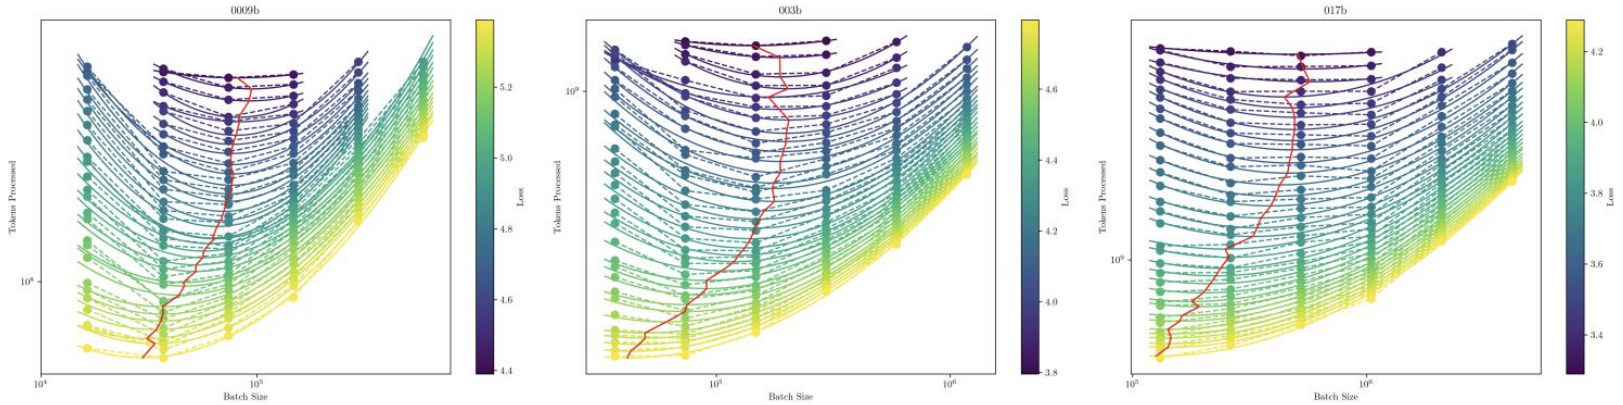
编者补充：最小可行的迁移实验

先用两个小宽度扫描同一组基准η，记录最终验证损失与发散情况；在中等宽度补扫谷底附近，再决定是否迁移。固定数据、调度、batch口径、训练终点及参数组规则。若最佳值漂移，先查实现和控制变量，再考虑拟合漂移规律；不要直接将差异归咎于μP理论。

本节参考（完整书目见讲义末尾）：[slides] · [minicpm]

Optimal batch

Three model sizes (9m, 30m, 170m) as a function of data size (y), batch (x) and loss (col)



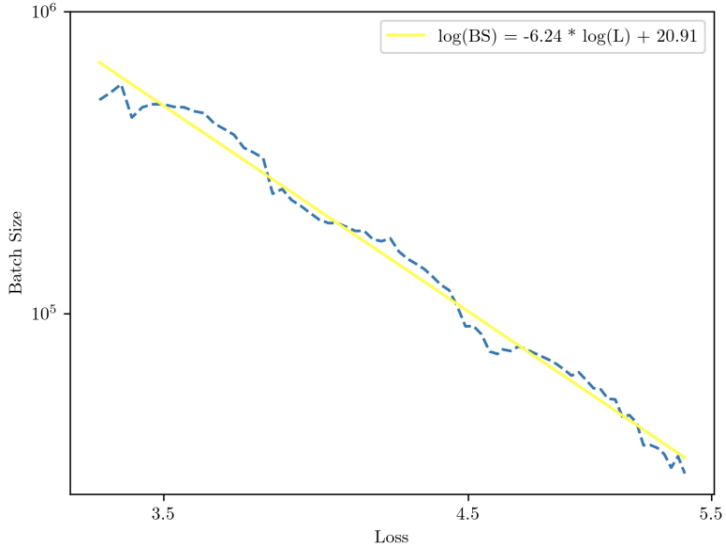
Vertical columns of points represent a single training curve (fixed batch, more points).

Red line attempts to identify minimum loss points for each y-value

– this is the ‘optimal batch size’ for a model size / dataset size combination.

Optimal batch size

We can then follow the Kaplan 2020 analysis and plot optimal batch size vs final loss.



Fairly clean trend – polynomially increase the batch size as loss decreases.

第 11 讲 · 原页 11–12 · 中文讲解

批大小仍需单独拟合

原页**11**：每列是一条训练轨迹

三个面板对应9M、30M、170M模型。横轴是batch，纵轴是数据量，颜色表示损失；同一竖列是固定batch训练过程中的不同checkpoint。比较同一y值的横截面，才是在相同累计token预算下选batch。红线是各数据量上低损失位置的估计；它不是把同一模型在训练中动态改batch后得到的实测轨迹。

原页**12**：损失与最优**batch**的经验关系

把上页选出的最佳batch按最终loss重新作图，得到loss降低时batch增大的趋势。这与第9讲的临界批大小直觉相连：梯度信号较弱、噪声相对更突出时，更大batch可能有用。但“固定token预算下最终loss最小的batch”和“继续加batch不再有效减少步数的临界batch”是不同定义，经验上相关不代表严格相等。

原图显式拟合log(BS)=−6.24log(L)+20.91，其中BS即batch size。同一对数底下，这表示BS∝L^(−6.24)；编者例：loss乘0.9时，预测batch乘0.9^(−6.24)≈1.93。指数描述相对变化，截距还依赖对数底、batch单位与loss口径；不能将这条局部经验拟合无限外推到loss趋0。

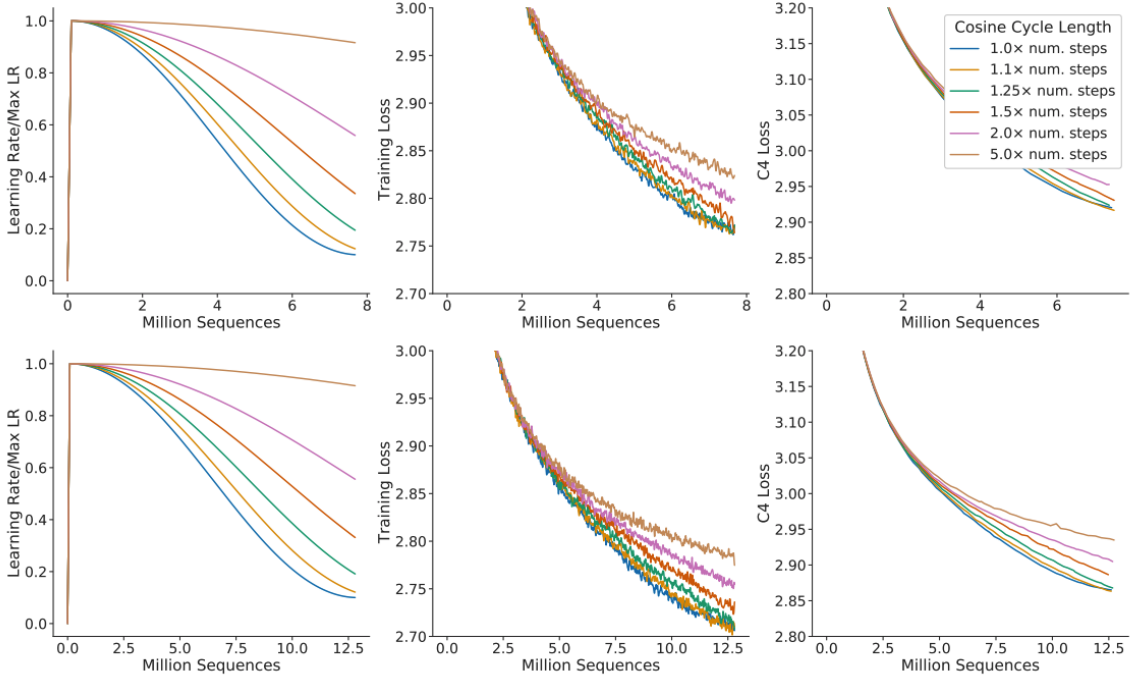
编者手算：**token**、样本和更新次数

若全局batch为512条、每条2048 tokens，则B=1,048,576 tokens/update。训练D=2^{24} tokens要16次更新；把B翻倍只剩8次。batch更大虽降低梯度噪声，却减少固定D下的更新次数，并改变硬件利用率。此处的最优loss不自动等于最短墙钟时间。梯度累积也计入全局B，不能把每卡microbatch直接代入缩放拟合。

本节参考（完整书目见讲义末尾）：[slides] · [minicpm]

What remains – model size vs data tradeoffs.

From chinchilla – to fit a scaling law, we need to train from scratch, not just early stop



This turns the cost of fitting a scaling law from n to n^2.. Can we avoid this?

第 11 讲 · 原页 13–13 · 中文讲解

为什么长 cosine 轨迹的中点不是短训练的终点

编者推导：调度依赖总预算

忽略warmup，零终值cosine可写为$\eta(t;T)=\eta_{max}[1+\cos(\pi t/T)]/2$，T是预定总步数。若短训练T=100，长训练T=200，在t=100时前者学习率为0，后者为$\eta_{max}/2$；在t=50时也分别为$\eta_{max}/2$与约$0.8536\eta_{max}$。两者从很早就走过不同更新轨迹，所以长训练在100步处的checkpoint不能视为完成100步cosine的结果。

把第9讲的实验点定义正确

为了拟合L(N,D)，每个点应来自约定训练配方下完成相应预算的训练。否则长计划早停点可能尚未得到衰减带来的损失改善，系统性高估短D的损失。原页“必须从头训练”针对这种终点依赖调度，不是宣称所有学习率方案都禁止共享前缀。

n到n^2究竟指什么

编者补充：固定模型，目标长度取$\Delta,2\Delta,\ldots,K\Delta$，分别从头训练要$\Delta K(K+1)/2$个单位token工作，而单次最长轨迹只需$K\Delta$。若还扫描J个模型大小，工作量再乘各自每token成本并求和。课件的n与n^2是重复前缀成本的示意，不能当作与预算采样方式无关的复杂度定理；几何递增长度时成本比例会不同。

本节参考（完整书目见讲义末尾）：[slides]

(partial) solution in miniCPM – WSD learning rate

Instead of cosine, split learning rate into warmup, stable, and decay phases.

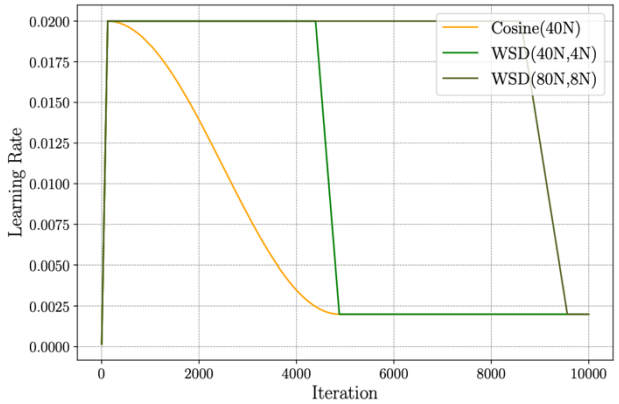


Figure 15: Illustrative comparison between Cosine LRS and WSD LRS. The WSD LRS with different end steps share the same stable training stage.

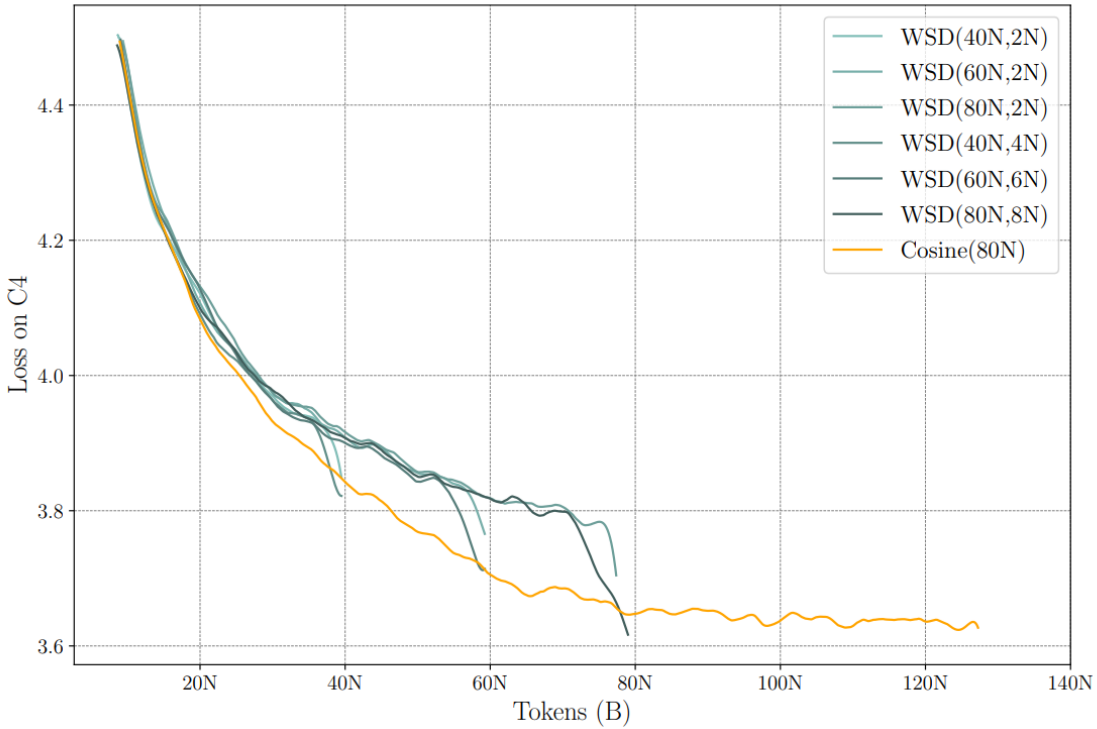
In this section, we introduce the utilization of the WSD scheduler as an effective approach to explore the scaling law with linear cost ($O(mC)$). Since WSD scheduler has the advantage of arriving at the optimal loss of Cosine LRS after decaying from stable stage's checkpoints of any step, we are now able to precisely measure the optimal scaling properties without re-training the models from scratch to different amount of tokens, thus making the scaling law measurement much more efficient along the data axis.

We measure the scaling law along the data and model axes by training SLMs of 6 sizes ranging from 0.04B to 2B, each with 6 decayed model starting from checkpoint of $10N$ to $60N$ data during the stable training stage. The final loss is evaluated on five held-out evaluation dataset. To potentially compare the loss when the model uses different tokenizer, we take the average of loss by number of bytes instead of number of tokens, following Achiam et al. (2023). The final loss of each pair of data size and model size is shown in the blue lines in Figure 17.

For chinchilla-style analysis, can restart the run at the end of the stable phase.

WSD learning rates work well in miniCPM

Slower during the stable phase, rapid loss decay during decay phase. Decay ~ 10%.



第 11 讲 · 原页 14–15 · 中文讲解

WSD：共享稳定前缀，为每个终点另接衰减

三阶段与可复用的状态

WSD是warmup、stable、decay。固定warmup长度后，η升到平台，稳定阶段维持相同η；在目标终点之前才分叉执行衰减。若各实验的模型、数据顺序、batch、平台η等相同，稳定前缀就能共用。应保存权重、优化器动量/二阶矩、随机状态与数据位置；只有权重相同并不保证继续训练相同。不要从已经衰减过的短跑终点重启并称之为共享原稳定轨迹。

编者算例：省计算但并非零代价

忽略固定warmup开销，目标D取100、200、400百万tokens，衰减各占10%。独立训练共700M。共享稳定主干训练到360M，再从90M、180M、360M处分出10M、20M、40M衰减尾巴，共360+10+20+40=430M，节约约38.6%。终点分别仍消耗100M、200M、400M训练tokens；430M是研究者收集三个终点的总支出，不能把它当作某个模型的D。

原页**15**：在相同终点比较

图中WSD稳定阶段看起来落后，但进入短衰减阶段后loss迅速下降。应把每条支线衰减完的终点与同预算cosine终点对比，不能拿平台中途loss宣布WSD失败，也不能忽略尾巴所消耗的token。原页约10%的衰减是案例经验；衰减形状、长度、终值都应记录。WSD不保证处处优于cosine，其价值包括更便宜的预算扫描。

课堂补充 · **00:10:05–00:13:40**

课堂先解释cosine为什么随总训练长度改变，再说明回到最后一个稳定checkpoint，延长稳定段并重新衰减的做法。每次衰减仍有成本。字幕中同时出现衰减到0和到峰值约10%的描述，应将其理解为不同常见调度设置；不能据此断言所有WSD终值相同。

本节参考（完整书目见讲义末尾）：[slides] · [minicpm] · [captions]

Chinchilla-type analysis

Equipped with the WSD learning rate,

we can now try to find the optimal data-to-model size ratio

Then we fit the losses with model size N and data size D following Hoffmann et al. (2022) using scipy `curvefit` function:

$$L(N, D) = C_N N^{-\alpha} + C_D D^{-\beta} + L_0 \tag{2}$$

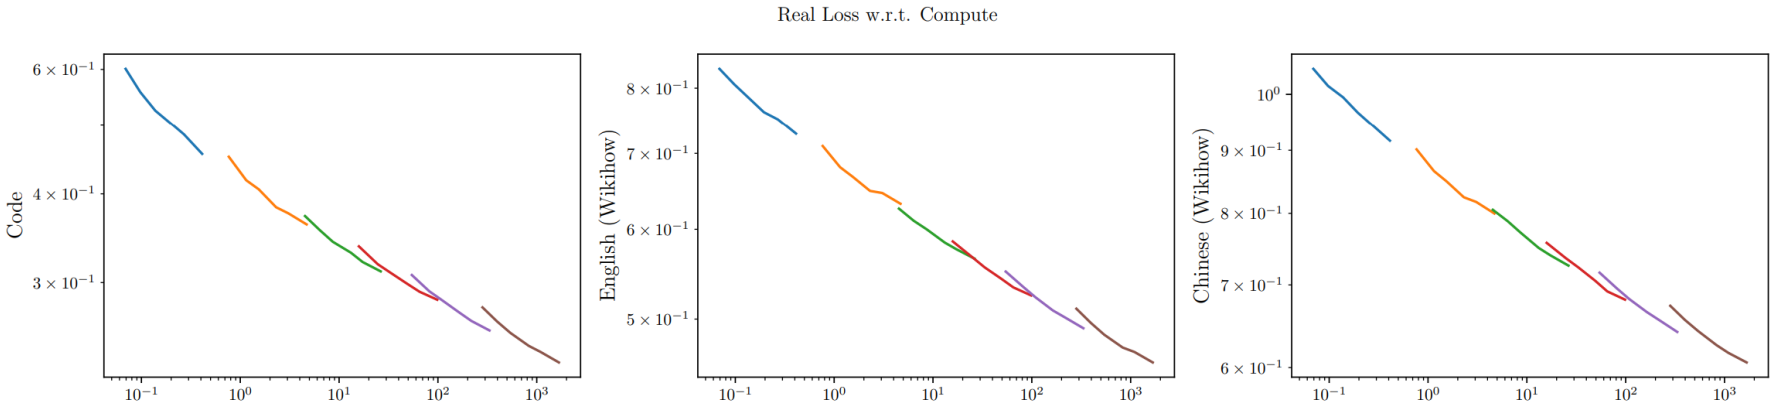
The fitted curve along the data axis for each dataset and each checkpoints are shown in orange lines in Figure 17. Then we have the optimal model size N_{opt}, dataset size D_{opt}, given a fixed amount of compute $C = 6ND$ (Rae et al., 2021) as:

$$\frac{N_{opt}}{D_{opt}} = K^2 \left(\frac{C}{6}\right)^{\eta}, \tag{3}$$

MiniCPM authors choose method 1 (lower envelope) and method 3 (joint fit)

Chinchlla method 1

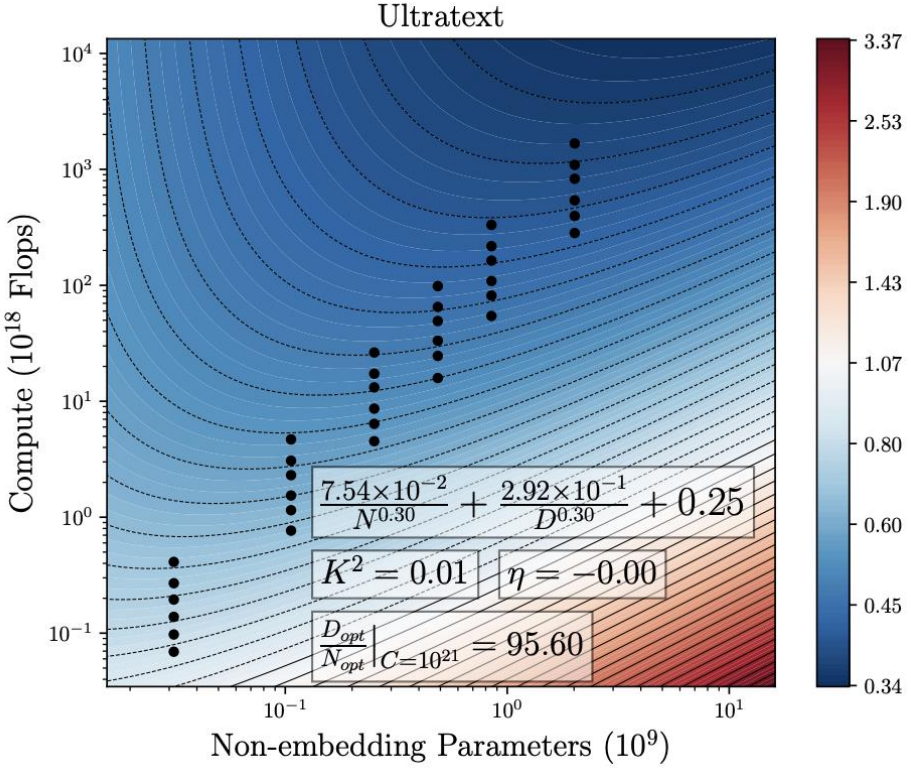
Fairly clear (though maybe not linear?) trends



Different colors indicate different models. Their runs suggest relatively low diminishing returns due to data.

Chinchilla method 3

Their primary scaling approach is the joint fit – they find *very* high data-model ratios.



第 11 讲 · 原页 16–18 · 中文讲解

用 WSD 终点连接第9讲的三种拟合方法

原页16–17：方法1，下包络

对每个N，用不同D完成各自衰减，得到(C,L)点；在相同C处比较，取最低loss构成下包络，再拟合相应N_opt(C)、D_opt(C)。原页17不同颜色代表不同模型，三图分别是在Code、English（Wikihow）、Chinese（Wikihow）评估语料上的loss–compute族曲线，并未直接画出最佳N、D随C的关系。可以沿各图下包络追踪在不同预算下胜出的已测模型，再另行估计分配趋势。包络只对已试配置最优，稀疏采样、插值和调参不足都会使其偏离真实最优。原页对“是否真是直线”的保留也应保留，不强迫弯曲趋势服从单一幂律。

原页18：方法3，先拟合曲面再优化

联合式可记为L(N,D)=E+A N^(−α)+B_0 D^(−β)，B_0是拟合系数，与batch B无关。用不同N,D的完整训练终点拟合A,B_0,α,β,E，再在C=6ND约束下选最小loss。原图横轴是非嵌入参数数，纵轴是compute，不是D；可由D=C/(6N)将曲面转换过来。黑点是实测，彩色区域与等高线是拟合预测，不能把连续底色误认成大量独立实验。

编者推导：数据/模型比为何会不同

代入D=C/(6N)，对N求导并令零：αA N^(−α)=βB_0 D^(−β)。因此N_opt∝C^[β/(α+β)]，D_opt∝C^[α/(α+β)]。若α=β=a，D/N=(B_0/A)^(1/a)。图中显示约a=0.30，A=7.54×10^{-2}，B_0=2.92×10^{-1}，代入四舍五入后的数值得约91.2；图中报告95.60，这与未舍入拟合参数及口径有关，不能强行声称这几个显示值能精确算出95.60。且系数依赖N,D的计量单位。

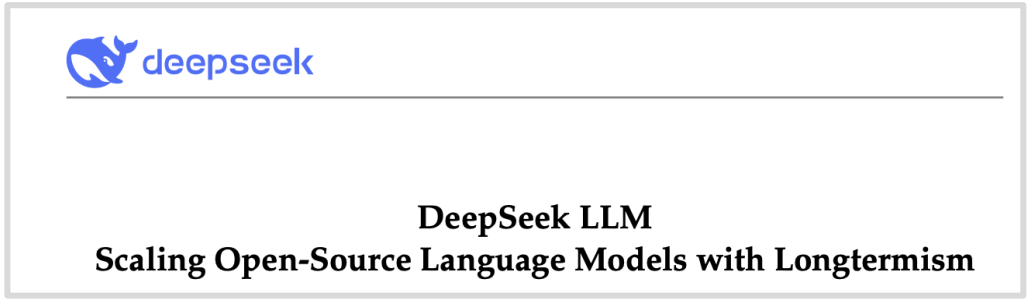
与方法2及第9讲的连接

方法2是先固定C、扫描N，再对各条IsoFLOP曲线找谷底；它是后面DeepSeek的选择。三种方法可以使用相近训练数据，却施加不同的拟合假设。WSD改变的是采样成本与调度协议，不把三种估计器变成同一种方法。MiniCPM原图在Ultratext评估口径、C=10^{21} FLOPs处给出95.60的数据/参数比（约96），而第9讲常见约20，提示数据配方、参数口径和训练协议都会改变最优点；不宜把一个比例迁到所有项目。

本节参考（完整书目见讲义末尾）：[slides] · [minicpm]

DeepSeek

DeepSeek (2024) – another LM with careful scaling analysis

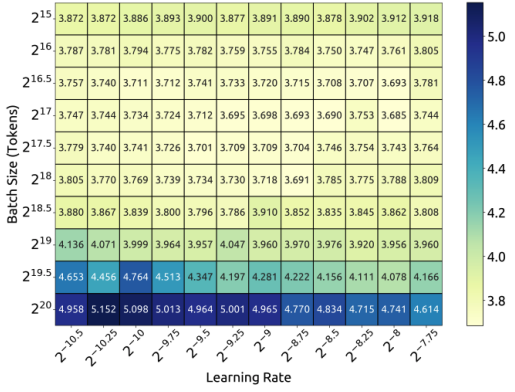


7 and 67B param models – generally high performance compared to other open LM

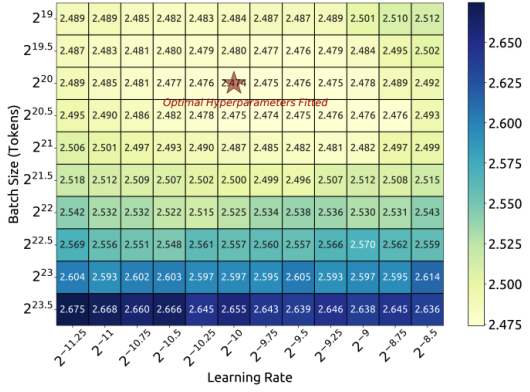
Scaling strategy – batch + LR

Scaling strategy: don't use any muP, directly estimate optimal batch / LR

We initially conducted a grid search for batch size and learning rate on small-scale experiments with a compute budget of 1e17, and the results of a specific model size (177M FLOPs/token) are illustrated in Figure 2(a). The results demonstrate that the generalization error remains stable across a wide range of choices of batch sizes and learning rates. This indicates that near-optimal performance can be achieved within a relatively wide parameter space.



(a) 1e17 FLOPs (177M FLOPs/token)

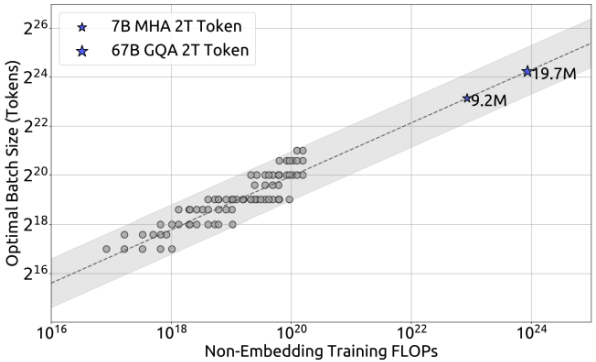


(b) 1e20 FLOPs (2.94B FLOPs/token)

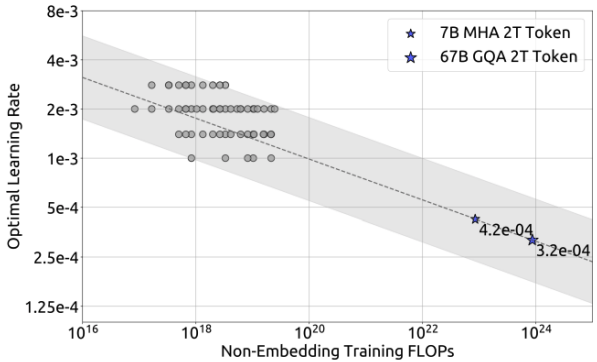
Scaling analysis of learning rates

Small scale runs + collect ‘near optimal’ (within 0.25% of min) models.

$$\eta_{\text{opt}} = 0.3118 \cdot C^{-0.1250}$$
$$B_{\text{opt}} = 0.2920 \cdot C^{0.3271} \quad (1)$$



(a) Batch size scaling curve



(b) Learning rate scaling curve

Learning rate fit looks a bit questionable..

第 11 讲 · 原页 19–21 · 中文讲解

DeepSeek：不预设 μP，直接拟合 batch 与学习率

原页19–20：另一条可行路线

这里是2024年DeepSeek LLM的7B/67B案例，不是后续所有DeepSeek模型的统一配方。其思路是在多个小计算预算上网格扫描batch和学习率，再对较好区域拟合缩放。原页20热图中最优附近是一片较平的区域；单个最小点容易受噪声影响，保留接近最优的一组配置更能反映可用区间。

原页21：读出拟合和不确定性

原图保留距最小loss约0.25%以内的近最优点，给出η_opt=0.3118 C^(−0.1250)，B_opt=0.2920 C^0.3271，C按该图非嵌入训练FLOPs的原单位。左图batch点大体随预算上升，右图学习率点散布较宽、预测跨度很大，讲者因此质疑其拟合稳健性。灰带与星号大模型位置帮助读者区分小规模证据和外推。系数的量纲随C单位改变；把FLOPs改成PFLOPs却不改系数会算错。

编者算例：用比例减少单位误用

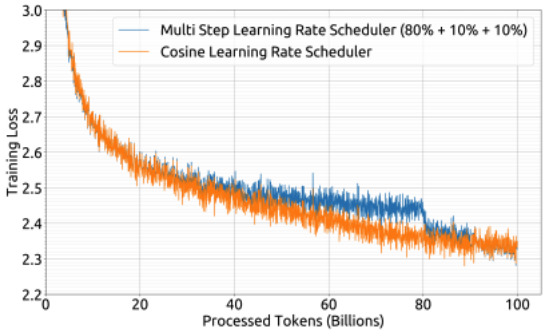
预算增加16倍，拟合意味着学习率乘16^(−0.125)=约0.707，batch乘16^0.3271=约2.48；并非学习率固定。若最低loss为2.000，按相对0.25%阈值，2.004属于近最优而2.006不属于。宽谷底说明多个设置都可用，但不能凭少数点断言最优η已被精确定位。训练稳定性和中等规模复核仍然必要。

本节参考（完整书目见讲义末尾）：[slides] · [deepseek]

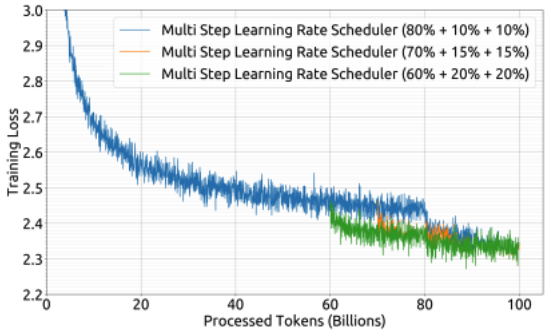
For chinchilla analysis: WSD-style learning rate

Deepseek uses WSD-style learning rate – fast warmup + two decay steps of 10% each.

A multi-step learning rate scheduler is employed during pre-training instead of the typical cosine scheduler. Specifically, the learning rate of the model reaches its maximum value after 2000 warmup steps, and then decreases to 31.6% of the maximum value after processing 80% of the training tokens. It further reduces to 10% of the maximum value after 90% of the tokens. The gradient clipping during the training phase is set to 1.0.



(a) Multi-step v.s. cosine learning rate decay



(b) Different proportions of multi-step stages

Generally seems to match performance of cosine learning rates.

第 11 讲 · 原页 22–22 · 中文讲解

DeepSeek 的多阶段调度如何节约扫描成本

原页的两个“10%”指时间段

原论文配方在2000步warmup后保持平台，在累计tokens达到80%与90%时，学习率分别降到峰值的约31.6%与10%。课件所谓两个10%的衰减阶段，是末尾两个各占总tokens 10%的区段，不能读成“每次把学习率减10%”。这与平滑线性WSD形状不同，但同样让大部分前缀不依赖最终训练长度。

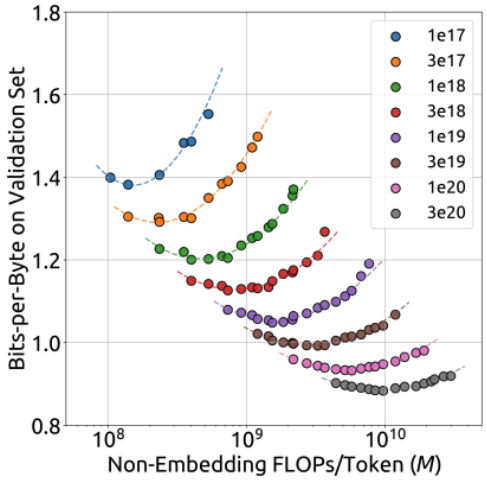
从示意到实验实现

编者例：若目标100M tokens，80M以前是平台，80–90M使用0.316η_max，90–100M使用0.1η_max。目标200M时分界在160M与180M，因此两者最多共享短跑首次衰减前的平台前缀。延长主干需回到分叉前的完整状态。原页两幅loss图显示该调度与cosine及不同衰减安排的终点接近，支持其在这些实验中的实用性；不能据图宣布所有调度在所有预算上等价。

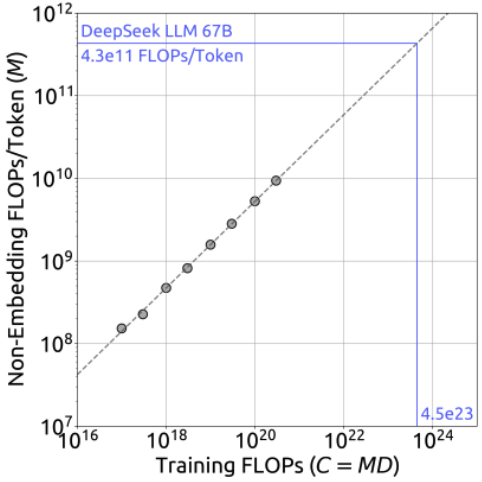
本节参考（完整书目见讲义末尾）：[slides] · [deepseek]

Data-size tradeoff analysis: Chinchilla method 2

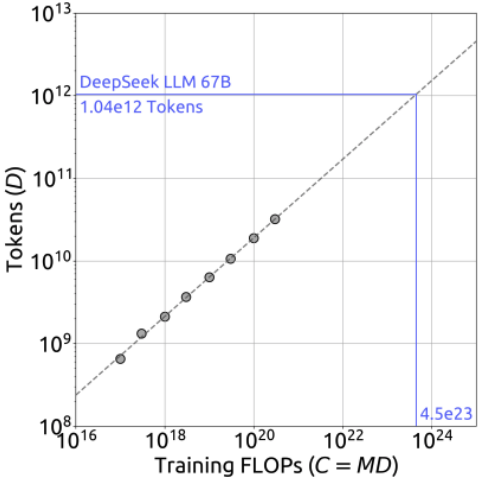
Straightforward isoflop-style analysis for selecting the model size tradeoffs.



(a) IsoFLOP curve



(b) Optimal model scaling



(c) Optimal data scaling

Scaling predicts final model loss

The fitted scaling models (generally) accurately predict the final model losses.

Additionally, we fitted the loss scaling curve according to compute budget C and optimal generalization error, and predicted the generalization error for DeepSeek LLM 7B and 67B, as shown in Figure 5. The results indicate that using small-scale experiments can accurately predict

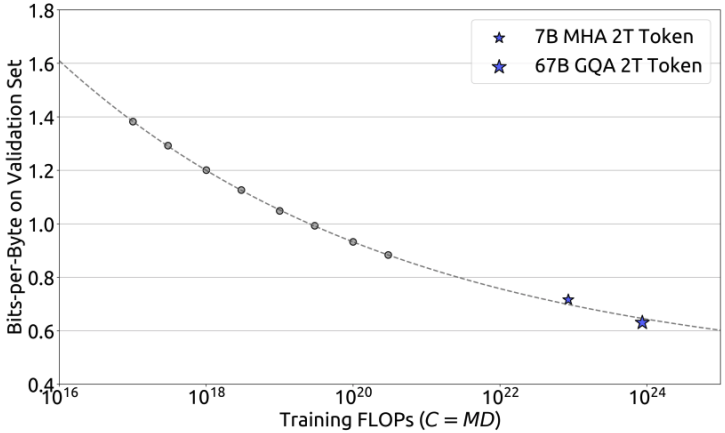


Figure 5 | Performance scaling curve. The metric is the bits-per-byte on the validation set. The dotted line represents the power law fitting the smaller model (grey circles). The blue stars represent DeepSeek LLM 7B and 67B. Their performance is well-predicted by the scaling curve.

第 11 讲 · 原页 23–24 · 中文讲解

IsoFLOP 找谷底，再用大模型检验预测

原页23：固定计算量才可比较分配

DeepSeek把模型规模M定义为每token的非嵌入计算量，故C=MD；近似密集Transformer时M≈6N，才与第9讲C≈6ND相接。左图每条曲线固定C：M太小时模型容量受限，M太大时可训练D太少，形成U形谷底。中图和右图分别拟合最佳M与最佳D随C的关系。不要把图中的FLOPs/token直接当成参数个数。

编者手算与验证设计

例如$C=6\times10^{18}$ FLOPs，在6ND近似下，$N=10^8$对应$D=10^{10}$，$N=2\times10^8$对应$D=5\times10^9$；两者计算相同，却需要不同长度的完整调度。对数空间二次拟合谷底只是局部插值，扫描若只覆盖下降侧就不能可靠定位最优。原页24用小模型拟合曲线去预测最终7B/67B模型损失，星号靠近预测是外推证据。该指标是验证集bits-per-byte；它不自动推出数学或代码能力的预测准确，也不等同于每token自然对数交叉熵。

编者补充：共用前缀带来的统计问题

WSD各支线共享初始化、数据和优化器历史，误差会相关。联合拟合可以使用这些点，但不宜当作很多相互独立的训练。评估不确定性时可按独立主干或随机种子分组；保留未参加拟合的预算与模型规模验证，比只报告训练点拟合优度更有意义。

本节参考（完整书目见讲义末尾）：[slides] · [deepseek]

Other models: Qwen scaling

Qwen 2.5 – batch and hyper scaling fits

3.2 Scaling Law for Hyper-parameters

We develop scaling laws for hyper-parameter based on the pre-training data of Qwen2.5 (Hoffmann et al., 2022; Kaplan et al., 2020). While previous studies (Dubey et al., 2024; Almazrouei et al., 2023; Hoffmann et al., 2022) primarily used scaling laws to determine optimal model sizes given compute budgets, we leverage them to identify optimal hyperparameters across model architectures. Specifically, our scaling laws help determine key training parameters like batch size B and learning rate μ for both dense models and MoE models of varying sizes.

Through extensive experimentation, we systematically study the relationship between model architecture and optimal training hyper-parameters. Specifically, we analyze how the optimal learning rate μ_{opt} and batch size B_{opt} vary with model size N and pre-training data size D. Our experiments cover a comprehensive range of architectures, including dense models with 44M to 14B parameters and MoE models with 44M to 1B activated parameters, trained on datasets ranging from 0.8B to 600B tokens. Using these optimal hyper-parameter predictions, we then model the final loss as a function of model architecture and training data scale.

Additionally, we leverage scaling laws to predict and compare the performance of MoE models with varying parameter counts against their dense counterparts. This analysis guides our hyper-parameter configuration for MoE models, enabling us to achieve performance parity with specific dense model variants (such as Qwen2.5-72B and Qwen2.5-14B) through careful tuning of both activated and total parameters.

Qwen 3 – similar scaling for LR/batch

Similar to Qwen2.5 (Yang et al., 2024b), we develop scaling laws for optimal hyper-parameters (e.g., learning rate scheduler, and batch size) predictions based on three pre-training stages mentioned above. Through extensive experiments, we systematically study the relationship between model architecture, training data, training stage, and optimal training hyper-parameters. Finally, we set the predicted optimal learning rate and batch size strategy for each dense or MoE model.

第 11 讲 · 原页 25–25 · 中文讲解

Qwen：有超参数缩放思路，不等于有完整复现实验

如何阅读两段报告摘录

Qwen2.5与Qwen3片段都提到在小模型上调参，再对batch、学习率等建立缩放关系。这说明实际训练先处理优化超参数，再决定最终训练配置，而不是直接拿一个N,D幂律包办全部选择。原页没有展示足以复原网格、全部测量点和拟合不确定性的细节，所以本页不补造具体公式。

编者补充：你能迁移的是方法

复现时可以采用“多个模型/数据规模上扫描→拟合→留出规模验证”的方法，但不能仅凭“我们使用scaling law”这句话推导某个指数。还要记录数据混合、训练阶段、架构和预算口径。不同阶段的数据质量变化会改变最优超参数；若把阶段边界附近的结果直接合成一条曲线，可能把数据变化误认为规模效应。

本节参考（完整书目见讲义末尾）：[slides]

Kimi K2

Many recent papers – sparsity scaling law to find the right sparsity levels

Sparsity Scaling Law We develop a sparsity scaling law tailored for the Mixture-of-Experts (MoE) model family using Muon. Sparsity is defined as the ratio of the total number of experts to the number of activated experts. Through carefully controlled small-scale experiments, we observe that — under a fixed number of activated parameters (i.e., constant FLOPs) — increasing the total number of experts (i.e., increasing sparsity) consistently lowers both the training and validation loss, thereby enhancing overall model performance (Figure 5). Concretely, under the compute-optimal sparsity scaling law, achieving the same validation loss of 1.5, sparsity 48 reduces FLOPs by 1.69×, 1.39×, and 1.15× compared to sparsity levels 8, 16, and 32, respectively. Though increasing sparsity leads to better performance, this gain comes with increased infrastructure complexity. To balance model performance with cost, we adopt a sparsity of 48 for Kimi K2, activating 8 out of 384 experts per forward pass.

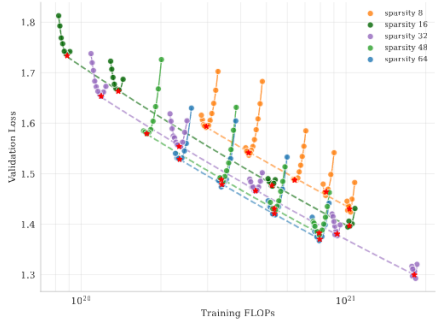


Figure 5: Sparsity Scaling Law. Increasing sparsity leads to improved model performance. We fixed the number of activated experts to 8 and the number of shared experts to 1, and varied the total number of experts, resulting in models with different sparsity levels.

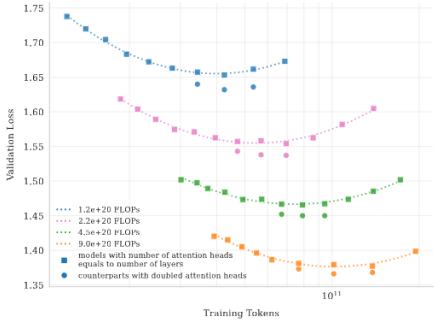


Figure 6: Scaling curves for models with number of attention heads equals to number of layers and their counterparts with doubled attention heads. Doubling the number of attention heads leads to a reduction in validation loss of approximately 0.5% to 1.2%.

Hunyuan (2024) large scaling laws

Yet more isoflops-style scaling (but this time for MoE parameter sizes)

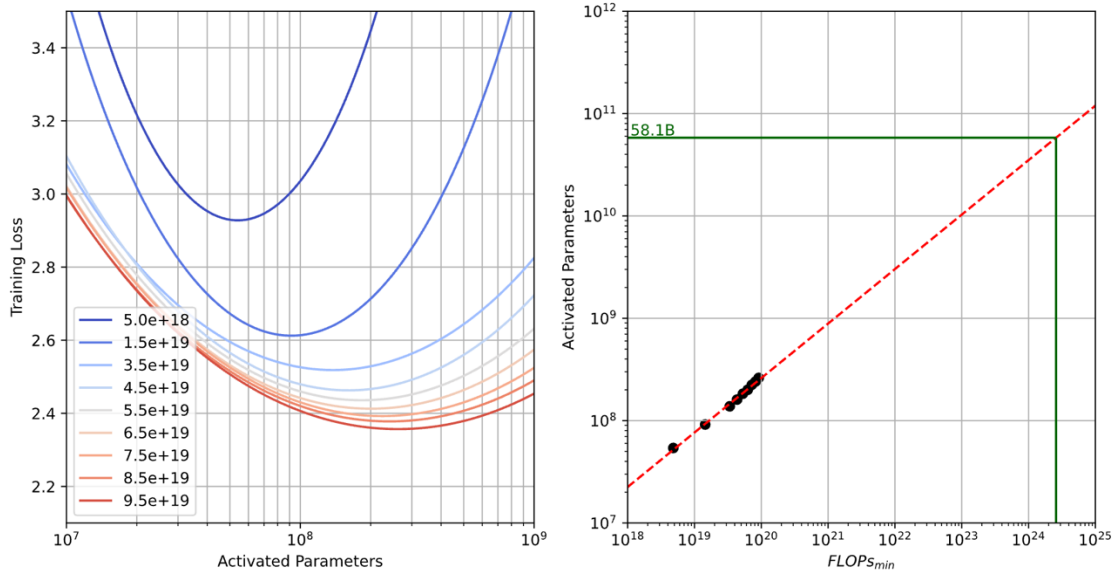


Figure 3: Using quadratic polynomial fitting, we obtain the scaling law of the optimal number of activation parameters under different minimum compute budgets.

Optimal ratio – 96-1 (data to active param)

第 11 讲 · 原页 26–27 · 中文讲解

MoE 缩放：总参数、激活参数和稀疏度

原页26：多一个可优化的轴

Kimi K2的图把稀疏度作为额外设计变量。MoE每个token只路由到部分专家，因此总参数决定存储与潜在容量，激活参数更接近每token算术量。比较不同稀疏度时应明确固定了总参数、激活参数还是FLOPs。图中多条曲线与谷底展示“更稀疏是否划算”要在预算约束下测量，不能从总参数越大直接推断计算更贵或效果更好。

原页27：读懂96:1的分母

Hunyuan左图是不同预算下loss对激活参数的曲线，右图把局部拟合出的最优点联系起来。原页给出的约96:1是数据tokens对激活参数，而非对全部专家总参数。编者例：若总参数100B、每token激活10B、训练960B tokens，则D/N_active=96而D/N_total=9.6，两者都算对但描述不同。共享层、路由、注意力及通信开销还会影响实际FLOPs和墙钟成本，6N_active D只是近似起点。

方法边界

MoE最优稀疏度还受专家负载、token覆盖与通信实现影响。应沿用第9讲控制变量的习惯：每条等算力线固定真正估算的计算预算，并保存参数口径。原页给出的模型案例支持“需要额外轴”，不支持把96或某个专家数当作普遍最佳值。

本节参考（完整书目见讲义末尾）：[slides]

LLaMA 3 (2024) Scaling laws

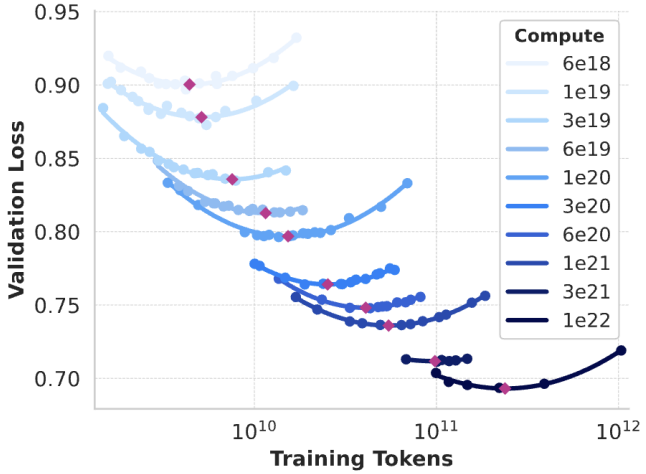
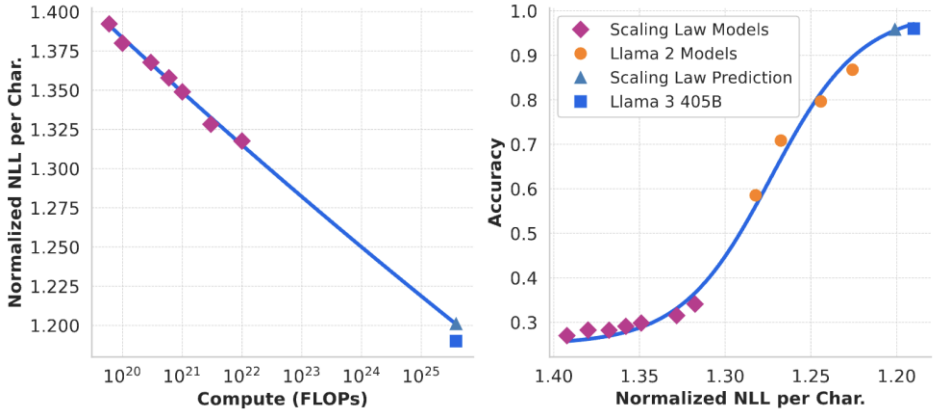


Figure 2 Scaling law IsoFLOPs curves between 6×10^{18} and 10^{22} FLOPs. The loss is the negative log-likelihood on a held-out validation set. We approximate measurements at each compute scale using a second degree polynomial.



Isoflops-style scaling (39-1 ratio)

Compute-to-downstream scaling

第 11 讲 · 原页 28–28 · 中文讲解

LLaMA 3：从预训练损失再走向下游能力

左图是资源分配，右图是两段预测

左侧IsoFLOP曲线在不同训练tokens处找到谷底，用来估计训练compute与模型/数据分配，原页标出约39:1。右侧先把训练compute映射到某个验证集的负对数似然，再把该loss映射到MMLU准确率；后者是弯曲的映射，不是“compute翻倍准确率翻倍”。请逐张辨别横轴，不能把右图的准确率直接当左图的优化目标。

编者补充：误差会穿过两层模型

设预测$L=f(C)$，准确率$A=g(L)$，小误差一阶近似为$\delta A \approx g'(L)\delta L$。若处于陡峭区，小loss误差也会放大为较大准确率误差；若曲线饱和则变化较小。此式是局部敏感性分析，不给全局保证。下游任务模板、测评噪声及训练数据覆盖变化，都可能使g失效。39、96、20等比例只有在同一优化目标和参数口径下才值得比较。

本节参考（完整书目见讲义末尾）：[slides]

MiniMax-01 (2025)

Architecture scaling laws + Chinchilla method 1

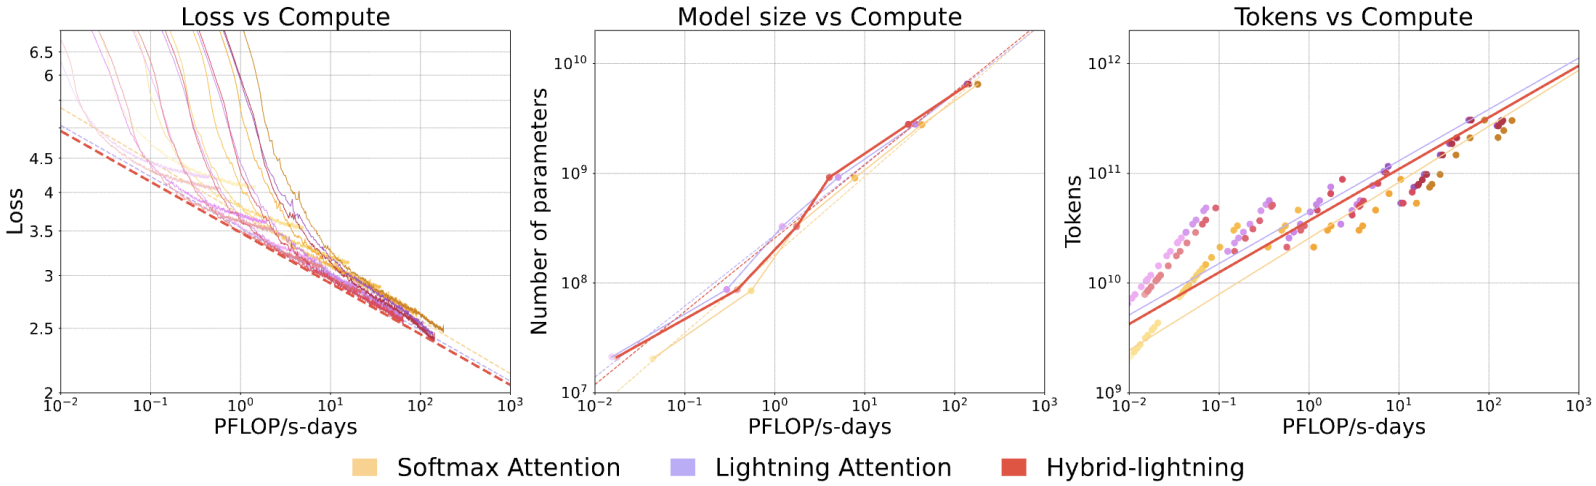


Figure 6 | **Summary of Scaling Laws.** Training curves (left) span models from 70M to 7B parameters. Optimal model size (center) and training tokens (right) are derived based on a specified compute budget estimation.

Recent scaling law recipes

DeepSeek recipe

- Assume most transformer hypers are invariant to scale
- Do a scaling analysis on batch / LR to figure out optimal scaling
- IsoFLOP analysis to figure out model sizing
  - Use a piecewise-linear schedule to make chinchilla scaling cheap.

miniCPM recipe

- Use muP to make transformer + LR invariant to scale
- Use a piecewise linear schedule to get sample for Chinchilla method 3 (curve fitting)

Recent (late 2024+) but less detailed

Qwen – Lr/batch (very few details..)
Kimi K2 – MoE scaling
LLaMA 3 / Hunyuan

- Just isoflops (no other scaling details)

Minimax

- Architecture choice / decision scaling

第 11 讲 · 原页 29–30 · 中文讲解

架构选择也要随预算评估

原页29：MiniMax把架构放入缩放实验

左图以不同注意力架构的loss–compute曲线取下包络，另两图展示推得的模型大小与数据量趋势。这是第9讲方法1用于架构决策：softmax attention、lightning attention及混合方案可能在不同预算区间占优。曲线交叉比某一个小预算上的排名更有信息。计算口径也应随架构重算，不能对明显不同的注意力成本永远使用同一个6ND系数。

原页30：把两条主配方并列

MiniCPM先通过μP规范初始化、前向和学习率尺度，再单独研究batch并以WSD收集终点，重点做联合曲面拟合。DeepSeek先假设大部分结构超参数可沿用，对batch和η做经验缩放，再用共享前缀的调度便宜地做IsoFLOP。两条路线都需要小规模试验和外推核验；μP不消除所有搜索，经验拟合也不要求必须先实现μP。

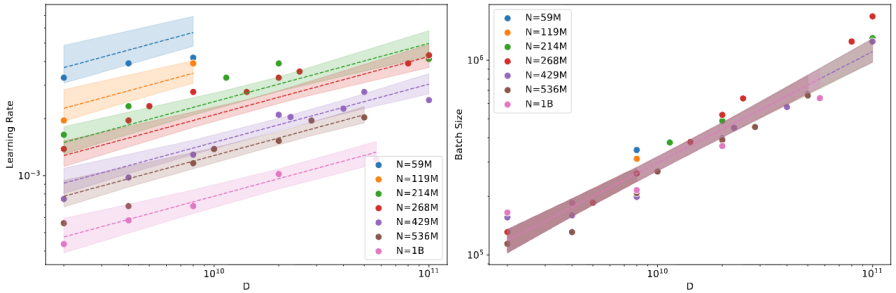
编者自学任务

写出一个“待固定/待拟合/待验证”实验记录：固定tokenizer、数据混合、宽深变化规则；拟合batch与基准η或明确μP映射；选N,D网格并设计调度；验证一个未见规模。这样才能把本页总结转成行动，而不是只记模型名称。

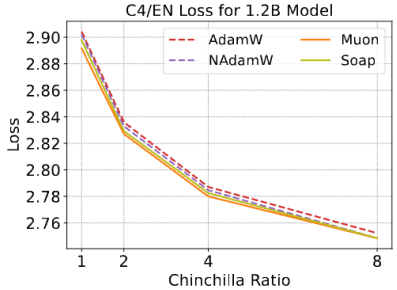
本节参考（完整书目见讲义末尾）：[slides]

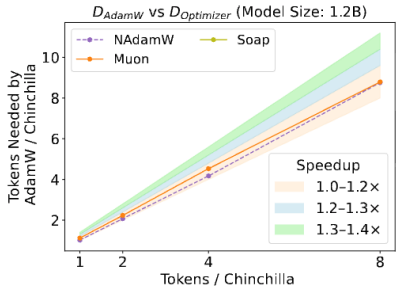
Optimizer scaling

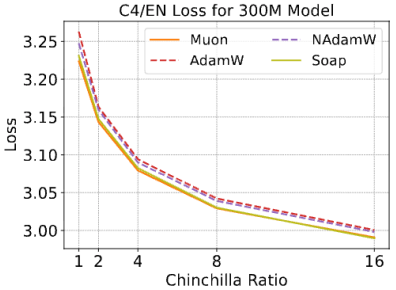
Optimizers choices / tuning can be tricky and scale sensitive



How should we pick different optimizers?







StepFun scaling law study

Large scale scaling law study from StepFun



Predictable Scale: Part I, Step Law – Optimal Hyperparameter Scaling Law in Large Language Model Pre-training

Houyi Li[*] StepFun, Fudan University

Wenzhen Zheng[*] StepFun

Qiufeng Wang StepFun

Hanshan Zhang StepFun

Zili Wang StepFun

Shijie Xuyang StepFun, Fudan University

YuanTao Fan StepFun

Zhenyu Ding Xi'an Jiaotong University

Haoying Wang Xi'an Jiaotong University

Ning Ding Xi'an Jiaotong University

Shuigeng Zhou Fudan University

Xiangyu Zhang StepFun, Megvii Technology

Daxin Jiang StepFun

Core question: how do we set LR / batch params as we scale? (Deepseek / qwen approach)

Core question – scaling rates on LR and batch

What are the right variables / functional form?

Name	Data Recipe	Model Sparsity	Learning Rate	Batch Size	Relative Error
OpenAI Law [20]	✘	✘	$3.239 * 10^{-3} + -1.395 * 10^{-4} log(N)$	$2e18\mathcal{L}^{-4.76190}$	9.51‰
Microsoft Law [2]	✘	✘	$1.3192e^{-5} N^{-0.23} D^{-0.32}$	-	9.25‰
DeepSeek Law [6]	✘	✘	$0.3188C^{-0.1250}$	$0.2920C^{0.3271}$	9.26‰
Porian Law [26]	✘	✘	$3.7N^{-0.36}$	$0.7576N^{0.703}$	3.71‰
MiniCPM Law [18]	✘	✘	-	$\frac{2e18}{L^{6.24}}$	-
MeiTuan Law [36]	✘	✔	$\lambda\mathcal{L}^{-\alpha}$	$\lambda_B\mathcal{L}^{-\alpha_B^{-1}}$	-
Ours (Step Law)	✔	✔	$1.79N^{-0.713} D^{0.307}$	$0.58D^{0.571}$	**0.94‰**

Different views:

Critical batch: batch as a function of loss (OpenAI)

Compute power law: poly function of compute (DeepSeek)

.. Or something else?

第 11 讲 · 原页 31–33 · 中文讲解

StepFun 的问题：学习率究竟是哪些变量的函数

从不同坐标系看同一训练问题

原页31回到优化器与超参数，32引入StepFun研究，33并列不同文献关系式。Kaplan式临界batch常以loss为自变量，DeepSeek式以compute为自变量，StepFun尝试直接以模型N、数据D为自变量。它们回答的问题不完全相同：给定训练进度的并行效率、沿某条最优路径的资源关系、固定N和D下的终点调参，不能只比指数大小就判谁正确。

编者推导：不同方向的变化不矛盾

写作η=kN^a D^b。固定N而增加D时，看的是b；沿N∝C^p、D∝C^(1−p)的路径，看的是ap+b(1−p)。用Step Law报告的a=−0.713、b=0.307作示例，若p=0.5，则η∝C^(−0.203)。所以“固定模型、数据越多最佳η越大”与“沿模型和数据同时扩大的路径、最佳η越小”可以同时成立。不能用一个方向的结论反驳另一个方向。

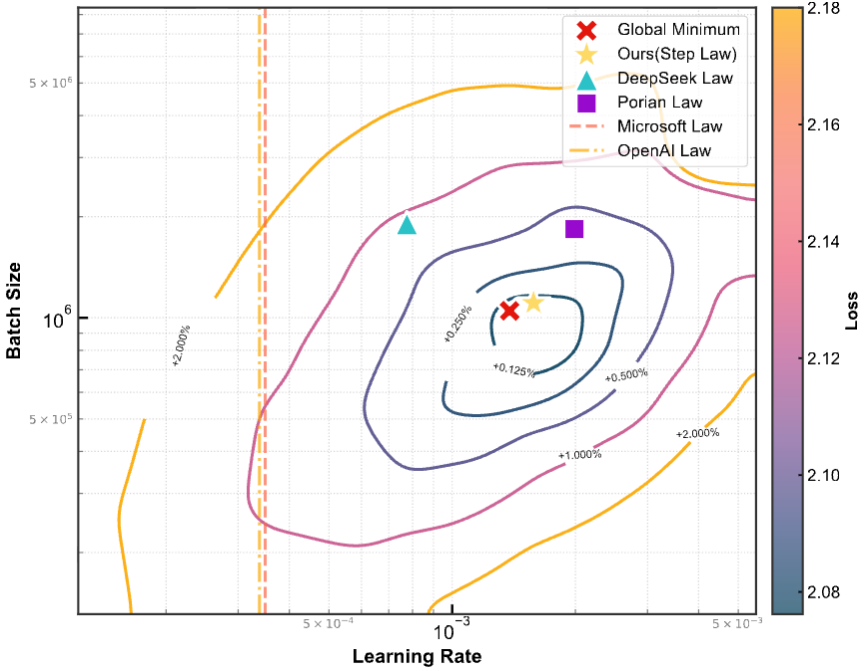
边界

原页表格中的经验函数都绑定各自调度、优化器和测量协议。把N或D改单位会改系数，沿不同路径会改观测指数。需要先明确希望预测的训练族，再选择函数形式，而非挑一条看起来最漂亮的拟合。

本节参考（完整书目见讲义末尾）：[slides] · [step]

The approach: purely empirical – grid search the space

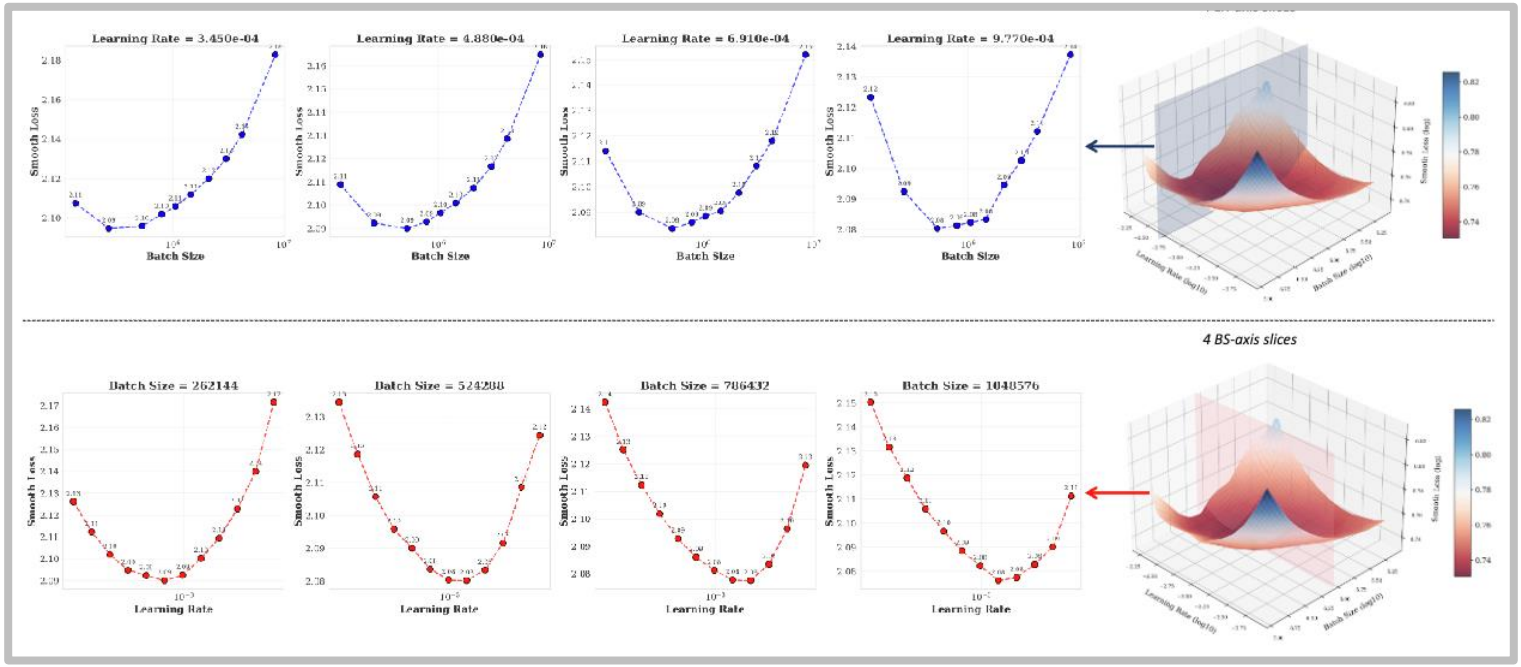
Much like the DeepSeek paper – train models to try to map out the hparam space



Model	N	D	d_{model}	d_{ff}	N_{head}	N_{layer}
1	2.15×10^8	1.14×10^{10}	960	9368	15	7
2	4.29×10^8	5.00×10^{10}	1280	9472	10	10
3	2.68×10^8	8.00×10^{10}	1024	9552	16	8
4	4.29×10^8	8.00×10^9	1280	9472	10	10
5	1.07×10^9	2.00×10^{10}	2048	8192	16	16
6	5.37×10^8	1.00×10^{10}	1280	9048	10	13
7	2.15×10^8	4.00×10^9	960	9368	15	7
8	2.68×10^8	5.00×10^9	1024	9552	16	8
9	2.68×10^8	1.42×10^{10}	1024	9552	16	8
10	1.07×10^9	5.69×10^{10}	2048	8192	16	16
11	2.15×10^8	1.00×10^{11}	960	9368	15	7
12	4.29×10^8	2.27×10^{10}	1280	9472	10	10
13	5.37×10^8	2.84×10^{10}	1280	9048	10	13
14	2.15×10^8	2.00×10^{10}	960	9368	15	7
15	4.29×10^8	4.00×10^{10}	1280	9472	10	10
16	2.68×10^8	2.50×10^{10}	1024	9552	16	8
17	5.37×10^8	5.00×10^{10}	1280	9048	10	13
18	1.07×10^9	1.00×10^{11}	2048	8192	16	16

Table 5: **Dense Model Configuration.**

Observation 1: loss over batch/LR are convex



For pre-training losses, minimizers for LR/batch can be cleanly identified

第 11 讲 · 原页 34–35 · 中文讲解

网格搜索的曲面：有盆地不等于神经网络是凸的

原页34的实验点是什么

横轴学习率、纵轴batch，每个点代表一次按该配置完成的训练；等高线把最终loss相同的位置连接起来。右侧模型配置表说明在多个模型规模重复搜索。一个loss点已经包含整段随机优化过程，横轴不是网络权重。搜索网格是否包住谷底、是否有足够分辨率、终点调度是否一致，决定了“最佳超参数”是否可信。

原页35的凸性要局部理解

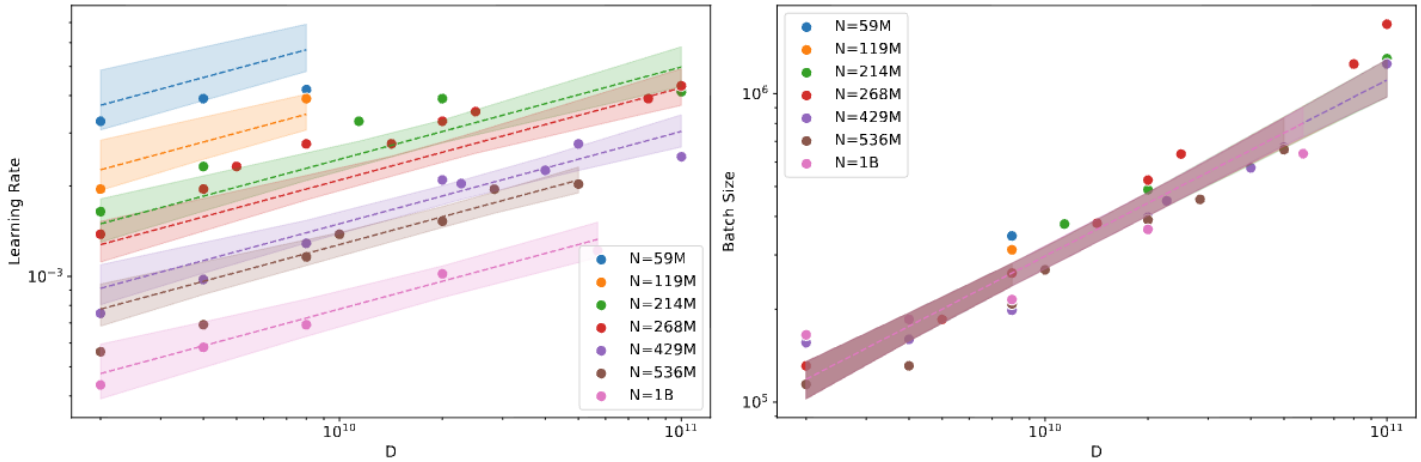
各剖面呈U形，三维图出现较平滑的盆地。这是有限实验区域内的经验形状，不是证明神经网络损失对所有权重全局凸，也不保证超参数空间在所有尺度都只有一个谷底。拟合曲面看起来平滑还可能来自所选回归形式。谷底很平时选稳健区间常比报告很多位小数的最优点更合理。

编者例：同时搜索的必要性

若在B=1M时η=0.002最好，而在B=4M时η=0.004更好，只固定η=0.002去比较所有batch，会把4M误判得过差。可先做较粗的二维网格定位谷底，再在邻域加密；保存原始点和失败点，避免只画平滑曲线遮蔽边界。重复种子可帮助判断两个谷底候选的微小loss差是否只是噪声。

本节参考（完整书目见讲义末尾）：[slides]

Observation 2: scaling trends



(a) Scaling laws with dataset size for different number of parameters

For chinchilla style joint scaling: batch is primarily dependent on dataset size.

They also find higher optimal LR with D (for fixed M), but this is likely more fragile if swapping to WSD – see e.g. InternLM scaling law paper (Zhou+ 2026)

Observation 3 (?) robustness

Generalization to MoEs

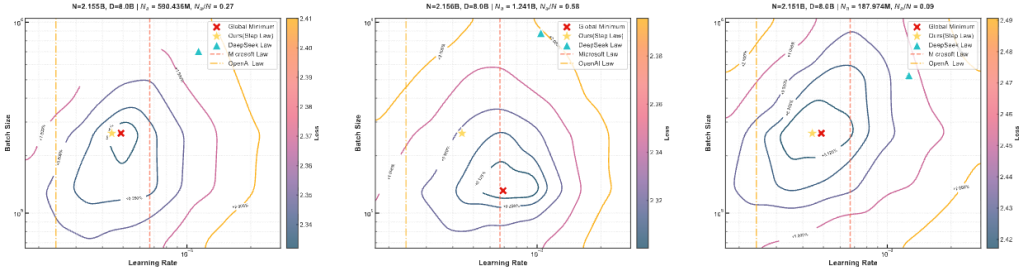
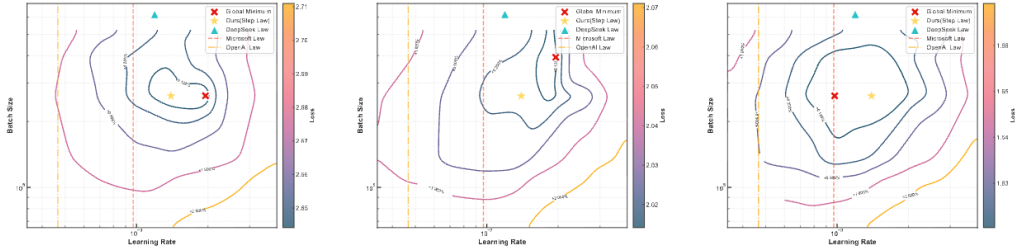


Figure 7: **Validation loss landscapes of MoE models under varying sparsity ratios (N_a/N).** Left: Low sparsity ($N_a/N = 0.27$). Middle: Medium sparsity ($N_a/N = 0.58$). Right: Medium sparsity at D=8.0B. Our method consistently approximates global minima across sparsity regimes.

Generalization to other datasets



(a) Bilingual Corpus (b) Code Integration (c) Code-Dominante

第 11 讲 · 原页 36–37 · 中文讲解

数据量主导 batch 的趋势与迁移范围

原页36：两张图分别保持什么不变

左图每种颜色是固定N，随D增大最优η上升；同D下较大模型通常需要较低η。右图各模型大小的batch点大体聚到随D增长的一条带上，支持“在此协议中batch主要由D解释”。Step Law以B∝D^0.571作经验概括：D翻4倍，对应B约翻2.21倍，更新步数D/B约翻1.81倍。它没有说batch与模型在任何情况下完全无关。

为什么更换WSD可能改变结论

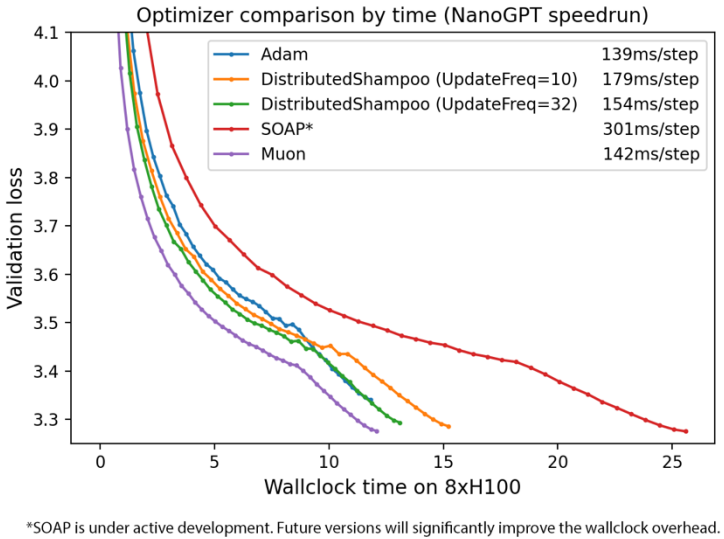
cosine的形状由训练终点决定，而WSD把大部分前缀固定下来。增大D时，两种协议改变早期与中期学习率的方式不同，所找到的最佳峰值η也可能不同。原页特别提醒换成WSD后η随D的规律可能更脆弱；这是一项方法边界，不能一面更换调度一面仍声称沿用同一经验拟合。

原页37：泛化要看新实验是否仍对齐

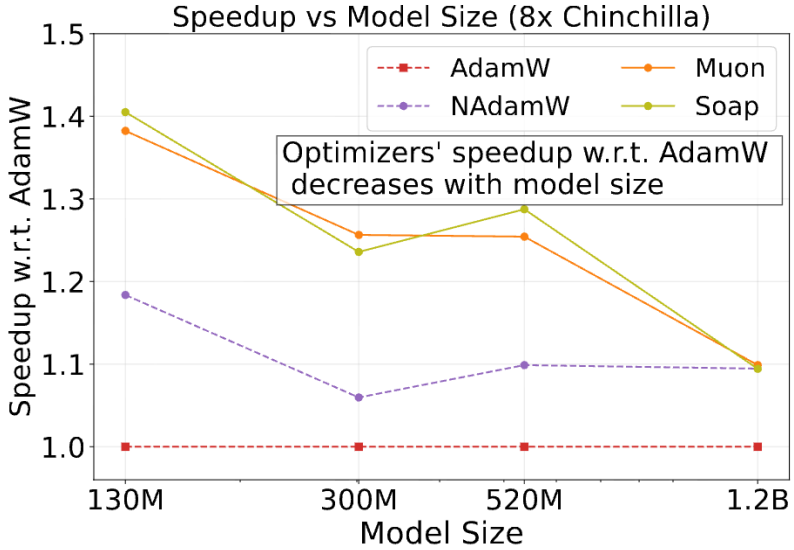
上排以MoE稀疏度变化作检验，下排换数据集，等高线展示预测点相对实测低谷的位置。预测能落入若干新场景的低谷是迁移证据，但仍只覆盖测过的架构、数据和训练协议。编者建议：在自己配方上拿一小部分预算复核两个尺度，至少比较预测点及其学习率/batch相邻点，再扩大训练。

本节参考（完整书目见讲义末尾）：[slides] · [step]

Optimizers and scale



*SOAP is under active development. Future versions will significantly improve the wallclock overhead.



Optimization is a core part of LLMs (but also tricky, due to scale dependence!)

Problem 1 – hyper tuning is often off..

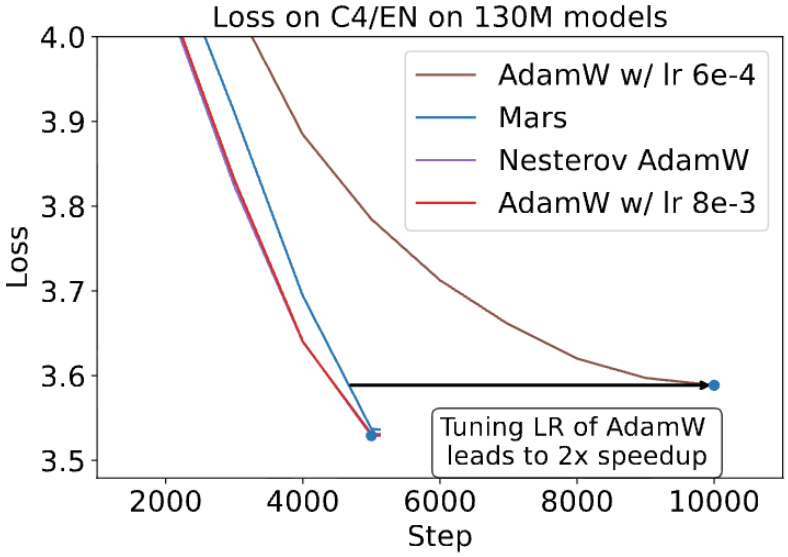
Fantastic Pretraining Optimizers and Where to Find Them

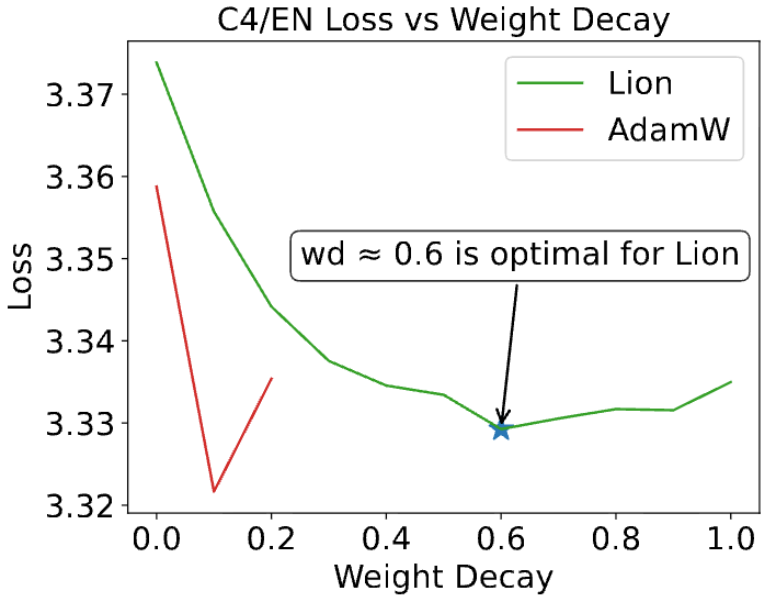
Kaiyue Wen
Stanford University
kaiyuew@stanford.edu

David Hall
Stanford University
dlwh@cs.stanford.edu

Tengyu Ma
Stanford University

Percy Liang
Stanford University

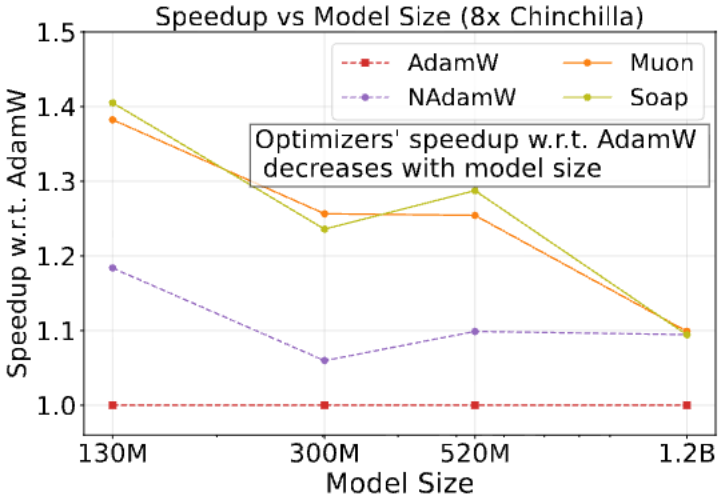


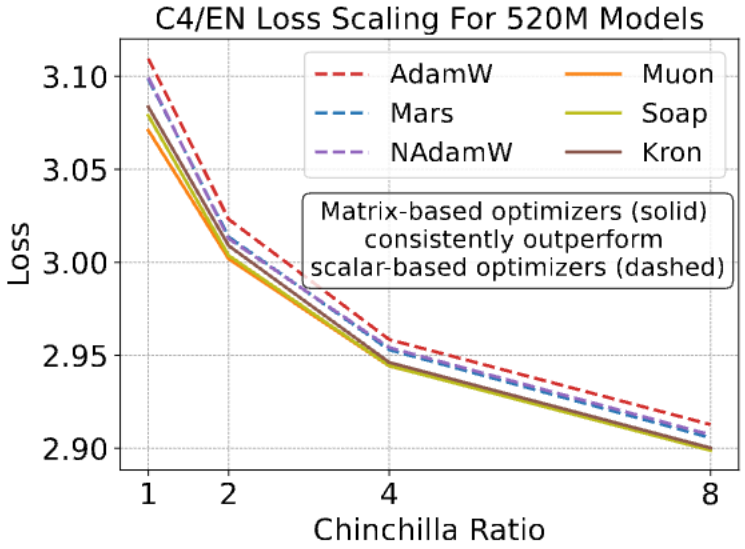


Different optimizers can require different hyperparameters!

(*and* likely have different optimal hyperparameter scaling)

Problem 2 – fairly significant scale dependence





General algorithm development note – *always* check scaling with respect to compute and chinchilla ratios. These are often major confounders to performance!

第 11 讲 · 原页 38–40 · 中文讲解

优化器比较：调参公平与规模效应

原页38–39：默认超参数并不公平

原页38的小模型训练曲线中某些优化器明显更快，右图却显示加速比随模型规模下降。原页39再揭示一个原因：调好AdamW学习率会改善基线，Lion的合适weight decay又可能与AdamW不同。若只认真调新方法、给基线一个默认值，比较混入了调参投入差。反过来，把AdamW的最优超参数直接复制给另一算法，也会低估后者。

原页40：模型规模与训练长度都要控制

图中横轴的Chinchilla ratio是相对该实验采用的计算最优tokens/参数比再归一化，并非直接的D/N。一个方法在1倍训练长度领先，训练到8倍时优势可能缩小；在130M上的优势也未必保持到1.2B。应在多个规模与多个D/N上比较完成衰减的终点，而不是只拿中途checkpoint挑赢家。

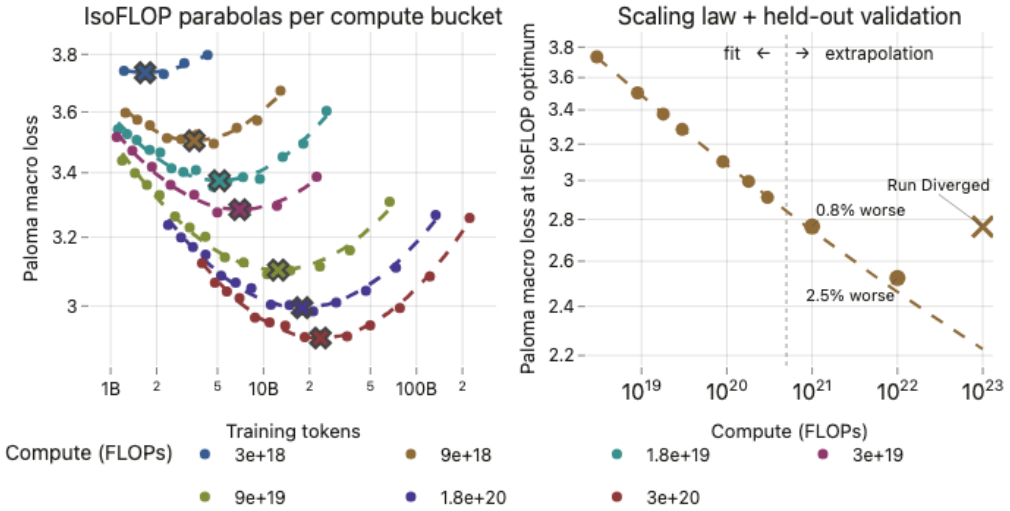
编者例：把加速比说完整

若达到同一loss，A要100M tokens而B要80M，则token等效加速为1.25倍。若B每步时间又是A的1.5倍且batch相同，总时间约为0.8×1.5=1.2倍，反而更慢。论文图的token等效收益不能直接译为GPU小时收益；须说明同loss、同tokens、同FLOPs还是同墙钟。矩阵优化器可能每步更贵，硬件实现也影响实际选择。

本节参考（完整书目见讲义末尾）：[slides] · [optimizers]

Problem 2.5 – establishing scaling is nontrivial!

Sometimes, a good looking scaling can blow up



[From https://oa.williamheld.com/blog/delphi/]

Cautious AdamC + Sqrt batch-size scaling of learning rates
(Fixed with some more careful parametrization / scaling / optimizer changes)

第 11 讲 · 原页 41–41 · 中文讲解

外推失败是配方失效的证据，不应藏进拟合曲线

原图提供的警示

左侧小预算IsoFLOP曲线看似规律，右侧外推验证在更大预算偏离甚至出现训练问题。课件举Cautious AdamC与学习率按batch平方根缩放的组合，说明小规模好看的趋势可能在新尺度崩溃，并注明后来通过更细致的参数化、缩放和优化器调整处理。这里仅依原课件讲解；页中博客地址本次返回403，未把未读到的博客细节加入正文。

编者诊断顺序

先确认发散、损失异常和拟合误差不是同一种现象：数值发散需查梯度、激活、更新范数与精度；稳定但预测偏差需查数据、参数口径、函数形式与调度；小差异需看随机波动。补一个中间预算可以区分突然不稳定与平滑弯曲。不要把失败的大模型点删掉后继续宣布外推有效；对失效范围的记录本身就是缩放研究的重要结果。

本节参考（完整书目见讲义末尾）：[slides]

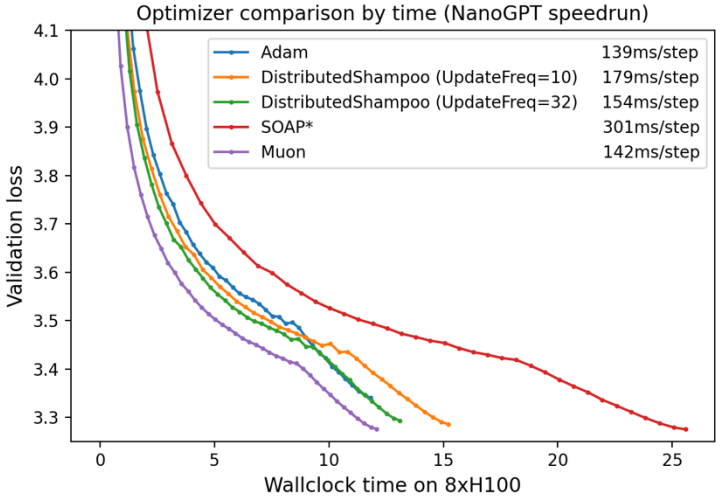
A few slides on muon..

Muon:

Algorithm 2 Muon

Require: Learning rate η, momentum μ

1: Initialize $B_0 \leftarrow 0$
2: **for** $t = 1, \ldots$ **do**
3: Compute gradient $G_t \leftarrow \nabla_\theta \mathcal{L}_t(\theta_{t-1})$
4: $B_t \leftarrow \mu B_{t-1} + G_t$
5: $O_t \leftarrow \text{NewtonSchulz5}(B_t)$
6: Update parameters $\theta_t \leftarrow \theta_{t-1} - \eta O_t$
7: **end for**
8: **return** θ_t

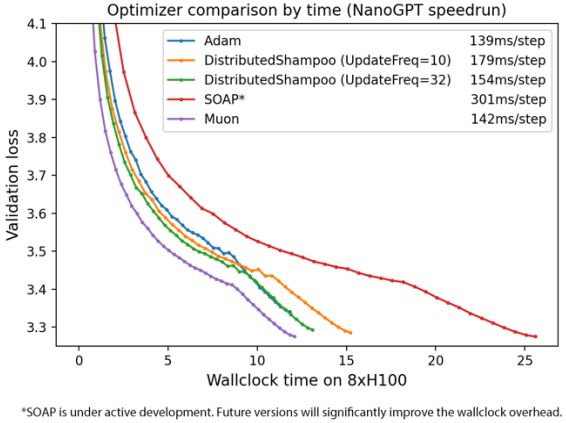


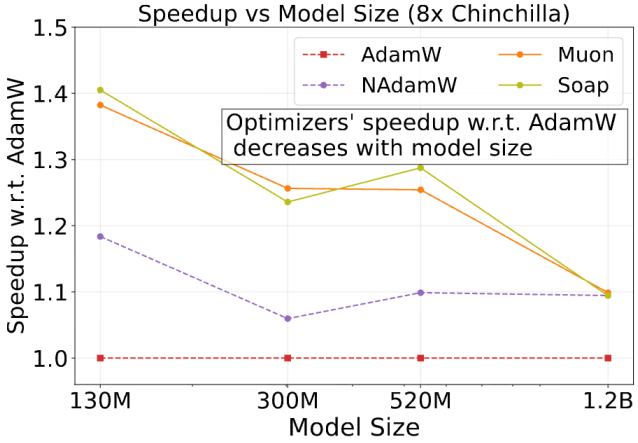
*SOAP is under active development. Future versions will significantly improve the wallclock overhead.

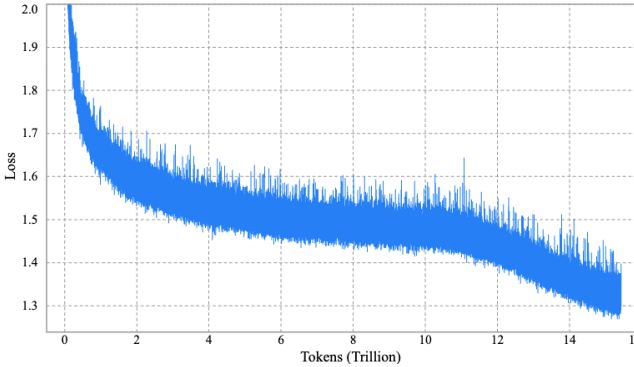
Optimizer for ‘matrix valued’ parameters.

NewtonSchultz (approximately) orthogonalizes the matrix $B_t = USV^\top \rightarrow UV^\top$

Muon and scaling







NanoGPT speedrun (very small!)

Scaling study

Kimi K2

Scaling gains are tricky to measure, but clearly muon ‘works’ at scale

第 11 讲 · 原页 42–43 · 中文讲解

Muon：对矩阵更新做近似正交化

原页42算法的线性代数含义

原算法先将梯度G_t累积为动量矩阵B_t，再通过Newton–Schulz迭代得到用于更新的矩阵。若$B=U\Sigma V^T$，理想化操作把非零奇异值的大小换成1，得到相应的UV^T方向；它保留奇异向量方向、改变各方向的相对尺度。对矩形矩阵，“正交”通常指行或列方向上的性质；秩亏情况需按非零奇异子空间理解。实际有限次迭代、归一化和缩放并不等于精确SVD。

编者小矩阵例

取$B=\mathrm{diag}(3,1)$，普通动量更新沿两个坐标大小比为3:1，而理想极分解方向$UV^T=\mathrm{diag}(1,1)$，变成1:1；再乘学习率才得到步长。由此可见Muon不是简单把整个梯度除以一个范数，也不同于对每个元素做Adam式缩放。对向量增益、偏置或embedding等参数，应按实现指定另外的处理，不能看到“优化器”就假定所有张量都用同一矩阵操作。

原页43：能大规模运行与加速多少是两件事

左图小型NanoGPT、中图多规模对照、右图Kimi K2训练曲线组成不同层次证据：可以有效优化，部分比较有收益，在大模型中确实有应用。它们没有自动构成同一设置下的大规模受控加速证明。要报告相对基线优势仍需前几页的公平调参、相同目标和资源口径。

本节参考（完整书目见讲义末尾）：[slides]

Maximum update parametrization – in depth

Recall – the maximum update parametrization makes appealing claims

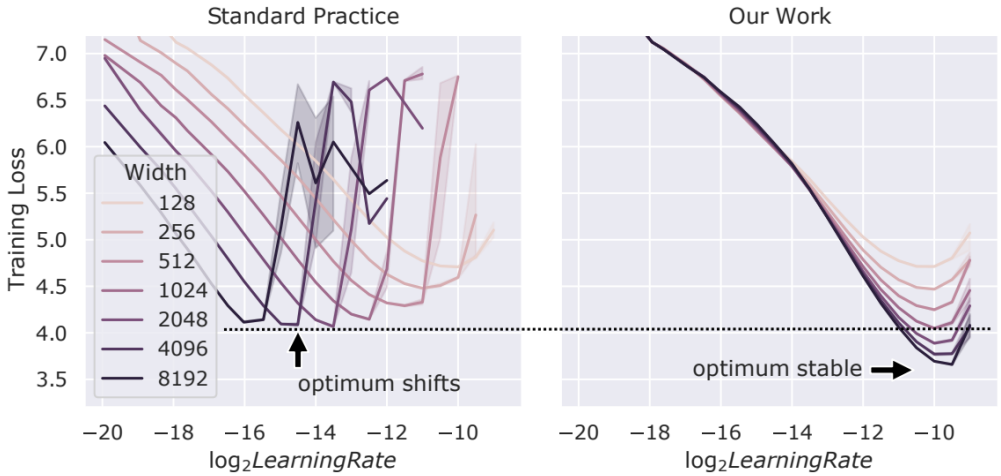


Table 2. μP function for a model M' that is r times the widths of M. If a parameter tensor has 2 dimensions that goes infinite when the model width goes infinite, it is "matrix-like" (*e.g.,* a fully-connected hidden layer); if the number is 1 or 0, it belongs to the "others" class. Note that embedding layers are "others". "Output" means the layer that maps an infinite dimension to a finite dimension, which is the word decoding layer (lm_head) in Transformers. A multiplier is a constant multiplied by a parameter tensor, which has a similar function to softmax temperature.

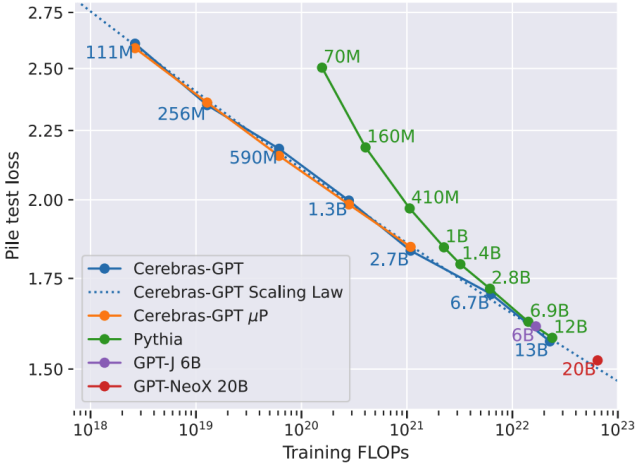
Hyperparameter (weight)	M	$M' \sim r$
AdamW learning rate (matrix-like)	l	l/r
AdamW learning rate (others)	l	l
Initialization variance (matrix-like)	σ	σ/r
Initialization variance (others)	σ	σ
Multiplier (output)	τ	τ/r
Multiplier (others)	τ	τ

Scale-invariant hyperparameter tuning would be very nice.

How does it work, and does it work in practice?

CerebrasGPT

CerebrasGPT – 0.1 to 13B models trained with the Chinchilla recipe.



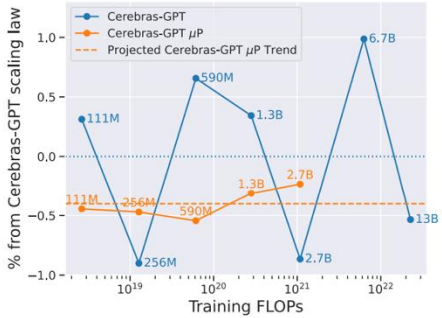


Figure 5: Percentage loss increase relative to Cerebras-GPT scaling law plotted against training FLOPs.

We train a set of Cerebras-GPT models using μP. We follow the μTransfer approach by first tuning hyperparameters for a small, 40M parameter μP model. Then, we transfer the hyperparameters along our μP scaling law up to a 2.7B parameter model. μP requires small changes to our baseline Cerebras-GPT models, including adding element-wise activation tensor scaling, adjusting initializers for affected layers, and adding layer-wise learning rates scaling to certain layers. We discuss the benefits we see with μP in Section 3.3. Refer to Appendix G for our tips to implement μP and our hyperparameter tuning notes.

Core finding – using muP parametrization makes scaling more stable

第 11 讲 · 原页 44–45 · 中文讲解

μP 的目标：让小模型调好的基准超参数有用

原页44：迁移的是坐标系中的最佳区域

standard practice图中不同宽度的最优学习率横向移动，μP图中谷底更对齐。μP即maximal update parametrization，关心扩大宽度时初始化、前向缩放和更新的量级。它不是另一个优化器，也不是把所有参数学习率强行设为同一值；其目标是选好缩放规则后，基准η等常数能从代理模型迁移。

原页45：CerebrasGPT的经验支持

图中μP系列的损失—规模趋势更稳定，偏离拟合曲线的波动较小。它说明规范参数化可能让训练和外推更可预测；不证明μP在所有数据、优化器、深度上必然给最低loss。只比较一条拟合线的平滑程度也不够，应看相同调参投入和外推误差。后面先用简化网络推导量级，再回到Transformer实验检查哪些真实组件破坏迁移。

本节参考（完整书目见讲义末尾）：[slides]

What is muP, anyway?



(this is a very accessible 'muP for babies' paper)

muP is based off the following assertion. As a function of the width of the network n_l..

A1: The activations at initialization should remain $\Theta(1)$
A2: After one gradient step, the change in activation should be $\Theta(1)$

Note: if individual activations are $\Theta(1)$, then the norm should be $\Theta\left(\sqrt{n_l}\right)$

第 11 讲 · 原页 46–46 · 中文讲解

两个不变量：激活不爆炸，特征变化不消失

符号准备与**A1**、**A2**

第l层宽度n_l，激活向量$h_l \in R^{n_l}$。A1要求初始化时典型坐标量级Θ(1)；A2要求一次更新后的典型坐标变化也为Θ(1)。Θ表示随宽度增长既有上界又有同阶非零下界，常数可以很小且依赖基准学习率；不表示每个坐标严格等于1。以$RMS(h)=\|h\|_2/\sqrt{n}$衡量典型大小，A1等价于RMS保持常数量级，即$\|h\|_2=\Theta(\sqrt{n})$，A2同理。

编者例与参数化边界

宽度从256到1024，若每坐标RMS约1，则向量范数从约16增到32，这是正常缩放，不是激活爆炸。若更新RMS从0.01随宽度不断趋零，输出仍可能被训练改变，但内部表征的学习在相应宽度极限中变弱。这里固定深度及其他条件讨论宽度；不能据此保证无限加深网络也稳定。one-hot输入范数为1，不符合“密集输入范数√n”的同一假设，embedding必须单独处理。

课堂补充 · **01:00:46–01:02:29**

讲者将这两个条件与feature learning联系起来，并对比神经切线核式极限下内部激活变化随宽度消失的情形。这个对比用于说明μP希望保留非平凡特征学习，不是宣称NTK无法学习输出或在任何任务上表现更差。

本节参考（完整书目见讲义末尾）：[slides] · [spectral] · [captions]

Deriving muP (condition A1)

Suppose that we have a simple, deep linear network ($h_l = W_l h_{l-1}$) and we init $W_l \sim N\left(0, \sigma^2 I_{n_l \times n_{l-1}}\right)$ then by basic matrix concentration $\|W_l\|_* \to \sigma(\sqrt{n_{l-1}} + \sqrt{n_l})$ and,

$$\|h_l\|_2 \approx \|W_l\|_* \|h_{l-1}\|_2$$

Now let's pick $\sigma = \frac{\sqrt{n_l}}{\sqrt{n_{l-1}}}\left(\sqrt{n_l} + \sqrt{n_{l-1}}\right)^{-1} = \Theta\left(\frac{1}{\sqrt{n_{l-1}}} \min\left(1, \sqrt{\frac{n_l}{n_{l-1}}}\right)\right)$. What happens?

Inductive assumption- $\|h_{l-1}\|_2 = \Theta\left(\sqrt{n_{l-1}}\right)$

Inductive case - $\|W_l\|_* \to \sigma\left(\sqrt{n_{l-1}} + \sqrt{n_l}\right) = \frac{\sqrt{n_l}}{\sqrt{n_{l-1}}}$

$$\|h_l\|_2 = \sqrt{n_l} + o(\sqrt{n_l})$$

[Comments – this is a kind of 'worst case' derivation – the ≈ is an upper bound]

第 11 讲 · 原页 47–47 · 中文讲解

A1 推导：谱范数控制能告诉我们什么

先把形状和范数分清

编者逐步解释：令m=n_{l−1}是fanin，n=n_l是fanout，W为n×m，h为m维，Wh为n维。此处‖W‖_*专指谱范数即最大奇异值，不是另一些文献用星号表示的核范数；‖W‖_F为所有元素平方和的平方根。永远有‖Wh‖₂≤‖W‖_*‖h‖₂。若希望输入范数Θ(√m)时输出最多同阶√n，一个自然的谱尺度是√(n/m)。

从随机矩阵到初始化尺度

独立均值0、标准差σ的高斯矩阵，在适当大维度条件下谱范数约σ(√m+√n)。把它设为√(n/m)，得到σ=√(n/m)/(√m+√n)。等价量级为σ=Θ[(1/√m) min(1,√(n/m))]。若n≥m，约1/√m；若n<m，约√n/m。课件标准差含平方根，不能读成1/m；后文表的variance是标准差的平方，也不能混抄。

原页简化需要补充的条件

原页底部已注明worst case upper bound。仅用谱范数上界和输入范数，不能推出‖Wh‖恰为√n，更不能推出每个方向都不衰减；若h落在W的零空间，输出就是0。特别在固定小输出维度、fanin增长的读出层，这个保守谱尺度与普通独立坐标方差保持的初始化不同。要得到Θ下界，还需非退化方向、网络结构和概率条件；本页是理解量级的启发式，不是对任意输入的完整证明。

编者数值检查

m=n=1024时，上述精确示意σ=1/64，量级写法为1/√1024=1/32，两者差一个常数并不矛盾，因为Θ忽略固定系数。m=1024、n=256时，σ=0.5/(32+16)=1/96，谱范数约0.5；乘输入范数32给输出范数上界约16。例子展示的是界与量级，不是每个随机样本的精确输出。

本节参考（完整书目见讲义末尾）：[slides] · [spectral]

Deriving muP (condition A2)

Now we need to deal with updates. Suppose we have the update ΔW_l on the weights. For SGD, on a linear layer, this looks like a rank-one loss-activation outer product.

$$\Delta W_l = -\eta_l \nabla_{h_l} \ell \; h_{l-1}^\top$$

Thus, $\|\Delta W_l h_{l-1}\|_2 = \|\Delta W_l\|_* \|h_{l-1}\|_2$. Now note that we have the update

$$\Delta \mathrm{h_l} = \mathrm{W_l} \Delta h_{l-1} + \Delta W_l (h_{l-1} + \Delta h_{l-1})$$

Assuming that the leading order terms don't cancel, we see that

- $\mathrm{W_l} \Delta h_{l-1} = \Theta(\sqrt{n_l})$ from induction assumption + condition A1 argument
- $\Delta W_l h_{l-1} = \|\Delta W_l\|_* \sqrt{n_{l-1}}$ from above, thus $\|\boldsymbol{\Delta W_l}\|_* = \boldsymbol{\Theta}\left(\frac{\sqrt{n_l}}{\sqrt{n_{l-1}}}\right)$
- $\Delta W_l \Delta h_{l-1} = O(\|\Delta W_l\|_* \sqrt{n_{l-1}})$

第 11 讲 · 原页 48–48 · 中文讲解

A2 推导：更新矩阵与更新后的特征

为什么单样本SGD更新是外积

线性层h_new=W h，令g=∇_{h_new}ℓ为n维向量。链式法则给 ∇ _Wℓ=g h^{T}，因此ΔW=−ηg h^{T}，为n×m的秩至多1矩阵。其谱范数等于η‖g‖₂‖h‖₂，且ΔW h=−ηg‖h‖₂²，所以在这个特殊方向上‖ΔW h‖₂=‖ΔW‖_*‖h‖₂。多样本batch的梯度是外积之和，Adam还会逐元素预处理，此等号一般不能直接照搬。

展开总变化，不要遗漏交叉项

上一层也变为h+Δh，本层更新后为(W+ΔW)(h+Δh)。减去Wh得到Δh_new=WΔh+ΔWh+ΔWΔh。假设上一层更新范数Θ(√m)，希望各项不超过√n且有非退化主导项，便要求更新矩阵谱范数量级‖ΔW‖_*=Θ(√(n/m))。其中上界控制避免爆炸；要得到整体Θ还需各项不精确抵消且至少一个项有相应下界。原页“无抵消”假设并不能把所有上界自动变成等式。

编者手算

取h=(1,1)^{T}，g=(1,−1)^{T}，η=0.1，则ΔW=[[-0.1,-0.1],[0.1,0.1]]。谱范数0.2，ΔWh=(−0.2,0.2)^{T}，范数约0.2828，恰等于0.2√2。换成输入(1,−1)^{T}则输出为0。这同时解释单样本等号的来历和把它推广到任意方向的错误。

本节参考（完整书目见讲义末尾）：[slides] · [spectral]

Deriving muP (condition A2) part 2

Recall –the key is to pick LR such that $\|\Delta W_l\|_* \sqrt{n_{l-1}} = \Theta\left(\sqrt{n_l}\right)$. How can we do that?

Suppose that the loss update *also* scales O(1). Then we can write down..

$$\Delta \ell \approx \Theta\left(\langle \Delta W_l, \nabla_{W_l} \ell \rangle\right) = \Theta\left(\|\Delta W_l\|_F \left\|\nabla_{W_l} \ell\right\|_F\right) = \Theta\left(\|\Delta W_l\|_* \left\|\nabla_{W_l} \ell\right\|_*\right)$$

Where we use the fact that $\Delta W_l = -\eta \nabla_{W_l} \ell$ in standard SGD updates.

Now plug in $\Delta \ell = O(1), \|\Delta W_l\|_* = \Theta\left(\frac{\sqrt{n_l}}{\sqrt{n_{l-1}}}\right)$ to get that $\left\|\nabla_{W_l} \ell\right\|_* = \Theta\left(\frac{\sqrt{n_{l-1}}}{\sqrt{n_l}}\right)$

Finally, from the previous slide, recall that $\Delta W_l = -\eta_l \nabla_{h_l} \ell \; h_{l-1}^\top$ and thus

$$\eta_l = \Theta\left(\frac{n_l}{n_{l-1}}\right)$$

[with Adam, $\|\Delta W_l\|_* \sqrt{n_{l-1}} = \Theta\left(\sqrt{\eta_l}\right)$]

第 11 讲 · 原页 49–49 · 中文讲解

把更新尺度换成学习率：补齐非退化假设

编者推导：SGD的三步量级计算

令G=∇_Wℓ。在单样本秩一、SGD方向ΔW=−ηG且一阶项主导的条件下，该层对损失的一阶贡献为⟨G,ΔW⟩_F=−η‖G‖_F²，其幅度为‖ΔW‖_F‖G‖_F。秩一时Frobenius范数与谱范数相等。若额外要求该层非退化的损失变化幅度Θ(1)，并已有‖ΔW‖_*=Θ(√(n/m))，才可推出‖G‖_*=Θ(√(m/n))。最后η=‖ΔW‖_*/‖G‖_*=Θ(n/m)。

原页O(1)不足以独自推出Θ

O(1)只是不发散，也容许变化趋0。原页从Δℓ=O(1)直接写出梯度Θ的跳步，需要以上非退化幅度、一阶主导和有效秩条件。损失下降本身带负号，这里只比较其绝对幅度。若全网多个参数块一起更新，应逐块解释其贡献；不能把总损失的有界性自动当作每块贡献的严格下界。多样本梯度的秩若随宽度增长，‖G‖_F与‖G‖_*也不再同阶。

Adam为什么不同

Adam按梯度二阶矩做逐元素归一化，不能继续使用ΔW=−ηG。编者直觉：在单样本的符号式简化中，归一化更新像sign(g)sign(h)^{T}，每项约η，谱范数约η√(nm)。令其等于√(n/m)，得η∝1/m。真实Adam有动量、epsilon、batch和相关性，需完整参数化规则；这个计算说明为何SGD与Adam的宽度规则不同，而非对任意Adam状态的精确证明。

本节参考（完整书目见讲义末尾）：[slides] · [spectral]

muP mini recap..

So, what is (baby) muP about? Controlling activations (and changes) via W and ΔW

Initialization (stdev): Set to $\Theta\left(\frac{1}{\sqrt{n_{l-1}}}\min\left(1, \sqrt{\frac{n_l}{n_{l-1}}}\right)\right)$

Learning rates: Set to $\frac{n_l}{n_{l-1}}$ (for Adam $\frac{1}{n_{l-1}}$)

Compared to 'standard' parametrizations – these set

Initialization: Set to $\frac{1}{\sqrt{n_{l-1}}}$

Learning rates: Set to $\Theta(1)$

Differences – LR changes for Adam, also init diffs when fanout n_l < fanin

第 11 讲 · 原页 50–50 · 中文讲解

μP 小结：量级规则不等于一个通用常数

将原表翻成可操作的对应

对本节简化线性层，μP初始化标准差按(1/√m)min(1,√(n/m))，SGD学习率按n/m，Adam按1/m；原页SP对照则是标准差1/√m、学习率Θ(1)。SP指standard parametrization，在这里是所比较的基准规则，不意味着所有软件默认设置完全一样。若隐藏层为等宽方阵，μP与SP的初始化可以同阶；突出差别可能出现在Adam实际η、收缩层和输出层。

编者例：同一基准η，不同实际步长

把隐藏宽度从512增到2048，等宽矩阵初始化标准差约减半；SGD的n/m仍为1，而Adam实际学习率约除4。若输入层输入维度固定d、输出宽度n扩大，n/m的变化又不同；若输出维度固定k，读出层标准差为Θ(√k/m)，随隐藏宽度约1/m。因此必须把输入、隐藏、输出分组。迁移成功是这些规则实施后基准系数的经验稳定，不是“网络大四倍，所有层都用同一个学习率”。

检查自己有没有混淆

宽度倍率不是参数量倍率；标准差不是方差；谱范数不是Frobenius范数；SGD规则不是Adam规则；基准η不是每组实际η。只要这五对概念分开，前面看似相互矛盾的“学习率保持不变”和“学习率随宽度下降”就能一致理解。

本节参考（完整书目见讲义末尾）：[slides] · [spectral]

Preprint

A Large-Scale Exploration of μ-Transfer

Lucas Dax Lingle
lucasdaxlingle@gmail.com

Deeper dive into muP

Recall – muP is a scaling procedure for hyperparams (as a function of width)

Param	Init Variance (Θ)	Adam LR (Θ)	Init Variance (Exact)	Adam LR (Exact)
$\mathbf{W}^{E}$	1	1	1	α
$\mathbf{W}^{AQ}$	$1/M$	$1/M$	$1/M$	$\alpha P/M$
$\mathbf{W}^{AK}$	$1/M$	$1/M$	$1/M$	$\alpha P/M$
$\mathbf{W}^{AV}$	$1/M$	$1/M$	$1/M$	$\alpha P/M$
$\mathbf{W}^{AO}$	$1/(HD)$	$1/(HD)$	$1/M$	$\alpha P/M$
$\mathbf{W}^{FI}$	$1/M$	$1/M$	$1/M$	$\alpha P/M$
$\mathbf{W}^{FO}$	$1/F$	$1/F$	$0.25/M$	$\alpha P/M$
$\mathbf{W}^{U}$	$1/M^2$	$1/M$	$1/M^2$	$\alpha P/M$

Embedding

Attention params

Input/output MLP MM

Softmax linear

Table 2: μP scaling rules for transformers; a rule for attention scale is detailed in text below.

In addition, μP uses an attention scale of $\tau^{-1} = \Theta(1/D)$ instead of the usual $\tau^{-1} = 1/\sqrt{D}$. For simplicity, we use $\tau^{-1} = 1/D$, since in preliminary experiments we observed only a small improvement from using smaller multiples of $1/D$. Note that for D fixed across model widths M, any constant $\tau^{-1} \neq 0$ technically complies with μP (Yang et al., 2021) but in the experiments, τ^{-1} will be shown to have a major impact on performance and transfer.

第 11 讲 · 原页 51–51 · 中文讲解

Transformer 参数化：表中每一行对应不同角色

先翻译符号，再抄缩放规则

本页原表改用M表示模型隐藏宽度，不再是DeepSeek的FLOPs/token；H为头数，D为每头维度，F为MLP隐藏维度，P为参考宽度，α为base LR。这里的D也不再是数据tokens，阅读局部公式必须重置符号。列名Init Variance表示方差。embedding W^E的方差与实际学习率保持常数级；Q/K/V、attention输出、MLP输入/输出按各自fanin缩放；unembedding W^U方差为$1/M^2$，即标准差1/M。

为什么不能所有张量都乘同一个因子

表的Exact列对矩阵学习率采用αP/M，embedding采用α；MLP输出方差为0.25/M，而不是简单复写输入矩阵。编者例：P=128、M=512时，矩阵实际η=α/4，M=2048时为α/16；两个模型都可以扫描同一α网格。embedding对应one-hot查表，读出层对应固定词表，所以两者不同于隐藏层方阵；权重共享时还需确认所采用实现是否满足原规则。

注意力分数还有一个缩放选择

原页下方说明该研究采用QK^T/D，而常见SP用$QK^T/\sqrt{D}$。若D=64，对同一内积，前者是后者的1/8，会改变softmax尖锐度及梯度。若头维D固定、只增加头数，两者相差与宽度无关的常数，量级理论本身无法替你挑选最优常数；若D随宽度增长，渐近阶数也不同。本页表是一套具体Transformer实现，不能只摘一个1/M就宣称完整实现μP。

本节参考（完整书目见讲义末尾）：[slides] · [transfer]

Replicating muP

Q1: Does muP work as claimed? When we scale widths, is optimal LR constant?

Ablation	Width	Base LR					Transfer
		2^{-10}	2^{-8}	2^{-6}	2^{-4}	2^{-2}	
Baseline μP	128	3.846	3.743	**3.695**	3.884	4.143	✔
	512	3.114	2.993	**2.953**	3.221	3.506	
	2048	2.711	2.553	**2.511**	2.563	3.244	
Projection Biases	128	3.838	3.735	**3.705**	3.911	4.269	✔
	512	3.108	2.986	**2.947**	2.970	3.557	
	2048	2.710	2.552	**2.529**	2.672	3.418	

As shown in Table 1, the learning rates transfer reliably across model sizes under μP. Despite each model being 4x wider (and 16x larger) than the last, the smallest model's optimal base learning rate α directly predicts the optimum in our sweeps for the larger models.

What is muP robust to?

Modern LMs have many components that deviate from muP's theory

- Activations – SwiGLU and squared relu
- Batch sizes – Large / small
- Initialization variations – zero attention, etc.
- RMS norm gains
- Exotic optimizers (Lion)
- Regularizers

Which of these (if any) break muP?

第 11 讲 · 原页 52–53 · 中文讲解

复现迁移：最低损失是否落在同一列

原页**52**的正确读法

行是宽度128、512、2048，列是base LR网格。baseline μP三行最低值均在2^(−6)附近；projection biases的变体也显示相似结果。成功指小模型选中的基准η仍落在大模型较优区域，而不是三种模型loss相同。更大模型整体loss更低是另一件事。每行的最佳格点也受扫描分辨率影响，表中的勾不是对所有连续η的严格证明。

原页**53**：理论范围与经验范围分开

实际模型还有SwiGLU、平方ReLU、batch变化、零初始化、RMSNorm增益、Lion和正则化等组件。简化线性网络推导未逐项覆盖这些组件，不代表它们一定失败；需在同一迁移实验中逐项替换并测试。反之，几种组件单独通过也不保证组合通过。编者建议：先复现基准，再一次改变一个组件，记录谷底移动、最佳loss、发散边界，才能定位哪个改变影响迁移。

本节参考（完整书目见讲义末尾）：[slides] · [transfer]

What is muP not robust to? RMSnorm gain

In our arch – RMSNorm has learnable gains. This turns out to break muP

Ablation	Width	Base LR					Transfer
		2^{-10}	2^{-8}	2^{-6}	2^{-4}	2^{-2}	
Baseline μP	128	3.846	3.743	**3.695**	3.884	4.143	✔
	512	3.114	2.993	**2.953**	3.221	3.506	
	2048	2.711	2.553	**2.511**	2.563	3.244	
RMSNorm Gains (Vector)	128	3.842	3.744	3.689	**3.670**	3.681	✗
	512	3.101	2.992	2.951	**2.950**	3.412	
	2048	2.692	**2.553**	2.609	2.605	3.169	
RMSNorm Gains (Scalar)	128	3.843	3.749	3.692	**3.670**	4.471	✗
	512	3.106	3.000	2.961	**2.959**	3.515	
	2048	2.704	2.570	**2.525**	2.542	3.334	

As shown in Table 1, optimal learning rates for these models *do not* reliably transfer when using $\Theta(1)$ learning rate scaling for the gains, despite the fact that the 'coordinate size' of the features before and after RMS Normalization is $\Theta(1)$ w.r.t. width by design. In addition to the lack of transfer in these experiments, we find trainable gains harm the quality of the largest μP models when the base learning rate α is optimal. In Section 4.5, we also find that standard transformers with trainable gains underperform μP transformers without them.

But these gains can be removed with little loss of perf..

第 11 讲 · 原页 54–54 · 中文讲解

RMSNorm 可学习增益：归一化后仍可能引入尺度

机制与原表证据

RMSNorm可写为$y=g\odot x/\sqrt{(\text{mean}(x^2)+\varepsilon)}$。分母规范化x，但可学习增益g仍能改变输出尺度及反向传播；它自己的更新规则也进入参数化。原表分别测试向量gain和标量gain，两者都出现最优base LR随宽度漂移，标成迁移失败。这里讨论的是该研究实现和实验范围，不能扩大为“所有RMSNorm、所有μP都不兼容”。

编者如何定位与修复

检查gain的初始化、实际η、weight decay是否与基准不同；做有gain、固定gain、无gain的对照，并同时比较最终性能和迁移情况。课件说明去掉gain在此设置中损失不大，是一个可测试的工程选择；它不是要求所有模型必须删掉归一化。RMS归一化本身与可学习gain是两个部件，别把移除gain误写成移除RMSNorm。

本节参考（完整书目见讲义末尾）：[slides] · [transfer]

What is muP not robust to? Exotic optimizers

There are other, exotic optimizers based on just gradient signs. Do they transfer?

Algorithm 1 AdamW Optimizer

given $\beta_1, \beta_2, \epsilon, \lambda, \eta, f$
initialize $\theta_0, m_0 \leftarrow 0, v_0 \leftarrow 0, t \leftarrow 0$
while θ_t not converged **do**
  $t \leftarrow t + 1$
  $g_t \leftarrow \nabla_\theta f(\theta_{t-1})$
  update EMA of g_t **and** g_t^2
  $m_t \leftarrow \beta_1 m_{t-1} + (1 - \beta_1) g_t$
  $v_t \leftarrow \beta_2 v_{t-1} + (1 - \beta_2) g_t^2$
  bias correction
  $\hat{m}_t \leftarrow m_t / (1 - \beta_1^t)$
  $\hat{v}_t \leftarrow v_t / (1 - \beta_2^t)$
  update model parameters
  $\theta_t \leftarrow \theta_{t-1} - \eta_t (\hat{m}_t / (\sqrt{\hat{v}_t} + \epsilon) + \lambda \theta_{t-1})$
end while
return θ_t

Algorithm 2 Lion Optimizer (ours)

given $\beta_1, \beta_2, \lambda, \eta, f$
initialize $\theta_0, m_0 \leftarrow 0$
while θ_t not converged **do**
  $g_t \leftarrow \nabla_\theta f(\theta_{t-1})$
  update model parameters
  $c_t \leftarrow \beta_1 m_{t-1} + (1 - \beta_1) g_t$
  $\theta_t \leftarrow \theta_{t-1} - \eta_t (\text{sign}(c_t) + \lambda \theta_{t-1})$
  update EMA of g_t
  $m_t \leftarrow \beta_2 m_{t-1} + (1 - \beta_2) g_t$
end while
return θ_t

Lion Optimizer	128	**3.708**	3.736	4.057	4.344	10.380	✗
	512	2.952	**2.947**	3.416	3.961	10.285	
	2048	2.519	**2.511**	3.151	10.377	10.377	

What is muP not robust to? – (strong) weight decay

What about strong (0.1) weight decay? – this is maybe the only significant muP failure

Decoupled Weight Decay	128	3.760	**3.679**	3.694	3.741	4.011	✗
	512	3.057	2.963	**2.957**	3.139	3.373	
	2048	2.686	2.535	**2.502**	3.123	6.594	

Algorithm 1 SGD with L_2 regularization and SGD with decoupled weight decay (SGDW), both with momentum

given initial learning rate $\alpha \in \mathbb{R}$, momentum factor $\beta_1 \in \mathbb{R}$, weight decay/L_2 regularization factor $\lambda \in \mathbb{R}$

initialize time step $t \leftarrow 0$, parameter vector $\boldsymbol{\theta}_{t=0} \in \mathbb{R}^n$, first moment vector $\boldsymbol{m}_{t=0} \leftarrow \boldsymbol{0}$, schedule multiplier $\eta_{t=0} \in \mathbb{R}$

repeat

$t \leftarrow t + 1$

$\nabla f_t(\boldsymbol{\theta}_{t-1}) \leftarrow \text{SelectBatch}(\boldsymbol{\theta}_{t-1})$ ▷ select batch and return the corresponding gradient

$\boldsymbol{g}_t \leftarrow \nabla f_t(\boldsymbol{\theta}_{t-1}) + \lambda \boldsymbol{\theta}_{t-1}$

$\eta_t \leftarrow \text{SetScheduleMultiplier}(t)$ ▷ can be fixed, decay, be used for warm restarts

$\boldsymbol{m}_t \leftarrow \beta_1 \boldsymbol{m}_{t-1} + \eta_t \alpha \boldsymbol{g}_t$

$\boldsymbol{\theta}_t \leftarrow \boldsymbol{\theta}_{t-1} - \boldsymbol{m}_t - \eta_t \lambda \boldsymbol{\theta}_{t-1}$

until *stopping criterion is met*

return optimized parameters $\boldsymbol{\theta}_t$

第 11 讲 · 原页 55–56 · 中文讲解

Lion 与权重衰减：迁移的边界

原页55：Lion改变更新方向与尺度

Lion基于动量与梯度组合的符号给出更新，与Adam的二阶矩归一化不同。原页表中最小宽度与较大宽度的最佳base LR不同，说明直接沿用既有μP配置并不保证迁移成功。不要据此断言符号优化器永远无法参数化，也不要把Lion与Muon混为一谈：前者是元素符号操作，后者对矩阵奇异方向作处理。

原页56：解耦衰减不只是loss里多一项

编者解释：AdamW式更新可示意为$W_{next}=(1-\eta\lambda)W-\eta U$，其中U为预处理梯度，λ为weight decay。忽略梯度时，T步累计收缩为$\prod_t(1-\eta_t\lambda)$，小$\eta\lambda$时约$\exp(-\lambda\Sigma_t\eta_t)$。因此即便λ数值相同，只要实际η、步数或调度不同，累计收缩就不同；B改变还会通过步数$T\approx D/B$影响它。

编者算例与边界

λ=0.1、η=0.01、T=1000时纯衰减因子约0.999^(1000)≈0.3677；若η=0.0025而步数不变，则约0.99975^(1000)≈0.7788。原表λ=0.1的案例出现最小代理与大模型最佳η不一致，属于其具体实验的迁移失败；它不是关于所有强衰减阈值的定理。理论推导只讨论梯度更新时，没有自动涵盖这项额外、长期累积的作用。

本节参考（完整书目见讲义末尾）：[slides] · [transfer]

Is muP useful? At least to some extent..

Overall, muP generally seems useful – insofar that SP is quite a bit more unstable.

Width	LR				
	2^{-10}	2^{-8}	2^{-6}	2^{-4}	2^{-2}
128	3.841	3.757	**3.706**	3.879	4.030
512	3.013	**2.967**	2.987	3.383	7.403
2048	**2.738**	2.902	7.247	7.477	7.314

Table 3: Validation losses for SP models.

Params	Width	Base LR		
		2^{-8}	2^{-6}	2^{-4}
2M	128	3.791	**3.766**	3.814
40M	512	3.016	**2.983**	3.004
600M	2048	2.513	**2.459**	2.466
10B	8192	2.238	**2.167**	2.169

Table 4: Validation losses for our large-scale experiment.

Current evidence suggests that muP parametrization / initialization may be easier to tune.

Recap: scaling in the wild

What are challenges in scaling ‘in practice’

1. Setting model arch hyperparameters (width, etc)
2. Setting optimizer hyperparameters (LR, batch)
3. Compute needed to fit the big chinchilla sweep

Some solutions?

1. Assume stability (or use muP)
2. Search for optimal LR / batch in small scale, either keep fixed or predict scaling
3. Use alternative learning schedules (WSD-like)

第 11 讲 · 原页 57–58 · 中文讲解

回到实践：一条有验证环节的缩放流程

原页**57**：相对价值与限制

SP对照表中宽度增大时最佳学习率明显移动；μP大规模实验中基准η更稳定。因此μP的实际收益可以是减少重新搜索、改善预测稳定性，而不一定是每个任务都比精调SP低很多loss。它应与经验拟合互补：μP控制部分漂移，batch、调度、数据配方及优化器变化仍需实验。

编者整讲实验流程

先固定tokenizer、评估集、模型族与参数口径，定义资源目标。再在小规模同时检查学习率和batch：使用μP时验证参数组和base LR迁移，不使用时拟合规模依赖。接着选N,D或IsoFLOP网格，用一致的WSD式协议共享稳定前缀，为各终点另做衰减，并记录实际总实验成本。然后用第9讲方法1/2/3拟合，同时保留失败点和拟合残差。最后在未见过的中等规模验证损失预测、超参数近邻与稳定性，通过后再做最大训练。

课堂补充 · **01:15:11–01:16:49**

结尾强调μP有助于稳定学习率，直接拟合缩放也有价值，但目前没有保证永远外推成功的单一方法。读完本讲应能给出“这项结论在什么模型族、调度、数据和预算下成立”，并能设计一个小实验反驳自己的假设；这比记住某个最佳比例或学习率数字更接近实际训练能力。

本节参考（完整书目见讲义末尾）：[slides] · [captions]

自测与参考答案

1. 第9讲写L(N,D)，本讲为什么要重新讨论学习率和batch？

省略这些变量，隐含各规模都获得可比较且足够好的训练。若学习率随规模失配，拟合的是L(N,D;训练缺陷)，不能把所得指数全归因于容量或数据。先固定配方或校准超参数，再收集完整终点。

2. 为什么200步cosine的100步checkpoint不能替代100步cosine终点？

同一时刻前者η=η_max/2，后者已到0；更早的更新也不同。完整调度的一半与较短完整调度不是同一实验。原页13的重新训练要求针对这个依赖，而非排除WSD共享前缀。

3. 三个目标100、200、400M tokens，尾段10%，共享WSD主干总共花多少tokens？

最长稳定主干360M，另加10M、20M、40M尾段，共430M，而独立训练为700M，少约38.6%。每个终点自己的D仍为100、200、400M；共享前缀不会让大模型看到少于400M就变成400M训练。此例假定固定warmup成本可忽略且稳定配方完全一致。

4. 方法1、2、3各在哪里找最优点？

方法1在loss–compute族曲线取下包络；方法2在每个固定compute的loss–model曲线找谷底；方法3先拟合L(N,D)曲面，再在计算约束上优化。WSD帮助为三者收集终点，但不消除拟合假设或使相关终点变独立。

5. L=E+A N^(–a)+B_0D^(–a)且C=6ND时，为何D/N可为常数？

驻点条件aA N^(–a)=aB_0D^(–a)，所以(D/N)^a=B_0/A，D/N=(B_0/A)^(1/a)。若两指数不同，比值一般随C变；系数与计量单位有关。常数比例也是给定拟合形式与协议下的推论。

6. 固定N增加D时最佳η上升，是否反驳DeepSeek的η随C下降？

不反驳。固定N是在二维曲面沿D方向走；最优compute路径一般N,D一起增大。若η∝N^aD^b，N∝C^p，沿该路径η∝C^[ap+b(1–p)]，可能为负。调度和参数化差异也会改变经验规律。

7. 总参数100B、激活10B、训练960B tokens，两个数据参数比分别是多少？

对激活参数是96，对总参数是9.6。MoE图若用active parameter就应报96。计算估计需再考虑共享层、注意力、路由与通信；不能仅凭总参数套用密集模型FLOPs。

8. μP宽度扩大4倍，为什么还能说最佳学习率不变？

不变通常指base LR。对等宽Adam隐藏矩阵，实际η按fanin倒数约除4，初始化标准差约除2；其他参数组依角色处理。若把所有组的原始η固定，未实施同一迁移规则。

9. $\|W\|_{*}=1$且$\|h\|_2=1$，是否推出$\|Wh\|_2=1$？

只能推出≤1。取W=diag(1,0)、$h=(0,1)^{\top}$就得0。μP谱范数启发式的Θ下界需要非退化方向等条件，不能由上界直接得到。

10. 为何页48的更新等号不能直接用于任意batch或Adam？

单样本SGD有$\Delta W=-\eta g h^{\top}$，该训练样本h恰沿其右奇异方向，所以达到谱范数界。batch是多个外积之和，Adam又逐元素改变更新，秩和方向都可能变，需重新分析。

11. 为什么$\Delta\ell=O(1)$还不足以推导页49的梯度Θ尺度？

O(1)允许$\Delta\ell$随宽度趋0。要反推出同阶非零梯度，需要$|\Delta\ell|=\Theta(1)$的一阶贡献、更新与梯度的关系、有效秩及非退化等条件。谱范数与Frobenius范数的互换也依赖秩。

12. Muon训练所需token少20%，每步贵50%，是否更省时间？

在batch相同、其他开销忽略的例子中时间为0.8×1.5=1.2倍，因此更慢。token等效加速是1.25倍，不等于墙钟加速。比较时还要公平调学习率、weight decay，并看规模与训练终点。

13. RMSNorm gain或weight decay导致一次迁移失败，应作什么结论？

只能断言该实现、超参数网格和预算下迁移失败。应核对参数组规则、衰减累计作用并做受控对照，不能推广为μP普遍无效。

参考资料

[course] Stanford CS336 Spring 2026 官方课程与讲次表

https://cs336.stanford.edu/

[slides] Lecture 11 官方原课件，本讲页码与图表的首要来源

https://github.com/stanford-cs336/lectures/blob/main/lecture_11.pdf

[captions] Lecture 011 公开录像字幕的第三方存档，非教师审校逐字稿

https://jingzechen.github.io/assets/courses/stanford-cs336-s26/lectures/011/captions.source.srt

[minicpm] MiniCPM（原论文；**μP**、**WSD**与缩放实验）

https://arxiv.org/html/2404.06395v3

[deepseek] DeepSeek LLM（原论文；超参数与**IsoFLOP**实验）

https://arxiv.org/html/2401.02954v1

[step] Predictable Scale Part I: Step Law，作者项目与原论文入口

https://step-law.github.io/

[optimizers] Fantastic Pretraining Optimizers and Where to Find Them（原论文）

https://arxiv.org/abs/2509.02046

[spectral] A Spectral Condition for Feature Learning，原论文，简化**μP**谱尺度推导

https://arxiv.org/html/2310.17813v1

[transfer] A Large-Scale Exploration of μ-Transfer，原论文**v4**，与课件标题和表格对应

https://arxiv.org/html/2404.05728v4